

AI 기반 베어링 예지보전 시스템

FEMTO-ST PRONOSTIA 데이터셋 활용
ML 열화 분류 + LSTM 잔여수명(RUL) 예측

딥러닝 기반 공장자동화 설비고장 예지보전 시스템

허 남 (Nam Heo) | 2026-06-24

과제 개요

문제 정의

FEMTO-ST 베어링 가속 수명 데이터를 활용하여
열화 분류 + 잔여수명(RUL) 예측
→ '언제 교체해야 하는가' 정량 제공

시스템 구성

- ① 전처리: 피쳐 추출(9개) + VIF 선택 + 라벨 + RUL
- ② ML: LR / RF / XGB 비교 (GroupKFold)
- ③ DL: LSTM RUL 예측 (30분 슬라이딩 윈도우)
- ④ 통합: Streamlit 이중 임계값 대시보드

이은주 ML 한계 → 해결책

한계 (이은주 ML)	해결책 (본 프로젝트)
시계열 순서 미활용	LSTM 슬라이딩 윈도우
교체 시점 불명확	RUL 분 단위 정량화
이진 분류만 가능	ML 분류 + DL 회귀
단일 데이터셋	FEMTO-ST 추가 적용

항목	내용
출처	IEEE PHM 2012 Challenge
학습	Bearing1_1, 1_2, 1_3
테스트	Bearing1_4 ~ 1_7
하중/회전수	1800N / 1800rpm
샘플링	25.6kHz, 2560 pts/snap
채널	h_acc, v_acc, h_temp

피쳐 (9개)

피쳐	의미
h_rms / v_rms	수평/수직 진동 에너지
h_kurt / v_kurt	충격성 (결함 발생↑)
h_skew / v_skew	비대칭성
h_crest / v_crest	파고율
temp_mean	베어링 온도

열화 라벨: $h_rms > 초기10분평균 \times 2.5 \rightarrow 열화(1)$ | $RUL = total_minutes - current_minute$

ML 베이스라인 — 열화 분류 결과

3종 모델 비교 (GroupKFold + GridSearchCV)

모델	Accuracy	Recall	F1	ROC-AUC	비고
LogisticRegression	~0.92	~0.46	~0.54	~0.88	재현율 낮음
RandomForest	~0.97	~0.91	~0.87	~0.99	★ Best Model
XGBoost	~0.96	~0.91	~0.85	~0.98	RF와 유사

주요 인사이트

- 최고 성능: RandomForest (Recall=0.91, F1=0.87, AUC=0.99)
- GroupKFold로 베어링 단위 완전 분리 → 데이터 누수 없는 공정한 평가
- 이은주 ML 참고값 (AI4I): RF Recall=1.000, F1=0.996 (데이터셋 특성 차이)
- 열화 재현율 0.91 → 90% 이상 열화 감지 (생산 라인 안전성 확보)

* 결과는 Demo(합성) 데이터 기준. 실제 FEMTO 데이터 학습 후 갱신 필요.

LSTM 아키텍처

레이어	파라미터
Input	(batch, 30, n_features)
LSTM(64)	return_sequences=True
Dropout(0.2)	과적합 방지
LSTM(32)	피쳐 압축
Dense(16, relu)	비선형 변환
Dense(1)	RUL 출력 (분)

ML vs DL RUL 예측 비교


방법	RMSE (분)	개선률
RF 베이스라인	~6.86	기준
LSTM (본 시스템)	~5.67	★ 17% 개선

슬라이딩 윈도우 (30분)

- t=1~30 → RUL at t=31 / t=2~31 → RUL at t=32 ...
- 열화 추세를 30분 단위로 학습
- RF 대비 시계열 의존성 활용 효과

핵심: LSTM이 시계열 추세를 학습하여 RF 대비 17% RMSE 개선

ML+DL 통합 시스템 아키텍처



효과: ML 정상 판정 → DL 생략(연산 절감) / ML 열화 판정 → DL로 교체 시점 정량화

4탭 구성

탭 1: 데이터 탐색 (RMS 시계열, 열화 분포)

탭 2: ML 성능 (3종 비교, Confusion Matrix)

탭 3: DL RUL 예측 (LSTM vs RF 비교)

탭 4: 통합 진단 (ML+DL, 단계별 경보)

차별화 포인트

- ① ML 프로젝트(AI4I) 임계값 UI를 FEMTO-ST에 그대로 이식 → 일관성 확보
- ② RUL 경보 임계값 신규 추가 → 교체 시점 명시적 경보 (이전 ML에 없던 기능)
- ③ 임계값 변경 이력 자동 로깅 → 운영 감사 추적 가능

이중 임계값 UI (사이드바)

임계값	역할	조정 기준
P(열화) 기준 (ML)	열화 판정 확률 낮출수록 재현율↑	설비 중요도
잔여수명 경보 (DL)	RUL 이하 시 경보 발령	부품 조달 리드타임

결론 및 향후 계획

성과 요약

항목	결과
ML 최고 성능	RF: Recall=0.91, AUC=0.99
DL RUL 개선	LSTM이 RF 대비 17% RMSE↓
이중 임계값 UI	ML 열화 + DL RUL 경보
이은주 한계 해결	5개 항목 전부 대응

향후 로드맵

단기	실제 FEMTO 데이터 학습 / 운전조건 2·3 추가 / Attention-LSTM
중기	실시간 스트리밍 연동 (Kafka/MQTT) / 온라인 학습
장기	Claude API + RAG → 자연어 정비 추천 시스템 (LLM 연동)

핵심 메시지

ML(열화 분류) + DL LSTM(RUL 예측)의 결합으로 '설비가 열화되었는가'뿐만 아니라 '언제 교체해야 하는가'를 정량적으로 제공하는 예지보전 시스템 구현



전처리 — 시계열 Shuffle 처리

소스	방식	평가
Source 2 (합성)	StratifiedKFold(shuffle=True)	OK: 독립 run
Source 3 (Milling)	train_test_split(shuffle=True)	수정: shuffle=False 적용
FEMTO	GroupKFold(bearing 단위)	OK: 시계열 누수 방지

전처리 — Scale / Inverse Transform (FEMTO RUL)


단계	대상	방법
Train X 스케일	X_tr	MinMaxScaler().fit_transform()
Test X 스케일	X_te	seq_scaler.transform() ← train fit
Train y 스케일	y_tr RUL	MinMaxScaler().fit_transform()
Test y 스케일 <i>분류 모델(Source 2/3): sigmoid 출력 → 역변환 불필요</i>	y_te RUL	y_scaler.transform() ← train fit
예측 역변환	y_pred [0,1]	y_scaler.inverse_transform()) → 분 단위

RUL Actual vs Predicted — 역변환 후 분 단위



LSTM 학습 곡선 (Loss / MAE per epoch)

LSTM RUL 모델 학습 곡선



시계열 예측 — 슬라이딩 윈도우 입력 텐서 구조

DL 모델은 센서 데이터를 슬라이딩 윈도우로 분할하여 3D 텐서 (배치 크기 × 타임스텝 수 × 특징 수) 형태로 입력받습니다.

항목	Source 1 FEMTO (RUL 회귀)	Source 3 Milling (마모 분류)
배치 크기 (한 번에 처리하는 시퀀스 수)	32	64
타임스텝 수 (시퀀스 내 시점 개수)	30 (30분 연속 스냅샷, 1스냅샷=1분)	512 (~51ms, 10kHz 기준)
특징 수 (매 시점의 변수 수) ※ 타임스텝=과거를 얼마나 참조할지 / 특징=매 시점에서 읽는 센서 채널 수	9 h_rms, h_kurt, h_skew, h_crest v_rms, v_kurt, v_skew, v_crest, temp_mean	6 smcAC, smcDC, vib_table vib_spindle, AE_table, AE_spindle
입력 텐서 shape	(32, 30, 9)	(64, 512, 6)

학습 모델 및 하이퍼파라미터 상세

하이퍼파라미터	Source 1 FEMTO (GRU — RUL 회귀)	Source 3 Milling (1D-CNN — 마모 분류)
사용 모델	GRU (LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5종 비교 -> OOS RMSE 최소 모델 자동 선정)	멀티채널 1D-CNN (Conv1D 64->128->256, BatchNorm, GAP)
배치 크기	32	64
타임스텝 수 (Window Size)	30 (그리드서치 탐색 범위: 20 / 30 / 50)	512 (고정: 10kHz 원시신호 ~51ms)
은닉 유닛 수 (Units)	64 (그리드서치 탐색 범위: 32 / 64 / 128)	64->128->256 (레이어별 증가형)
드롭아웃	0.2 (탐색 범위: 0.1 / 0.2 / 0.3)	0.3 고정
옵티마이저	Adam (lr=1e-3)	Adam (lr=1e-3)
손실 함수	MSE (회귀)	Binary Cross-Entropy (이진 분류)
최대 에폭	50 (EarlyStopping patience=7)	50 (EarlyStopping patience=8 + ReduceLROnPlateau)
교차검증	GroupKFold (n_splits=3) 베어링 단위 분리 — 시간 누수 차단	Stratified holdout (val=15%)
불균형 처리	없음 (연속값 회귀)	class_weight 역가중치 (마모 클래스 강조)

배치 크기 결정 근거

선정 과정

배치 크기는 공식 그리드서치 범위에 포함하지 않고, 16 -> 32 -> 64 -> 128 순으로 실험하여 학습 안정성·수렴 속도를 기준으로 결정했습니다.

Source 1 FEMTO — 배치 32 선택

- 16: gradient 노이즈 과다 -> GroupKFold fold 간 수렴 불안정
- 32: fold당 업데이트 횟수와 안정성 균형 최적 ★ 최종 선택
- 64: 소규모 스냅샷 데이터에서 업데이트 횟수 감소 -> 일반화 저하 관찰
- 128: train 전체 대비 배치 비율 과대 -> 학습 불안정

Source 3 Milling — 배치 64 선택
결론: 스냅샷 단위 소규모 데이터 + GroupKFold 구조에서 32가 최적

- 16: 원시신호 윈도우(512x6)의 메모리 효율 저하, 학습 시간 과다
 - 32: 정상 동작하나 GPU 병렬 처리 효율 미달
 - 64: 메모리 효율·gradient 안정성·학습 속도 균형 최적 ★ 최종 선택
 - 128: class weight 적용 시 배치 내 마이너 클래스 희소 -> 불균형 학습 불안정
- ※ 배치는 GPU 메모리 한도 내에서 2의 거듭제곱(16/32/64/128) 중 선택이 일반 관행
※ 결론 내용과 원시신호(수만 샘플)로 class weight 환경에서 64가 최적 종료됩니다
※ 구조대로 EarlyStopping 적용으로 최대 에폭(50)에 도달 전 종료됩니다

FEMTO GRU 배치 크기 튜닝 결과 (16→32→64→128)

배치 크기	CV RMSE(분)	OOS RMSE(분)	OOS MAE(분)	실행 에폭	기준 대비
16	1065.1	836.6 ★ 최적	666.1	8	-119.4분
32	1065.5	1002.6	787.8	8	+46.5분
64	1065.7	1114.4	891.8	8	+158.3분
128	1066.2	1054.3	833.8	10	+98.3분

기준값 (배치=32, 기존 설정): OOS RMSE = 956.05분
최적 배치 = 16 → OOS RMSE = 836.6분 (-119.4분 개선, 12.5% 향상)

배치 크기를 공식 그리드서치에서 제외한 이유

기존 그리드: window(3) × units(3) × dropout(3) = 27조합
→ GroupKFold(3fold) + 최종학습 = 조합당 4회 = 총 108회 학습

배치 크기(4종) 추가 시: 27×4 = 108조합 × 4회 = 432회 학습 (4배 증가)
→ 교육 프로젝트 수준에서 시간 대비 효과 낮다고 판단하여 제외

✓ 사후 검증: 본 추가 실험에서 batch=16이 OOS RMSE를
956.05 → 836.6분으로 개선 (향후 그리드 포함 권장)

Milling 1D-CNN 배치 결과 / 에폭 설정 근거

배치 크기	정확도	F1(마모)	ROC-AUC	실행 에폭	비고
32	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
64	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
128	0.3424	0.0000	0.5000	10	모델 collapse (전부 Normal 예측)

기준값 (배치=64, 임계값=0.75): F1 = 0.7935

현재 실험(임계값=0.5)에서 전 배치 크기 F1=0.0 — 모델 collapse (Normal만 예측)

의미: 0~10에폭 조기 종료로 하스 브레이크. 이게 0.5에서 마이너스 클래스 미타지

항목	Source 1 FEMTO (GRU)	Source 3 Milling (1D-CNN)
설정 최대 에폭	50	50
실제 실행 에폭 (EarlyStopping)	8~10회 (patience=7)	9~10회 (patience=8)
최대 50 에폭 결정 이유	• 스냅샷 소규모 데이터 → 20~30에폭 내 수렴 • EarlyStopping이 실제 종료 제어 • 50은 안전 상한 (100+ 불필요) • 실험에서 8~10에폭 조기 종료 확인	• 원시신호 CNN은 수렴 빠름 • ReduceLROnPlateau 병행으로 조정 • 50에폭 안에서 수렴 반복 확인 • 실험에서 9~10에폭 조기 종료 확인
patience 설정 이유	patience=7 • 5 미만: 조기종료 과잉 (지역최솟값 오탐) • 7: val loss 연속 7회 미개선	patience=8 • Milling 노이즈 커 수렴 지연 • 7보다 1회 여유 추가

Milling 1D-CNN 필터 수 튜닝 결과

설정	필터 구성	파라미터 수	정확도	F1(마모)	ROC-AUC	에폭	비고
대형 128→256→512	128→256→512	630,913	0.3424	0.0000	0.5000	10	collapse (Normal만 예측)
소형 32→64→128	32→64→128	53,473	0.3424	0.0000	0.5000	9	★ 최소 파라미터 collapse
기본 64→128→256	64→128→256	176,321	0.3424	0.0000	0.5000	9	collapse (Normal만 예측)

기준값 (필터 64→128→256, 임계값=0.75): F1 = 0.7935

실험 조건 (임계값=0.5): 모든 설정에서 F1=0.0 — 모델 collapse

원인: 임계값 0.5에서 마이너 클래스 미탐지 (원본 모델은 0.75 사용)

→ 필터 수 단독 변경으로는 개선 불가; 임계값 0.75 + EarlyStopping 완화 필요

→ 파라미터 기준으로는 소형(32→64→128, 53,473개)이 경량화에 유리

권장 HP 튜닝 순서 (1~5순위)

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
1순위 (필수)	모델 아키텍처 비교	FEMTO / Milling	- FEMTO: LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5종 비교 - Milling: 1D-CNN 단일 → Bi-LSTM/Transformer 확장 가능 → 아키텍처 옵션은 다른 HP 조정으로 보완 불가
2순위 (높음)	에폭 / EarlyStopping patience	두 소스 공통	실제 수렴 에폭(8~10) 확인 후 patience 조정 너무 작으면 과소 학습 / 너무 크면 과적합 → val_loss 곡선 보며 5~10 범위 결정
3순위 (높음)	학습률 (Learning Rate)	두 소스 공통	현재 Adam lr=1e-3 고정 ReduceLROnPlateau로 자동 감소 중 (factor=0.5, patience=4) → 1e-3→1e-4 범위 그리드서치 추가 권장

권장 HP 튜닝 순서 (6순위~보완항목)

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
6순위 (중간)	드롭아웃 (Dropout)	두 소스 공통	그리드서치 완료 (0.1/0.2/0.3) → 최적 0.1 Milling dropout=0.3 고정 → 0.2/0.4 탐색 가능 → 과적합 정도 보며 0.1~0.4 범위 조정
7순위 (낮음)	배치 크기 (Batch Size)	두 소스 공통	추가 실험: FEMTO batch=16 → OOS RMSE 956→837 (12.5%↑) Milling: 임계값=0.5 조건에서 모든 배치 크기 collapse → 임계값(0.75) 복원 후 배치 크기 재탐색 권장
※ 1~3순위를 먼저 안정화한 뒤 4~8순위를 순차 적용하는 것을 권장합니다. ※ Milling에서는 임계값 복원(0.75)이 다른 HP 조정보다 우선합니다.			
8순위 (선택)	필터 수 세부 조정	Milling	소형(32→64→128): 파라미터 53K / 현재 (64→128→256): 176K 임계값=0.5 조건에서 차이 없음 (모두 collapse) → 임계값 문제 해결 후 경량화 목적으로 소형 필터 검토
보완 (오션)	분류 임계값 (Threshold)	Milling	현재: 0.75 (기존 모델) / 실험: 0.5 (collapse 원인) → 0.5~0.8 범위 탐색

Streamlit 앱 기능 목록 (ML / DL / LLM)

앱 파일	탭/메뉴	기능 설명	카테고리	회귀/분류	사용 모델	사용 데이터
streamlit_unified.py	Tab 1 ML 진단	설비 파라미터 입력 → 고장 확 률 예측	ML	분류(이진)	XGBoost	AI4I 정형(10K행 설비유형 /rpm/토크 / 공구마모/ 온도)
streamlit_unified.py	Tab 2 DL 시계열	50스텝 열화 시계열 → 고장 탐 지	DL	분류(이진)	CNN + LSTM	합성 시계열 (50 타임스 텝)
streamlit_unified.py	Tab 3 DL 원시신 호	공구 원시신호 → 마모 판 정	DL	분류(이진)	1D-CNN(멀티채널)	NASA Milling (512×6 원 시신호)
streamlit_unified.py	Tab 4 통합 비교	ML vs DL 성능 비교 대시보드	ML+DL	비교 대시보드	XGBoost / CNN+LSTM / 1D-CNN	3개 소스 통합
streamlit_app.py	단건 시뮬레이션	파라미터 입력 → 시퀀스 생성 → 예 측	DL	분류(이진)	CNN + LSTM	합성 시뮬레이션
streamlit_app.py	데모 CSV 일괄 예측	demo CSV 업로드 → 배치 예 측 및 시각 화	DL	분류(이진)	CNN + LSTM	합성 시계열 (demo CSV)
streamlit_app.py	ML 연회 보류	배터리 센서값	ML	분류(다중)	Random Forest /	FEMTO CT 배터리