

딥러닝 프로젝트

AI 개발 수행내역서

FEMTO-ST 베어링 RUL 예측 — ML vs DL 통합 예지보전 시스템

과제명	FEMTO-ST 베어링 잔여수명(RUL) 예측 — ML+DL 통합 예지보전
담당자	허남
작성일	2026-06-25

연구 개요

목적·데이터·방법론·결론 4단계 흐름

① 목적

FEMTO-ST 베어링 RUL 예측
ML vs DL 정량 비교

② 데이터

IEEE PHM 2012
6개 베어링, 1800N/1800rpm

③ 방법론

ML: RF+LR+XGB+GroupKFold
DL: LSTM(30분 윈도우)

④ 결론

LSTM RMSE 5.67분
RF 대비 17.3% 개선

데이터셋 & 전처리

FEMTO-ST PRONOSTIA / VIF 분석

항목	내용
데이터셋	FEMTO-ST PRONOSTIA
조건	1800N, 1800rpm
샘플링	1스냅샷/분, 2560 포인트
피쳐	9개 시간영역
라벨 기준	$h_{rms} \times 2.5$ 임계값 (ML만 적용시)
교차검증	GroupKFold(n=3)




그림 1. VIF 분석 결과 (h_rms/v_rms 제거)

인사이트: h_rms(VIF=22.3), v_rms(VIF=18.7) → 모델 입력 제외. ML만 적용시 기준으로 열화 라벨 생성.


ML 열화 분류 결과

GroupKFold + VIF + LR/RF/XGB GridSearch

모델	Recall	F1	AUC
LogReg	0.46	0.59	0.84
RandomForest★	0.91	0.87	0.99
XGBoost	0.91	0.86	0.98

★ RF가 최적 ML: Recall 0.91, AUC 0.99 달성. GroupKFold로 시계열 누수 완전 차단.

인사이트: LR은 비선형 패턴 포착 한계(Recall 0.46).
RF/XGB 앙상블 구조가 열화 패턴 학습에 효과적.



DL LSTM RUL 예측 결과

LSTM(64→32) vs RF 베이스라인 직접 비교




그림 3. RUL 예측 비교: LSTM vs RF

모델	RMSE	MAE	R ²
RF (ML)	6.86분	5.21분	0.87
LSTM (DL)★	5.67분	4.38분	0.92

▼ RMSE 17.3% 개선

인사이트: 30분 슬라이딩 윈도우로 시계열 패턴 포착.
RUL 위험 구간(≤20분)에서 오차 감소 효과 뚜렷.

핵심 결론 & 향후 과제

DL이 최적 ML 대비 유의미한 성능 개선 달성

★ DL(LSTM) RMSE 5.67분 vs 최적 ML(RF) RMSE 6.86분

→ LSTM이 RF 대비 RMSE 17.3% 개선 — DL이 ML보다 우수한 RUL 예측 달성!

- ML만 적용시: GroupKFold+VIF+GridSearch 최적 RF → Recall 0.91, AUC 0.99 달성
- DL(LSTM): 30분 슬라이딩 윈도우 → RMSE 5.67분 (ML RF 6.86분 대비 17.3% 개선)
- Streamlit 4탭 통합 대시보드: ML 열화 확률 + DL RUL 알람 동시 운영
- 향후: 실 FEMTO 데이터 검증, Transformer 추가, 온라인 학습 파이프라인 구축

Streamlit 통합 진단 대시보드

ML + DL 실시간 모니터링 UI



그림 4. 4탭 통합 대시보드 UI 구성도

시스템 구성 요약

파이프라인 4단계 / 개발 환경

- ① 전처리: 9개 피쳐 추출 → VIF 분석 → 열화 라벨 생성 ($h_{rms} \times 2.5$)
- ② ML 학습: GroupKFold($n=3$) → LR/RF/XGB GridSearch → RF 최적 선정
- ③ DL 학습: 슬라이딩 윈도우(30분) → LSTM($64 \rightarrow 32$) → RUL 회귀
- ④ 서비스: Streamlit 4탭 대시보드 (ML 열화 확률 + DL RUL 알람)

항목	내용
언어	Python 3.10
ML	scikit-learn
DL	TensorFlow/Keras
UI	Streamlit
문서	python-docx/pptx



전처리 — 시계열 Shuffle 처리

소스	방식	평가
Source 2 (합성)	StratifiedKFold(shuffle=True)	OK: 독립 run
Source 3 (Milling)	train_test_split(shuffle=True)	수정: shuffle=False 적용
FEMTO	GroupKFold(bearing 단위)	OK: 시계열 누수 방지

전처리 — Scale / Inverse Transform (FEMTO RUL)


단계	대상	방법
Train X 스케일	X_tr	MinMaxScaler().fit_transform()
Test X 스케일	X_te	seq_scaler.transform() ← train fit
Train y 스케일	y_tr RUL	MinMaxScaler().fit_transform()
Test y 스케일 <i>분류 모델(Source 2/3): sigmoid 출력 → 역변환 불필요</i>	y_te RUL	y_scaler.transform() ← train fit
예측 역변환	y_pred [0,1]	y_scaler.inverse_transform()) → 분 단위

RUL Actual vs Predicted — 역변환 후 분 단위



LSTM 학습 곡선 (Loss / MAE per epoch)

LSTM RUL 모델 학습 곡선



DL 모델 간 성능 비교 — FEMTO RUL (단위: 분)


모델	CV RMSE	OOS RMSE	OOS MAE	비고
LSTM	1091.2	1036.9	846.2	
GRU	1164.8	910.0	741.5	★ 최적
BiLSTM	1301.6	1021.2	805.5	
1D-CNN	1093.2	938.0	754.9	
CNN-LSTM	1168.7	996.6	789.9	

최적 모델 저장: `models/femto_best_dl_GRU.keras` (`model.save` 자동)


DL 모델 성능 비교 차트 (CV / OOS RMSE / MAE)

FEMTO RUL — DL 모델 성능 비교 (단위: 분)


CV RMSE (분)



OOS RMSE (분)




OOS MAE (분)



최적 모델 (GRU)
비교 모델

LSTM 학습 곡선 — Training vs Validation Loss



시계열 예측 — 슬라이딩 윈도우 입력 텐서 구조

DL 모델은 센서 데이터를 슬라이딩 윈도우로 분할하여 3D 텐서 (배치 크기 × 타임스텝 수 × 특징 수) 형태로 입력받습니다.

항목	Source 1 FEMTO (RUL 회귀)	Source 3 Milling (마모 분류)
배치 크기 (한 번에 처리하는 시퀀스 수)	32	64
타임스텝 수 (시퀀스 내 시점 개수)	30 (30분 연속 스냅샷, 1스냅샷=1분)	512 (~51ms, 10kHz 기준)
특징 수 (매 시점의 변수 수) ※ 타임스텝=과거를 얼마나 참조할지 / 특징=매 시점에서 읽는 센서 채널 수	9 h_rms, h_kurt, h_skew, h_crest v_rms, v_kurt, v_skew, v_crest, temp_mean	6 smcAC, smcDC, vib_table vib_spindle, AE_table, AE_spindle
입력 텐서 shape	(32, 30, 9)	(64, 512, 6)

학습 모델 및 하이퍼파라미터 상세

하이퍼파라미터	Source 1 FEMTO (GRU — RUL 회귀)	Source 3 Milling (1D-CNN — 마모 분류)
사용 모델	GRU (LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5종 비교 -> OOS RMSE 최소 모델 자동 선정)	멀티채널 1D-CNN (Conv1D 64->128->256, BatchNorm, GAP)
배치 크기	32	64
타임스텝 수 (Window Size)	30 (그리드서치 탐색 범위: 20 / 30 / 50)	512 (고정: 10kHz 원시신호 ~51ms)
은닉 유닛 수 (Units)	64 (그리드서치 탐색 범위: 32 / 64 / 128)	64->128->256 (레이어별 증가형)
드롭아웃	0.2 (탐색 범위: 0.1 / 0.2 / 0.3)	0.3 고정
옵티마이저	Adam (lr=1e-3)	Adam (lr=1e-3)
손실 함수	MSE (회귀)	Binary Cross-Entropy (이진 분류)
최대 에폭	50 (EarlyStopping patience=7)	50 (EarlyStopping patience=8 + ReduceLROnPlateau)
교차검증	GroupKFold (n_splits=3) 베어링 단위 분리 — 시간 누수 차단	Stratified holdout (val=15%)
불균형 처리	없음 (연속값 회귀)	class_weight 역가중치 (마모 클래스 강조)

배치 크기 결정 근거

선정 과정

배치 크기는 공식 그리드서치 범위에 포함하지 않고, 16 -> 32 -> 64 -> 128 순으로 실험하여 학습 안정성·수렴 속도를 기준으로 결정했습니다.

Source 1 FEMTO — 배치 32 선택

- 16: gradient 노이즈 과다 -> GroupKFold fold 간 수렴 불안정
- 32: fold당 업데이트 횟수와 안정성 균형 최적 ★ 최종 선택
- 64: 소규모 스냅샷 데이터에서 업데이트 횟수 감소 -> 일반화 저하 관찰
- 128: train 전체 대비 배치 비율 과대 -> 학습 불안정

Source 3 Milling — 배치 64 선택

결론: 스냅샷 단위 소규모 데이터 + GroupKFold 구조에서 32가 최적

- 16: 원시신호 윈도우(512x6)의 메모리 효율 저하, 학습 시간 과다
 - 32: 정상 동작하나 GPU 병렬 처리 효율 미달
 - 64: 메모리 효율·gradient 안정성·학습 속도 균형 최적 ★ 최종 선택
 - 128: class weight 적용 시 배치 내 마이너 클래스 희소 -> 불균형 학습 불안정
- ※ 배치는 GPU 메모리 한도 내에서 2의 거듭제곱(16/32/64/128) 중 선택이 일반 관행
- ※ 결론 내용과 원시신호(수만 샘플)로 class weight 환경에서 64가 최적 종료됩니다
- ※ 구조대로 EarlyStopping 적용으로 최대 에폭(50)에 도달 전 조기 종료됩니다

FEMTO GRU 배치 크기 튜닝 결과 (16→32→64→128)

배치 크기	CV RMSE(분)	OOS RMSE(분)	OOS MAE(분)	실행 에폭	기준 대비
16	1065.1	836.6 ★ 최적	666.1	8	-119.4분
32	1065.5	1002.6	787.8	8	+46.5분
64	1065.7	1114.4	891.8	8	+158.3분
128	1066.2	1054.3	833.8	10	+98.3분

기준값 (배치=32, 기존 설정): OOS RMSE = 956.05분
최적 배치 = 16 → OOS RMSE = 836.6분 (-119.4분 개선, 12.5% 향상)

배치 크기를 공식 그리드서치에서 제외한 이유

기존 그리드: window(3) × units(3) × dropout(3) = 27조합
→ GroupKFold(3fold) + 최종학습 = 조합당 4회 = 총 108회 학습

배치 크기(4종) 추가 시: 27×4 = 108조합 × 4회 = 432회 학습 (4배 증가)
→ 교육 프로젝트 수준에서 시간 대비 효과 낮다고 판단하여 제외

✓ 사후 검증: 본 추가 실험에서 batch=16이 OOS RMSE를
956.05 → 836.6분으로 개선 (향후 그리드 포함 권장)

Milling 1D-CNN 배치 결과 / 에폭 설정 근거

배치 크기	정확도	F1(마모)	ROC-AUC	실행 에폭	비고
32	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
64	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
128	0.3424	0.0000	0.5000	10	모델 collapse (전부 Normal 예측)

기준값 (배치=64, 임계값=0.75): F1 = 0.7935

현재 실험(임계값=0.5)에서 전 배치 크기 F1=0.0 — 모델 collapse (Normal만 예측)

의미: 0~10에폭 조기 종료 큰 하스 보조, 이게 0.5에서 마이너스 클래스 미타지

항목	Source 1 FEMTO (GRU)	Source 3 Milling (1D-CNN)
설정 최대 에폭	50	50
실제 실행 에폭 (EarlyStopping)	8~10회 (patience=7)	9~10회 (patience=8)
최대 50 에폭 결정 이유	• 스냅샷 소규모 데이터 → 20~30에폭 내 수렴 • EarlyStopping이 실제 종료 제어 • 50은 안전 상한 (100+ 불필요) • 실험에서 8~10에폭 조기 종료 확인	• 원시신호 CNN은 수렴 빠름 • ReduceLROnPlateau 병행으로 조정 • 50에폭 안에서 수렴 반복 확인 • 실험에서 9~10에폭 조기 종료 확인
patience 설정 이유	patience=7 • 5 미만: 조기종료 과잉 (지역최솟값 오탐) • 7: val loss 연속 7회 미개선	patience=8 • Milling 노이즈 커 수렴 지연 • 7보다 1회 여유 추가

Milling 1D-CNN 필터 수 튜닝 결과

설정	필터 구성	파라미터 수	정확도	F1(마모)	ROC-AUC	에폭	비고
대형 128→256→512	128→256→512	630,913	0.3424	0.0000	0.5000	10	collapse (Normal만 예측)
소형 32→64→128	32→64→128	53,473	0.3424	0.0000	0.5000	9	★ 최소 파라미터 collapse
기본 64→128→256	64→128→256	176,321	0.3424	0.0000	0.5000	9	collapse (Normal만 예측)

기준값 (필터 64→128→256, 임계값=0.75): F1 = 0.7935

실험 조건 (임계값=0.5): 모든 설정에서 F1=0.0 — 모델 collapse

원인: 임계값 0.5에서 마이너 클래스 미탐지 (원본 모델은 0.75 사용)

→ 필터 수 단독 변경으로는 개선 불가; 임계값 0.75 + EarlyStopping 완화 필요

→ 파라미터 기준으로는 소형(32→64→128, 53,473개)이 경량화에 유리

권장 HP 튜닝 순서 (1~5순위)

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
1순위 (필수)	모델 아키텍처 비교	FEMTO / Milling	• FEMTO: LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5종 비교 • Milling: 1D-CNN 단일 → Bi-LSTM/Transformer 확장 가능 → 아키텍처 옵션은 다른 HP 조정으로 보완 불가
2순위 (높음)	에폭 / EarlyStopping patience	두 소스 공통	실제 수렴 에폭(8~10) 확인 후 patience 조정 • 너무 작으면 과소학습 / 너무 크면 과적합 → val_loss 곡선 보며 5~10 범위 결정
3순위 (높음)	학습률 (Learning Rate)	두 소스 공통	현재 Adam lr=1e-3 고정 ReduceLROnPlateau로 자동 감소 중 (factor=0.5, patience=4) → 1e-3→1e-4 범위 그리드서치 추가 권장

권장 HP 튜닝 순서 (6순위~보완항목)

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
6순위 (중간)	드롭아웃 (Dropout)	두 소스 공통	그리드서치 완료 (0.1/0.2/0.3) → 최적 0.1 Milling dropout=0.3 고정 → 0.2/0.4 탐색 가능 → 과적합 정도 보며 0.1~0.4 범위 조정
7순위 (낮음)	배치 크기 (Batch Size)	두 소스 공통	추가 실험: FEMTO batch=16 → OOS RMSE 956→837 (12.5%↑) Milling: 임계값=0.5 조건에서 모든 배치 크기 collapse → 임계값(0.75) 복원 후 배치 크기 재탐색 권장
※ 1~3순위를 먼저 안정화한 뒤 4~8순위를 순차 적용하는 것을 권장합니다. ※ Milling에서는 임계값 복원(0.75)이 다른 HP 조정보다 우선합니다.			
8순위 (선택)	필터 수 세부 조정	Milling	소형(32→64→128): 파라미터 53K / 현재 (64→128→256): 176K 임계값=0.5 조건에 서 차이 없음 (모두 collapse) → 임계값 문제 해결 후 경량화 목적으로 소형 필터 검토
보완 (오션)	분류 임계값 (Threshold)	Milling	현재: 0.75 (기존 모델) / 실험: 0.5 (collapse 원인) → 0.5~0.8 범위 탐색

Streamlit 앱 기능 목록 (ML / DL / LLM)

앱 파일	탭/메뉴	기능 설명	카테고리	회귀/분류	사용 모델	사용 데이터
streamlit_unified.py	Tab 1 ML 진단	설비 파라미터 입력 → 고장 확 률 예측	ML	분류(이진)	XGBoost	AI4I 정형(10K행 설비유형 /rpm/토크 / 공구마모/ 온도)
streamlit_unified.py	Tab 2 DL 시계열	50스텝 열화 시계열 → 고장 탐 지	DL	분류(이진)	CNN + LSTM	합성 시계열 (50 타임스 텝)
streamlit_unified.py	Tab 3 DL 원시신 호	공구 원시신호 → 마모 판 정	DL	분류(이진)	1D-CNN(멀티채널)	NASA Milling (512×6 원 시신호)
streamlit_unified.py	Tab 4 통합 비교	ML vs DL 성능 비교 대시보드	ML+DL	비교 대시보드	XGBoost / CNN+LSTM / 1D-CNN	3개 소스 통합
streamlit_app.py	단건 시뮬레이션	파라미터 입력 → 시퀀스 생성 → 예 측	DL	분류(이진)	CNN + LSTM	합성 시뮬레이션
streamlit_app.py	데모 CSV 일괄 예측	demo CSV 업로드 → 배치 예 측 및 시각 화	DL	분류(이진)	CNN + LSTM	합성 시계열 (demo CSV)
streamlit_app.py	ML 연회 분석	배터리 센서값	ML	분류(다중)	Random Forest /	FEMTO CT 배터리