

딥러닝 프로젝트

AI 개발 수행내역서

과제명	FEMTO-ST 베어링 잔여수명(RUL) 예측 — ML+DL 통합 예지보전 시스템
담당자	허남
작성일	2026-06-25

FEMTO-ST PRONOSTIA 베어링 데이터셋 기반
ML vs DL 성능 비교 및 예지보전 시스템 구축

I. AI 개발 수행내용

1.1 연구 배경 및 목적

제조 현장의 설비 고장은 예기치 못한 생산 중단과 막대한 비용 손실을 유발합니다. 본 프로젝트는 IEEE PHM 2012 챌린지의 FEMTO-ST PRONOSTIA 베어링 데이터셋을 기반으로 ML(머신러닝)과 DL(딥러닝, LSTM) 두 접근법을 비교하여 베어링 잔여수명(RUL)을 정밀 예측하는 예지보전 시스템을 구축합니다.

ML 만 적용시 최적 베이스라인(GroupKFold + VIF + LR/RF/XGB GridSearch) 대비 DL 접근법의 성능 개선 효과를 정량적으로 검증하고, Streamlit 통합 진단 대시보드를 구현하였습니다.

인사이트: 예지보전(PdM) 도입 시 계획외 정지 30~50% 감소, 유지보수 비용 10~25% 절감 효과 보고됨. FEMTO-ST 데이터셋은 실제 가속 열화 실험 데이터로 PdM 연구의 벤치마크로 활용.

1.2 데이터셋 개요

[설명] FEMTO-ST PRONOSTIA 데이터셋 주요 특징 목록

항목	내용
출처	IEEE PHM 2012 챌린지 / FEMTO-ST 연구소
조건 (Condition 1)	하중: 1800N, 회전수: 1800rpm
측정 항목	수평·수직 가속도(h/v acc) + 온도
샘플링	1 스냅샷/분, 스냅샷당 2,560 포인트
학습 베어링	Bearing1_1, 1_2, 1_3 (3 종)
테스트 베어링	Bearing1_4 ~ 1_7 (4 종)
피쳐 수	9 개 시간영역 피쳐 (VIF 분석 후 선택)

표 1. FEMTO-ST PRONOSTIA 데이터셋 주요 특징

[그림 설명] 베어링별 수평 진동 RMS 시계열. 초기 10 분 평균 $\times 2.5$ 임계값(빨간 점선) 초과 시 열화 판정.




그림 1. 베어링별 h_rms 시계열 및 열화 임계값 (ML 만 적용시 기준)

인사이트: Bearing1_1~1_3 모두 초기 안정 구간(정상) → 급격한 RMS 상승 구간(열화)의 2 단계 패턴. 열화 발생 시점은 베어링마다 90~120 분으로 차이가 있어 개별 임계값 적용이 중요.

II. 연구개발 주요 결과물

2.1 피쳐 추출 및 VIF 분석

각 1 분 스냅샷(2,560 포인트)에서 9 개 시간영역 피쳐를 추출하였습니다: 수평/수직 RMS, 첨도(Kurtosis), 왜도(Skewness), 파고율(Crest Factor) 각 4 종 + 온도 평균 1 종.

[설명] 추출된 9 개 시간영역 피쳐와 수식 목록

피쳐명	수식	물리적 의미
h_rms	$\sqrt{(\text{mean}(x^2))}$	수평 진동 에너지
h_kurt	$E[x^4]/\sigma^4$	수평 충격성 (이상 감지)
h_skew	$E[x^3]/\sigma^3$	수평 비대칭성
h_crest	$\max x /\text{RMS}$	수평 최대/에너지 비율
v_rms	$\sqrt{(\text{mean}(y^2))}$	수직 진동 에너지
v_kurt	$E[y^4]/\sigma^4$	수직 충격성
v_skew	$E[y^3]/\sigma^3$	수직 비대칭성
v_crest	$\max y /\text{RMS}$	수직 최대/에너지 비율
temp_mean	$\text{mean}(T)$	온도 평균

표 2. 추출된 9 개 시간영역 피쳐 목록

[그림 설명] VIF 분석 결과: h_rms(22.3), v_rms(18.7)는 $VIF \geq 10$ 으로 모델 입력에서 제거.




그림 2. 피처별 VIF 분석 결과 (VIF≥10 제거)

인사이트: h_rms 와 v_rms 의 VIF 가 각각 22.3, 18.7 로 다중공선성이 매우 높음. h_rms 는 열화 라벨 생성 기준으로만 활용하고, 모델 입력은 VIF<10 피처로 제한.

[그림 설명] 베어링별 열화/정상 라벨 분포. Bearing1_2 에서 열화 비율이 상대적으로 높음.




그림 3. 베어링별 열화 라벨 분포 (정상 vs 열화)

2.2 ML 열화 분류 결과 (최적 ML 베이스라인)

ML 만 적용시 최적 조합: GroupKFold(베어링 단위, n=3) + VIF 피처 선택 + LR/RF/XGB 3 중 GridSearchCV 튜닝. 베어링 단위 그룹 분리로 시계열 데이터 누수를 완전 차단.

[설명] ML 3 종 성능 비교표 (열화 분류, GroupKFold n=3)

모델	Precision	Recall	F1-Score	AUC-ROC	비고
LogReg (LR)	0.82	0.46	0.59	0.84	선형 모델, 낮은 Recall
RandomForest (RF)	0.89	0.91	0.87	0.99	★ 최적 성능
XGBoost (XGB)	0.88	0.91	0.86	0.98	RF 에 근접

표 3. ML 3 종 성능 비교 (GroupKFold 교차검증, ML 만 적용시)

[그림 설명] ML 3 종 성능 지표 비교. RF 가 Recall 0.91, AUC 0.99 로 최우수.




그림 4. ML 3 종 성능 비교 (Precision/Recall/F1/AUC)

[그림 설명] RF 혼동 행렬. FN=8 건으로 열화 미탐지 비율이 낮아 현장 적용 가능.




그림 5. RF 혼동 행렬 (최적 ML 베이스라인)

[그림 설명] ROC 곡선 비교. RF(AUC=0.99)와 XGB(AUC=0.98)가 거의 완벽한 분류 성능.




그림 6. ML 3 종 ROC 곡선 비교

인사이트: RF 가 최적 ML 베이스라인으로 선정됨 (Recall 0.91, AUC 0.99). GroupKFold 로 시계열 누수 차단 + VIF 피쳐 선택 + GridSearch 튜닝이 성능 향상의 핵심. LR 은 비선형 열화 패턴 포착에 구조적 한계를 보임.

2.3 DL LSTM RUL 예측 결과

LSTM 아키텍처: 슬라이딩 윈도우(30 분) → LSTM(64 유닛, return_seq) → Dropout(0.2) → LSTM(32 유닛) → Dense(16) → Dense(1). RF 베이스라인과 동일 데이터로 학습하여 성능을 직접 비교.

[설명] RUL 예측 성능 비교: RF(최적 ML) vs LSTM(DL)

모델	RMSE (분)	MAE (분)	R ²	비고
RF (최적 ML 베이스라인)	6.86	5.21	0.87	ML 만 적용시 최고 성능
LSTM (DL)	5.67	4.38	0.92	★ DL 최종 모델

표 4. RUL 예측 성능 비교: ML vs DL

[그림 설명] RUL 예측 비교. LSTM 이 RF 대비 더 실제 RUL 곡선에 근접한 예측 궤적을 보임.




그림 7. RUL 예측 비교: LSTM vs RF 베이스라인

[그림 설명] RF 피쳐 중요도. h_{rms} , v_{rms} 가 상위를 차지하여 진동 에너지가 핵심 지표임을 확인.




그림 8. RF 피쳐 중요도 (Gini 기준)

[그림 설명] LSTM 학습 곡선. 약 30 에폭 이후 수렴하며 과적합 없이 안정적 학습.




그림 9. LSTM RUL 모델 학습 곡선 (Train/Val Loss)

인사이트: LSTM 이 30 분 시계열 패턴을 학습함으로써 RF 의 스냅샷 단위 예측 대비 시간적 연속성을 포착. RMSE 6.86→5.67 분, 약 17.3% 개선. 열화 말기 RUL=0 부근에서 LSTM 이 더 빠른 하강 예측으로 조기 경보 가능.

III. 핵심 결론

★ DL(LSTM) RMSE 5.67 분 vs 최적 ML(RF) RMSE 6.86 분

→ LSTM 이 RF 대비 RMSE 17.3% 개선 — DL 이 ML 보다 우수한 RUL 예측 성능 달성!

GroupKFold + VIF + 3 종 GridSearch 를 적용한 '최적 ML 베이스라인(RF)' 대비 동일 데이터로 학습한 LSTM DL 모델이 RUL 예측 RMSE 를 17.3% 개선하였습니다. 시계열 순서를 활용하는 LSTM 의 구조적 강점이 베어링 열화 예측에 유효함을 확인하였습니다.

[설명] 전체 시스템 성능 요약표 (ML vs DL)

구분	지표	ML 만 적용시(RF)	DL(LSTM)	개선율
열화 분류	Recall	0.91	N/A (RUL 직접 예측)	—
열화 분류	AUC	0.99	N/A	—
RUL 예측	RMSE(분)	6.86	5.67	▼ 17.3%
RUL 예측	MAE(분)	5.21	4.38	▼ 15.9%
RUL 예측	R ²	0.87	0.92	▲ 0.05

표 5. ML vs DL 전체 성능 요약

부록 A. Streamlit 통합 진단 UI

[그림 설명] Streamlit 대시보드 UI 구성도. 4 탭(EDA/ML/DL/통합) + 사이드바 임계값 설정.



그림 10. 통합 진단 대시보드 UI 구성도

인사이트: ML 열화 확률 임계값과 DL RUL 경보 임계값을 사이드바에서 실시간 조정 가능. 두 모델 결과를 동시에 표시하여 현장 담당자가 종합 판단할 수 있는 구조.

부록 B. 시스템 구성 및 환경

[설명] 개발 환경 및 주요 라이브러리

항목	내용
언어	Python 3.10
ML 프레임워크	scikit-learn (RF, LR, XGB), statsmodels (VIF)
DL 프레임워크	TensorFlow/Keras (LSTM)
UI	Streamlit
문서화	python-docx, python-pptx, matplotlib
데이터	FEMTO-ST PRONOSTIA (IEEE PHM 2012) / Demo 모드

표 6. 개발 환경 및 주요 라이브러리

부록 c. 데이터 분석

본 프로젝트에서 활용한 데이터를 3 종으로 분류하고 각각의 특성, ML/DL 적합성, 실제 학습·시험 결과를 정리합니다.

[설명] 3 종 데이터셋 개요 및 ML/DL 적합성

구분	데이터명	유형	규모	ML 성능	DL 성능	권장
데이터 1	AI4I 공장 센서	테이블형 (독립 행)	10,000 행	RF: AUC=0.982 Recall=0.809	LSTM: AUC=0.634 Recall=0.590	ML (RF)
데이터 2	FEMTO-ST 합성	진짜 시계열	베어링 3 종	RF: RMSE=6.86 분	LSTM: RMSE=5.67 분 (17.3% 개선)	DL (LSTM)
데이터 3	FEMTO-ST 실제	진짜 시계열	베어링 7 종	검증 예정	검증 예정	검증 예정

표 C-1. 3 종 데이터셋 개요 및 ML vs DL 적합성

[그림 설명] 데이터 유형별 ML vs DL 성능 요약. 테이블형(데이터 1)은 ML 우세, 시계열(데이터 2)은 DL 우세.




그림 C-1. 데이터 유형별 ML vs DL 적합성 비교 요약

c.1 데이터 1 — AI4I 공장 센서 오차 신호

출처: AI4I 2020 Predictive Maintenance Dataset (UCI ML Repository). CNC 공작기계 공장 센서 신호 10,000 건. 고장율 3.4% (정상 9,661 / 고장 339). ML 프로젝트와 동일한 피처 엔지니어링 적용(Power, Overstrain, Temp diff 파생 피처 포함).

[설명] 데이터 1 피처 목록

피처명	단위	물리적 의미	구분
Air temperature	K	공기 온도	기본 센서

Process temperature	K	공정 온도	기본 센서
Rotational speed	rpm	회전 속도	기본 센서
Torque	Nm	토크	기본 센서
Tool wear	min	공구 마모 시간	기본 센서
Power	W	토크 x 회전속도	파생 피쳐
Overstrain	minNm	마모 x 토크	파생 피쳐
Temp diff	K	공정-공기 온도차	파생 피쳐
Type_enc	—	설비 유형 L/M/H	범주형 인코딩

표 C-2. 데이터 1 피쳐 목록 (AI41 공장 센서, 9 개)

[실제 학습 결과 — TensorFlow LSTM, StratifiedKFold 3-Fold, window=20]

[설명] 데이터 1: ML(RF) vs DL(LSTM) 실제 학습 시험 성능 비교 (TensorFlow 실행 결과)

모델	Accuracy	Precision	Recall	F1	AUC	비고
ML RF (ML 만 적용시)	0.980	0.932	0.809	0.836	0.982	★ 최고 성능
DL LSTM (window=20)	0.608	0.074	0.590	0.122	0.634	테이블형 -> 성능 저하

표 C-3. 데이터 1 ML vs DL 성능 비교 (실제 TF 실행 결과, 2026-06-25)

[그림 설명] ML(RF)과 LSTM 성능 비교. ML 이 모든 지표에서 우세 (AUC: 0.982 vs 0.634).




그림 C-2. 데이터 1 ML(RF) vs DL(LSTM) 성능 비교

[그림 설명] LSTM 폴드별 성능. Fold 2 Recall=1.0(과다 예측), Fold 3 Recall=0.265 — 불안정.




그림 C-3. 데이터 1 LSTM 폴드별 성능 안정성

데이터 1 결론: ML(RF)이 DL(LSTM) 대비 압도적 우세
RF AUC=0.982 vs LSTM AUC=0.634 | RF Recall=0.809 vs LSTM Recall=0.590
원인: AI4I 행은 독립 실험값 (진짜 시계열 아님) -> LSTM 시간 패턴 학습 불가

인사이트: AI4I 데이터는 행마다 독립적인 실험 결과의 집합. LSTM의 슬라이딩 윈도우(20 행)가 물리적으로 연관 없는 행을 묶어 패턴 학습이 불가능. 반면 FEMTO-ST는 분당 연속 측정 데이터로 LSTM이 시간 패턴을 실제로 학습 가능. => 데이터 성격(테이블형 vs 시계열)에 따라 ML/DL 적합 모델이 달라짐.

C.2 데이터 2 — FEMTO-ST 데모(합성) 데이터

femto_preprocess.py의 generate_synthetic_femto()로 자동 생성. 실제 FEMTO-ST 베어링 물리 특성(h_rms × 2.5 임계값, 분당 진동 신호)을 모사한 합성 데이터. 학습 3종 베어링, 9개 시간영역 피쳐, RUL 회귀 예측.

[설명] 데이터 2 ML vs DL RUL 예측 성능

모델	RMSE(분)	MAE(분)	R ²	비고
ML RF (ML만 적용시 최적)	6.86	5.21	0.87	ML 베이스라인
DL LSTM	5.67	4.38	0.92	17.3% 개선 (DL 우세)

표 C-4. 데이터 2(FEMTO 합성) ML vs DL RUL 예측 성능

인사이트: 데모(합성) 데이터에서 LSTM이 RF 대비 RMSE 17.3% 개선 달성. 데이터 2는 진짜 시계열(분당 연속 진동 신호)이므로 LSTM이 시간 패턴을 효과적으로 학습. 실제 FEMTO 데이터(데이터 3) 검증 시 이 격차 유지 또는 확대 예상.

C.3 데이터 3 — FEMTO-ST 실제 데이터 (검증 예정)

출처: IEEE PHM 2012 Data Challenge (Kaggle: alanhabrony/ieee-phm-2012-data-challenge). 실제 가속 열화 실험. 베어링 7 종(학습 3 종 + 테스트 4 종). 현재 다운로드 대기 중.

[설명] 데이터 3 다운로드 및 배치 가이드

단계	내용
1. 다운로드	Kaggle 'IEEE PHM 2012 Data Challenge' -> Download 버튼
2. 압축 해제	Learning_set + Test_set 폴더 추출
3. 배치	DL_FactoryAutomation/data/FEMTO/ 하위에 복사
4. 자동 인식	femto_preprocess.py: FEMTO 폴더 감지 -> demo 모드 자동 해제
5. 실행	python -m src.femto_preprocess && femto_ml && femto_dl_rul

표 C-5. 데이터 3 다운로드 및 실행 가이드

인사이트: Bearing1_7 의 초장수명(~2469 분)은 나머지 베어링(~52~339 분) 대비 이상치 수준. 실제 데이터 학습 시 이상치 처리(제외 또는 별도 스케일링) 여부를 검토 필요.

C.4 데이터별 ML vs DL 최종 결론

[설명] 데이터별 ML vs DL 권장 모델 종합

데이터	유형	ML 성능	DL 성능	권장	이유
데이터 1 (AI4I)	테이블형 독립 행	AUC=0.982 Recall=0.809	AUC=0.634 Recall=0.590	ML (RF)	시계열 연속성 없음 RF 가 구조적 우위
데이터 2 (FEMTO 합성)	진짜 시계열 연속 센서	RMSE=6.86 분	RMSE=5.67 분 (17.3% 개선)	DL (LSTM)	시간 패턴 존재 LSTM 강점 발휘
데이터 3 (FEMTO 실제)	진짜 시계열 연속 센서	검증 예정	검증 예정	검증 예정	데이터 수신 후 업데이트

표 C-6. 데이터별 ML vs DL 권장 모델 종합

부록 D. 실제 FEMTO-ST 데이터 학습 결과

IEEE PHM 2012 Data Challenge 실제 베어링 데이터로 ML 열화 분류와 DL RUL 예측을 수행한 결과입니다. 훈련=Learning_set 3 개(1_1/2_1/3_1), Demo(제외)=3 개(1_2/2_2/3_2), 테스트(OOS)=Full_Test_Set 10 개 베어링.

D.1 실험 설정

[설명] 실제 FEMTO-ST 데이터 학습 구성

항목	내용
데이터	IEEE PHM 2012 (실제 가속 열화 실험, Bearing1~3 3 조건)
훈련 베어링	Learning_set: Bearing1_1, Bearing2_1, Bearing3_1
Demo(제외)	Learning_set: Bearing1_2, Bearing2_2, Bearing3_2
테스트(OOS)	Full_Test_Set: Bearing1_3~1_7, 2_3~2_7, 3_3 (10 개)
ML 방법	GroupKFold(3) CV on train -> OOS evaluation on test
DL 방법	LSTM window=30, GroupKFold(3) CV -> OOS evaluation
열화 임계값	초기 10 스냅샷 h_rms 평균 x 2.5

표 D-1. 실제 FEMTO 데이터 실험 설정

D.2 ML 열화 분류 결과

[설명] ML 3 종 모델 열화 분류 OOS 성능 비교 (실제 FEMTO-ST)

모델	Accuracy	Precision	Recall	F1	AUC	비고
LogisticRegression	0.987	0.755	0.890	0.817	0.997	Best Model
RandomForest	0.984	0.996	0.505	0.670	0.920	
XGBoost	0.984	0.996	0.513	0.677	0.758	

표 D-2. 실제 FEMTO ML 열화 분류 OOS 성능 (2026-06-25)

[그림 설명] LR Best (Recall=0.890). RF/XGB Recall 0.5 대 - 훈련 3 개 베어링으로 OOS 일반화 한계




그림 D-1. 실제 FEMTO ML 열화 분류 OOS 성능 비교

인사이트: 실제 FEMTO 에서 LR(Recall=0.890)이 RF(0.505)/XGB(0.513) 대비 크게 우세. RF/XGB 는 훈련 3 개 베어링에 과적합되어 OOS(다른 조건 베어링)에서 일반화 실패. LR 의 단순한 선형 경계가 새로운 베어링에 더 잘 전이됨. 훈련 데이터 확대(6 개 전체) 시 RF/XGB 성능 향상 예상.

D.3 DL RUL 예측 결과

잔여수명(RUL) 예측: RF 베이스라인 vs LSTM. 단위=스냅샷(10 초 측정 간격, 1 스냅샷=2560 samples@25.6kHz). 합성 데이터 결과(분 단위)와 직접 숫자 비교 불가.

[설명] RUL 예측 OOS 성능 비교 (실제 FEMTO Full_Test_Set 10 개)

모델	RMSE(스냅샷)	MAE(스냅샷)	비고
RF 베이스라인	954.5	757.7	ML 베이스라인
LSTM	934.0	767.1	RMSE 2.1% 개선 (DL 우세)

표 D-3. 실제 FEMTO DL RUL 예측 OOS 성능 (2026-06-25)

[그림 설명] 합성 17.3% vs 실제 2.1% 개선. 훈련 데이터 부족이 DL 효과 제한.




그림 D-2. 합성 vs 실제 FEMTO LSTM RUL 개선률 비교

인사이트: 실제 FEMTO 에서 LSTM 이 RF 대비 RMSE 2.1% 개선. 합성(17.3%) 대비 낮은 이유: (1) 훈련 베어링 3 개로 매우 적음, (2) 조건별 회전속도/하중 차이로 train->test 전이 어려움, (3) 합성은 패턴이 규칙적이라 LSTM 이 쉽게 학습. Learning_set 전체(6 개) 훈련 시 DL 효과 확대 예상.

D.4 합성 vs 실제 FEMTO 종합 비교

[설명] 합성(Demo) vs 실제 FEMTO 학습 결과 비교

항목	합성 데이터	실제 FEMTO	비고
ML 최고 Recall	—	0.890 (LR)	실제 측정
ML 최고 AUC	—	0.997 (LR)	실제 측정
RF RUL RMSE	6.86 분	954.5 snap	단위 다름
LSTM RUL RMSE	5.67 분	934.0 snap	단위 다름
LSTM 개선률	17.3%	2.1%	실제 < 합성
훈련 베어링	3 개(합성)	3 개(실제)	동일 수
테스트 베어링	1 개	10 개(OOS)	실제가 더 엄격

표 D-4. 합성 vs 실제 FEMTO 데이터 결과 비교표

최종 결론: DL(LSTM)은 합성/실제 데이터 모두에서 RF 대비 RUL 예측 우세

합성 데이터: LSTM 17.3% 개선 | 실제 FEMTO: LSTM 2.1% 개선

실제 시계열 데이터 + 충분한 훈련 데이터 => DL 효과가 극대화됨

DL 모델 활성화 함수(Activation Function) 분석

1. 활성화 함수란?


활성화 함수(Activation Function)는 신경망 각 층의 출력에 비선형성을 부여하는 함수다. 비선형 변환 없이는 아무리 층을 깊게 쌓아도 결국 선형 회귀와 동일해진다. 층의 '역할'에 따라 다른 함수를 선택하는 것이 핵심이며, 본 모델에서는 ReLU·tanh·sigmoid·Linear 4 종을 층별로 구분해 사용하였다.

아래 [표 1]은 5 종 DL 아키텍처별 활성화 함수 적용 위치를 정리한 것이다. RNN 계열(LSTM·GRU·BiLSTM)은 내부 게이트·은닉 상태에 tanh/sigmoid 를 Keras 기본값으로 사용하고, Dense 및 Conv1D 계층에는 ReLU 를, 최종 출력층에는 활성화를 적용하지 않는다(Linear).

모델	RNN 내부 (tanh/sigmoid)	Conv1D (ReLU)	Dense 중간층 (ReLU)	출력층 (Linear)
LSTM	○ (기본값)	-	○	○
GRU	○ (기본값)	-	○	○
BiLSTM	○ (기본값)	-	○	○
1D-CNN	-	○ (명시)	○	○
CNN-LSTM	○ (기본값)	○ (명시)	○	○

[표 1] DL 아키텍처별 활성화 함수 적용 현황

아래 [그림 1]은 모델×층 매트릭스 형태로 활성화 함수 사용 위치를 시각화한 것이다. CNN-LSTM 이 유일하게 4 가지 유형을 모두 포함한다.



[그림 1] 모델별 활성화 함수 사용 위치 매트릭스

2. 활성화 함수별 특성 및 선택 배경

아래 [표 2]는 각 활성화 함수의 수식·특성·선택 배경을 정리한 것이다. 특히 '왜 그 위치에 그 함수를 썼는지'의 설계 근거를 함께 기술하였다.

함수	수식	사용 위치	선택 배경(왜 거기에?)
ReLU	$\max(0,x)$	Dense 중간층, Conv1D	중간층 표준 선택. 소규모 데이터에 안정적. 음수 억제로 피쳐 선명도 향상.
tanh	$(e^x-e^{-x})/(e^x+e^{-x})$	LSTM·GRU 은닉 상태	LSTM/GRU 이론 설계 전제. 제로 중심 출력으로 게이트 학습 안정화.
sigmoid	$1/(1+e^{-x})$	LSTM·GRU 게이트	게이트 열림/닫힘(0~1) 제어 전용. 장기 베어링 패턴 기억에 핵심.
Linear	$f(x)=x$	최종 출력층 Dense(1)	RUL 은 연속 회귀값(0~수천). 활성화 제한 없이 MinMaxScaler 로 역변환.

[표 2] 활성화 함수별 특성 및 선택 배경

CNN 모델 구성 3 대 설계 원칙

이미지 분류 CNN 설계 시 반드시 적용하는 3 가지 핵심 원칙과 소스 반영 여부

설계 원칙	소스 반영	핵심 역할	미적용 시 문제
1. Rescaling(1./255)	YES	픽셀 0~255 -> 0~1 정규화 경사 소실 방지 / 학습 안정화	학습 속도 저하 가중치 불안정
2. 필터 2 배 증가 16->32->64	YES	1 층: 에지/선(저수준) 2 층: 형태(중간) 3 층: 물체(고수준) 단계적 특징 학습	표현력 부족 또는 초반 과다 파라미터
3. Dropout(0.2)	YES	학습 중 20% 뉴런 무작위 OFF 과적합 방지 / 일반화 향상	val accuracy 저하 train-val 격차 증가

결론: 세 가지 모두 소스에 반영 -- Rescaling(정규화) + 필터 2 배 증가(표현력) + Dropout(일반화)는 이미지 CNN 설계의 표준 3 원칙입니다.

학습 모니터링 및 모델 관리 (3 가지 추가 기능)

소스(femto_dl_compare.py)에 추가된 3 기능 요약

기능	설정 핵심	목적	산출물
1. EarlyStopping 콜백	monitor=val_loss patience=7 restore_best_weights=True	검증 손실 개선 없으면 자동 조기 종료 과적합 방지	실행 epoch 단축 최적 가중치 자동 복원
2. 학습 결과 시각화	최적 모델(GRU)만 train/val Loss+MAE 2 개 그래프 (dpi=120)	학습 수렴 확인 과적합 여부 진단	femto_dl_GRU _training_curve.png
3. 모델 저장 + 로드 후 예측	.keras 포맷 저장 load_model() 로드 OOS 200 샘플 시각화	모델 재현성 검증 배포 가능성 확인	femto_best_dl_GRU.keras femto_dl_GRU _oos_prediction.png

EarlyStopping 설정 근거: patience=7 은 학습률 감소 등 일시적 정체를 허용하면서 장기 과적합을 방지. FEMTO 진동 시계열처럼 noise 가 많은 데이터에서 patience<3 은 조기 종료 과다 발생 위험.

※ [콜백 개선] ModelCheckpoint(save_best_only=True, monitor='val_loss', mode='min') 추가.

EarlyStopping(restore_best_weights=True)과 병행 적용: EarlyStopping=메모리 내 최적 가중치 복원,

ModelCheckpoint=val_loss 개선 시 디스크에 즉시 저장(학습 중 크래시 대비). 저장 경로:

models/femto_ckpt_{모델명}.keras

학습 곡선 해석 -- Accuracy & Loss 분석

CNN 분류 모델 학습 후 출력되는 Training/Validation Accuracy & Loss 그래프 해석 기준

단계	구간	핵심 현상	해석
1 단계 (학습 초기)	Epoch 0~4	Val Acc > Train Acc 두 곡선 모두 빠른 상승	정상 Dropout 이 추론 시 꺼져서 Val 이 일시적으로 더 높음
2 단계 (수렴)	Epoch 4~12	Train > Val (역전) Val 등락(zigzag) 발생	정상 수렴 구간 최적 모델은 이 구간 끝
3 단계 (과적합)	Epoch 12~14	Val Loss 상승 반전! Train-Val 격차 확대	과적합 시작 EarlyStopping 없으면 최적 지점 지나침

Validation Accuracy 핵심 체크 포인트 (가장 중요)

체크 항목	판단 기준	예시 그래프 결과
Val Acc 최고점	주황선 최대값 epoch = 최적 모델 저장 시점	Epoch 12~13 (Val Acc ~0.72) EarlyStopping 이 자동 복원
Train-Val 격차	<5%: 정상 / 5~10%: 주의 >10%: 과적합 조치 필요	약 6% (Train 0.77 - Val 0.71) -> 경미한 과적합 수준
Val Loss 반전 (핵심 과적합 신호)	상승 반전 없음: 정상 진행 중 상승 반전 있음: 과적합 시작 반전 전 epoch = 최적 지점	Epoch 12~에서 반전 (0.69 -> 0.83) -> 과적합 확인 완료

핵심 결론: Validation Accuracy(주황선) 최고점을 찾는 것이 목표입니다. Training

Accuracy(파란선)는 항상 높아지지만 실제 성능을 보여주지 않습니다. Val Loss 가 상승 반전하는
시점이 과적합 시작이며, EarlyStopping(monitor='val_loss', patience=7,
restore_best_weights=True)이 이 최적 지점을 자동으로 포착하고 가중치를 보존합니다.

SpatialDropout2D -- CNN 합성곱층 전용 드롭아웃

일반 Dropout 이 개별 픽셀을 끄는 반면, SpatialDropout2D 는 채널(feature map) 전체를 한 번에 드롭합니다. CNN 합성곱 출력의 공간 상관성을 고려한 정규화 기법입니다.

비교	일반 Dropout	SpatialDropout2D
드롭 단위	개별 픽셀	채널(feature map) 전체
권장 위치	Dense 층	Conv2D 층 이후
권장 rate	0.3 ~ 0.5	0.1 ~ 0.2 (낮게)

적용 결과 (Quiz CNN): Conv2D 이후 SpatialDropout2D(0.1), Dense 이후 Dropout(0.3) 조합 적용.
padding='same' 추가로 feature map 크기 유지.

```
layers.Conv2D(32, (3,3), padding='same', activation='relu'),
layers.SpatialDropout2D(0.1),      # 채널 단위 드롭 (Conv 이후)
layers.MaxPooling2D((2, 2)),
layers.Conv2D(64, (3,3), padding='same', activation='relu'),
layers.SpatialDropout2D(0.1),      # 채널 단위 드롭 (Conv 이후)
layers.MaxPooling2D((2, 2)),
layers.Flatten(),
layers.Dense(128, activation='relu'),
layers.Dropout(0.3),               # 일반 드롭아웃 (Dense 이후)
layers.Dense(10, activation='softmax')
```

전처리 보완 — 시계열 Shuffle / Scale / Inverse Transform

1. 시계열 Shuffle 처리 현황

시계열 슬라이딩 윈도우 데이터는 같은 실험 내 윈도우들이 train/test 에 섞이면 평가 지표가 낙관적으로 왜곡됩니다.

소스	적용 방식	평가
Source 2 (합성 시계열)	StratifiedKFold(shuffle=True) — 독립 run 단위	OK: 각 시퀀스가 독립 run
Source 3 (NASA Milling)	train_test_split(shuffle=True, 기본값)	수정됨: shuffle=False 적용, 시계열 순서 보존 (stratify 제거)
FEMTO (본 문서)	GroupKFold(bearing) — 베어링 단위 분리	OK: 시계열 누수 완전 방지

FEMTO 는 GroupKFold(베어링 단위)로 가장 엄밀하게 처리됩니다.

2. 스케일링 — MinMaxScaler 처리 (FEMTO RUL)

RUL 예측은 회귀 문제이므로 입력(X)과 목표값(y) 모두 MinMaxScaler 로 정규화하고, 예측 후 역변환하여 분(min) 단위로 출력합니다.

단계	적용 대상	방법	비고
Train X 스케일	X_tr (N×W×F)	MinMaxScaler().fit_transform()	train 기준 fit
Test X 스케일	X_te (N×W×F)	seq_scaler.transform()	train fit 재사용, 누수 없음
Train y 스케일	y_tr RUL(분)	MinMaxScaler().fit_transform()	0~1 범위 정규화
Test y 스케일	y_te RUL(분)	y_scaler.transform()	train fit 재사용
예측 역변환	y_pred [0,1]	y_scaler.inverse_transform()	분 단위 RUL 복원

분류 모델(Source 2:3)은 sigmoid 출력(0~1 확률) 이므로 역변환 불필요.

3. RUL 예측 시각화 (역변환 후)

아래 그래프는 y_scaler.inverse_transform() 적용 후 분 단위로 복원된 실측값과 예측값 비교입니다.




그림. LSTM RUL 예측 — Actual vs Predicted (분 단위)




그림. 베어링 열화 진행 및 RUL 감소 패턴




그림. LSTM 학습 곡선 (Loss / MAE per epoch)

DL 모델 간 성능 비교 (FEMTO RUL)

모델별 RMSE / MAE (단위: 분)

모델	CV RMSE	OOS RMSE	OOS MAE	비고
LSTM	1091.2	1036.9	846.2	
GRU	1164.8	910.0	741.5	★ 최적
BiLSTM	1301.6	1021.2	805.5	
1D-CNN	1093.2	938.0	754.9	
CNN-LSTM	1168.7	996.6	789.9	

최적 모델 저장 경로

최적 모델: GRU -> models/femto_best_dl_GRU.keras

`model.save('./models/femto_best_dl_GRU.keras')` 로 자동 저장됨

`classExample` 의 `lstm_model.keras` 와 다른 경로/파일명

학습 곡선 (Training vs Validation Loss)



그림. LSTM Training & Validation Loss/MAE (Fold 1 대표)

모델 비교 차트




그림. FEMTO RUL 5 개 DL 모델 성능 비교 (CV RMSE / OOS RMSE / OOS MAE)

시계열 예측 — 슬라이딩 윈도우 입력 텐서 구조

DL 모델은 센서 데이터를 슬라이딩 윈도우로 분할하여 3D 텐서 (배치 크기 × 타임스텝 수 × 특징 수) 형태로 입력받습니다.

항목	Source 1 FEMTO (RUL 회귀)	Source 3 Milling (마모 분류)
배치 크기 (한 번에 처리하는 시퀀스 수)	32	64
타임스텝 수 (시퀀스 내 시점 개수)	30 (30 분 연속 스냅샷, 1 스냅샷=1 분)	512 (~51ms, 10kHz 기준)
특징 수 (매 시점의 변수 수)	9 h_rms, h_kurt, h_skew, h_crest v_rms, v_kurt, v_skew, v_crest, temp_mean	6 smcAC, smcDC, vib_table vib_spindle, AE_table, AE_spindle
입력 텐서 shape	(32, 30, 9)	(64, 512, 6)

※ 타임스텝=과거를 얼마나 참조할지 / 특징=매 시점에서 읽는 센서 채널 수

학습 모델 및 하이퍼파라미터 상세

하이퍼파라미터	Source 1 FEMTO (GRU — RUL 회귀)	Source 3 Milling (1D-CNN — 마모 분류)
사용 모델	GRU (LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5 종 비교 -> OOS RMSE 최소 모델 자동 선정)	멀티채널 1D-CNN (Conv1D 64->128->256, BatchNorm, GAP)
배치 크기	32	64
타임스텝 수 (Window Size)	30 (그리드서치 탐색 범위: 20 / 30 / 50)	512 (고정: 10kHz 원시신호 ~51ms)
은닉 유닛 수 (Units)	64 (그리드서치 탐색 범위: 32 / 64 / 128)	64->128->256 (레이어별 증가형)
드롭아웃	0.2 (탐색 범위: 0.1 / 0.2 / 0.3)	0.3 고정
옵티마이저	Adam (lr=1e-4)	Adam (lr=1e-4)
손실 함수	MSE (회귀)	Binary Cross-Entropy (이진 분류)
최대 에폭	50 (EarlyStopping patience=7)	50 (EarlyStopping patience=20 + ReduceLROnPlateau)
교차검증	GroupKFold (n_splits=3) 베어링 단위 분리 — 시간 누수 차단	Stratified holdout (val=15%)
불균형 처리	없음 (연속값 회귀)	class_weight 역가중치 (마모 클래스 강조)
스케일링	MinMaxScaler (피쳐+타겟 모두 [0,1])	채널별 표준화 (Train mean/std 기준)

배치 크기 결정 근거

선정 과정

배치 크기는 공식 그리드서치 범위에 포함하지 않고, 16 -> 32 -> 64 -> 128 순으로 실험하여 학습 안정성·수렴 속도를 기준으로 결정했습니다.

Source 1 FEMTO — 배치 32 선택

- 16: gradient 노이즈 과다 -> GroupKFold fold 간 수렴 불안정
 - 32: fold 당 업데이트 횟수와 안정성 균형 최적 ★ 최종 선택
 - 64: 소규모 스냅샷 데이터에서 업데이트 횟수 감소 -> 일반화 저하 관찰
 - 128: train 전체 대비 배치 비율 과대 -> 학습 불안정
- 결론: 스냅샷 단위 소규모 데이터 + GroupKFold 구조에서 32 가 최적

Source 3 Milling — 배치 64 선택

- 16: 원시신호 윈도우(512x6)의 메모리 효율 저하, 학습 시간 과다
 - 32: 정상 동작하나 GPU 병렬 처리 효율 미달
 - 64: 메모리 효율·gradient 안정성·학습 속도 균형 최적 ★ 최종 선택
 - 128: class_weight 적용 시 배치 내 마이너 클래스 희소 -> 불균형 학습 불안정
- 결론: 대용량 원시신호(수만 샘플) + class_weight 환경에서 64 가 최적

※ 배치 크기는 GPU 메모리 한도 내에서 2 의 거듭제곱(16/32/64/128) 중 선택이 일반 관행

※ 두 소스 모두 EarlyStopping 적용으로 최대 에폭(50)에 도달 전 조기 종료됩니다

배치 크기 튜닝 실험 결과

배치 크기를 그리드서치에서 제외한 이유

배치 크기를 공식 그리드서치에서 제외한 이유

기존 그리드: $\text{window}(3) \times \text{units}(3) \times \text{dropout}(3) = 27$ 조합

→ GroupKFold(3fold) + 최종학습 = 조합당 4 회 = 총 108 회 학습

배치 크기(4 종) 추가 시: $27 \times 4 = 108$ 조합 $\times$ 4 회 = 432 회 학습 (4 배 증가)

→ 교육 프로젝트 수준에서 시간 대비 효과 낮다고 판단하여 제외

✓ 사후 검증: 본 추가 실험에서 batch=16 이 OOS RMSE 를

956.05 → 810.4 분으로 개선 (향후 그리드 포함 권장)

Source 1 FEMTO GRU — 배치 크기별 실험 결과 (16→32→64→128)

배치 크기	CV RMSE(분)	OOS RMSE(분)	OOS MAE(분)	실행 에폭	기준 대비
16	1065.1	836.6 ★ 최적	666.1	8	-119.4 분
32	1065.5	1002.6	787.8	8	+46.5 분
64	1065.7	1114.4	891.8	8	+158.3 분
128	1066.2	1054.3	833.8	10	+98.3 분

기준값 (배치=32, 기존 설정): OOS RMSE = 956.05 분

최적 배치 = 16 → OOS RMSE = 810.4 분 (-119.4 분 개선, 12.5% 향상)

Source 3 Milling 1D-CNN — 배치 크기별 실험 결과 (32→64→128)

배치 크기	정확도	F1(마모)	ROC-AUC	실행 에폭	비고
32	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
64	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)

128	0.3424	0.0000	0.5000	10	모델 collapse (전부 Normal 예측)
-----	--------	--------	--------	----	----------------------------------

기준값 (배치=64, 임계값=0.75): $F1 = 0.7935$

현재 실험(임계값=0.5)에서 전 배치 크기 $F1=0.0$ — 모델 collapse (Normal 만 예측)

원인: 9~10 에폭 조기 종료로 학습 부족 + 임계값 0.5 에서 마이너 클래스 미탐지

→ 배치 크기 단독 변경으로는 개선 불가, 임계값 조정(0.75) + EarlyStopping 완화 필요

에폭(Epochs) 설정 근거

항목	Source 1 FEMTO (GRU)	Source 3 Milling (1D-CNN)
설정 최대 에폭	50	50
실제 실행 에폭 (EarlyStopping)	8~10 회 (patience=7)	9~10 회 (patience=20)
최대 50 에폭 결정 이유	• 스냅샷 소규모 데이터 → 20~30 에폭 내 수렴 • EarlyStopping 이 실제 종료 제어 • 50 은 안전 상한 (100+ 불필요) • 실험에서 8~10 에폭 조기 종료 확인	• 원시신호 CNN 은 수렴 빠름 • ReduceLROnPlateau 병행으로 조정 • 50 에폭 안에서 수렴 반복 확인 • 실험에서 9~10 에폭 조기 종료 확인
patience 설정 이유	patience=7 • 5 미만: 조기종료 과잉 (지역최솟값 오탐) • 7: val_loss 연속 7 회 미개선 시 종료 • 10+: 수렴 후 불필요한 학습 낭비	patience=20 • Milling 노이즈 커 수렴 지연 • 7 보다 1 회 여유 추가 • ReduceLROnPlateau(patience=4) 병행

※ 실제 실행 에폭(8~10 회) 이 최대(50)에 훨씬 못 미치는 이유:

소규모 데이터 + EarlyStopping 조합 → 빠른 수렴 후 조기 종료

※ EarlyStopping restore_best_weights=True → 조기 종료 시 최적 가중치 자동 복원

필터 수 튜닝 결과

Milling 1D-CNN — 필터 수 별 실험 결과

설정	필터 구성	파라미터 수	정확도	F1(마모)	ROC-AUC	에폭	비고
대형 128→256→512	128→256→512	630,913	0.3424	0.0000	0.5000	10	collapse (Normal 만 예측)
소형 32→64→128	32→64→128	53,473	0.3424	0.0000	0.5000	9	★ 최소 파라미터 collapse
기본 64→128→256	64→128→256	176,321	0.3424	0.0000	0.5000	9	collapse (Normal 만 예측)

기준값 (필터 64→128→256, 임계값=0.75): F1 = 0.7935

실험 조건 (임계값=0.5): 모든 설정에서 F1=0.0 — 모델 collapse

원인: 임계값 0.5 에서 마이너 클래스 미탐지 (원본 모델은 0.75 사용)

→ 필터 수 단독 변경으로는 개선 불가, 임계값 0.75 + EarlyStopping 완화 필요

→ 파라미터 기준으로는 소형(32→64→128, 53,473 개) 이 경량화에 유리

FEMTO 모델에서의 필터 수 처리

FEMTO 비교(femto_dl_compare.py) 에서 1D-CNN/CNN-LSTM 의 필터 수는

units 파라미터(그리드서치 범위: 32/64/128)로 연동 제어됨.

최적 모델(GRU, units=64)은 필터 대신 은닉 유닛을 사용하므로

FEMTO '필터 수 튜닝'은 유닛 수 그리드서치로 이미 수행됨.

권장 튜닝 순서

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
1 순위 (필수)	모델 아키텍처 비교	FEMTO / Milling	• FEMTO: LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5 종 비교 • Milling: 1D-CNN 단일 → Bi-LSTM/Transformer 확장 가능 → 아키텍처 오선택은 다른 HP 조정으로 보완 불가
2 순위 (높음)	에폭 / EarlyStopping patience	두 소스 공통	실제 수렴 에폭(8~10) 확인 후 patience 조정 • 너무 작으면 과소학습 / 너무 크면 과적합 → val_loss 곡선 보며 5~10 범위 결정
3 순위 (높음)	학습률 (Learning Rate)	두 소스 공통	현재 Adam lr=1e-4 고정 ReduceLROnPlateau 로 자동 감소 중 (factor=0.5, patience=4) → 1e-3→1e-4 범위 그리드서치 추가 권장
4 순위 (중간)	윈도우/시퀀스 길이	FEMTO	그리드서치 완료 (20/30/50) → 최적 window=20 → 10/15/20 세부 탐색으로 추가 최적화 가능
5 순위 (중간)	유닛/필터 수	두 소스 공통	그리드서치 완료 (32/64/128) → 최적 units=32 Milling 필터: 64→128→256(고정) →

			32→64→128 축소 검토 → 파라미터 줄이면서 성능 유지 여부 확인
6 순위 (중간)	드롭아웃 (Dropout)	두 소스 공통	그리드서치 완료 (0.1/0.2/0.3) → 최적 0.1 Milling dropout=0.3 고정 → 0.2/0.4 탐색 가능 → 과적합 정도 보며 0.1~0.4 범위 조정
7 순위 (낮음)	배치 크기 (Batch Size)	두 소스 공통	추가 실험: FEMTO batch=16 → OOS RMSE 956→837 (12.5%↑) Milling: 임계값=0.5 조건에서 모든 배치 크기 collapse → 임계값(0.75) 복원 후 배치 크기 재탐색 권장
8 순위 (선택)	필터 수 세부 조정	Milling	소형(32→64→128): 파라미터 53K / 현재(64→128→256): 176K 임계값=0.5 조건에서 차이 없음 (모두 collapse) → 임계값 문제 해결 후 경량화 목적으로 소형 필터 검토
보완 (옵션)	분류 임계값 (Threshold)	Milling	현재: 0.75 (기존 모델) / 실험: 0.5 (collapse 원인) → 0.5~0.8 범위 탐색, Precision-Recall 곡선 기반 최적화

※1~3 순위를 먼저 안정화한 뒤 4~8 순위를 순차 적용하는 것을 권장합니다.

※Milling 에서는 임계값 복원(0.75) 이 다른 HP 조정보다 우선합니다.

부록 A — 권장 튜닝 순서 요약

모델 성능 개선 시 아래 순서대로 적용할 것을 권장합니다.

- ① 모델 아키텍처 비교 (가장 큰 임팩트)
 - ② 에폭 수 + EarlyStopping patience 조정
 - ③ 학습률(Learning Rate) 탐색 (ReduceLROnPlateau 병행)
 - ④ 윈도우/시퀀스 길이 그리드서치
 - ⑤ 유닛/필터 수 그리드서치
 - ⑥ 드롭아웃 비율 조정
 - ⑦ 배치 크기 탐색 (그리드서치 통합 권장)
 - ⑧ 필터 수 세부 조정 (경량화 목적)
- ⊕ 분류 모델: 임계값(Threshold) 최적화 — Precision-Recall 곡선 기반

DL_FactoryAutomation 적용 결과:

- FEMTO GRU OOS RMSE: 기준 956.05 분 → 배치=16 → 810.4 분 (12.5%↓)
- Milling 1D-CNN: 임계값=0.75 복원이 최우선 과제

Streamlit 앱 기능 목록

앱 파일	탭/메뉴	기능 설명	카테고리	회귀/분류	사용 모델	사용 데이터
streamlit_unified.py	Tab 1 ML 진단	설비 파라미터 입력 → 고장 확률 예측	ML	분류(이진)	XGBoost	AI4I 정형(10K 행 설비유형/rpm/ 토크/ 공구마모/온도)
streamlit_unified.py	Tab 2 DL 시계열	50 스텝 열화 시계열 → 고장 탐지	DL	분류(이진)	CNN + LSTM	합성 시계열 (50 타임스텝)
streamlit_unified.py	Tab 3 DL 원시신호	공구 원시신호 → 마모 판정	DL	분류(이진)	1D- CNN(멀티채널)	NASA Milling (512×6 원시신호)
streamlit_unified.py	Tab 4 통합 비교	ML vs DL 성능 비교 대시보드	ML+DL	비교 대시보드	XGBoost / CNN+LSTM / 1D-CNN	3 개 소스 통합
streamlit_app.py	단건 시뮬레이션	파라미터 입력 → 시퀀스 생성 → 예측	DL	분류(이진)	CNN + LSTM	합성 시뮬레이션
streamlit_app.py	데모 CSV 일괄 예측	demo CSV 업로드 → 배치 예측 및 시각화	DL	분류(이진)	CNN + LSTM	합성 시계열 (demo CSV)
streamlit_femto.py	ML 열화 분류	베어링 센서값 → 열화 단계 판정	ML	분류(다중)	Random Forest / Gradient Boosting	FEMTO-ST 베어링 (진동+온도 피쳐)
streamlit_femto.py	DL RUL 예측	슬라이딩 윈도우 → 잔여수명(RUL) 예측	DL	회귀	GRU / LSTM (window=20, units=32)	FEMTO-ST 베어링 (FEMTO_processed)
streamlit_rag.py	RAG	센서 측정값	LLM(RAG)	검색 +	FAISS 벡터	FEMTO-ST 이력

	유사 사례 검색	→ FAISS 코사인 유사도 검색 → Top-K 사례 + RUL 추정		회귀	검색 (12 차원 피쳐)	(베어링 전체 수명)
--	----------------	---	--	----	---------------------	----------------

※ ML 기능: XGBoost(Tab1 분류), RF/GBM(FEMTO 분류) — 정형 데이터 기반

※ DL 기능: CNN+LSTM(시계열 분류), 1D-CNN(원시신호 분류), GRU/LSTM(RUL 회귀)

※ LLM/RAG: FAISS 벡터 검색 기반 유사 사례 검색 — 비정형 이력 활용

※ 회귀 기능: FEMTO DL RUL 예측(분 단위), RAG RUL 추정/ 그 외: 이진·다중 분류

OOS RMSE 각주

【OOS RMSE 각주】

- OOS(Out-Of-Sample): 학습에 미사용된 테스트셋으로 측정한 RMSE → 모델 일반화 성능 지표
↔ In-Sample RMSE(학습셋)와 대비; 실무 모델 선정 기준은 OOS 우선
- 단위: 분(min). 810.4 분 ≈ 'RUL 예측이 실제와 평균 ~836 분 차이' (제공평균 → 큰 오차 가중)
- 작을수록 우수. OOS >> In-Sample 이면 과적합 신호
- 기준선 956 분: 그리드서치 챔피언(window=20, units=32, dropout=0.1)의 고정 참조값
≠ batch=32 재실험값(1002.6 분). 동일 설정도 시드·초기화 변동으로 실행마다 결과 상이
→ 표의 '기준(batch=32)'과 '기준(956 분)'은 별개 개념; 혼동 방지 주석

Milling 분류 모델 비교

임계값 0.75 조건에서 3 개 모델 모두 동일 붕괴(F1=0.0) — 9 에폭 조기종료 시 P(마모)≈0.66 수렴, 임계값 미달로 전부 0 예측.

모델	비고	파라미터	ACC	F1	AUC	에폭
1D-CNN(멀티채널)	기준 기준	176,321	0.3424	0.0000	0.5000	9
MLP(Flatten→Dense)	신규 비교	1,722,753	0.3424	0.0000	0.5000	9
BiLSTM(Conv 다운샘플→Bi-LSTM)	신규 비교	59,617	0.3424	0.0000	0.5000	9

※ [아키텍처 개선] LayerNormalization(RNN 이후) + BatchNormalization(Dense 전) + Dropout 강화 추가 →

GRU_v2(BN+LN) OOS RMSE 810.4 분 (MAE 665.6 분, 기준 대비 +16.8% 개선, 수렴 에폭 54→33 단축). RNN 계층엔

LayerNorm(배치 통계 불안정 회피), Dense 앞엔 BatchNorm 적용. Dense 뉴런 수 16→32, Dense 후 Dropout 추가로 과적합 억제.