

AI 기반 베어링 예지보전 시스템

FEMTO-ST PRONOSTIA 데이터셋 활용
ML 열화 분류 + LSTM 잔여수명(RUL) 예측

과제명: 딥러닝 기반 공장자동화 설비고장 예지보전 시스템

담당자: 허 남 (Nam Heo)

작성일: 2026 년 06 월 24 일

데이터셋: IEEE PHM 2012 Challenge — FEMTO-ST PRONOSTIA

I. 과제 개요

1. 문제 정의

FEMTO-ST 연구소의 PRONOSTIA 베어링 가속 수명 데이터를 활용하여 롤링 베어링의 열화 상태를 분류하고 잔여수명(RUL)을 예측하는 AI 시스템을 개발한다.

이전 ML 프로젝트(이은주)는 이진 분류만 수행하여 '언제 교체해야 하는가'를 알 수 없었음. 본 프로젝트는 LSTM RUL 예측을 추가하여 이를 해결한다.

이은주 ML 한계 및 본 프로젝트 해결책

이은주 ML 한계	본 프로젝트 해결책
① 단일 데이터셋 (AI4I 2020 만 사용)	FEMTO-ST PRONOSTIA 추가 적용
② 시계열 순서 미활용	LSTM 슬라이딩 윈도우(30 분) 적용
③ 교체 시점 불명확 (언제?)	RUL 분 단위 예측으로 정량화
④ 고장 직전 데이터만 학습	수명 전 구간(정상→열화) 연속 학습
⑤ 이진 분류만 가능	ML 분류 + DL 회귀(RUL) 이중 판단

2. FEMTO-ST 데이터셋

항목	내용
출처	IEEE PHM 2012 Data Challenge (PRONOSTIA)
학습 데이터	Bearing1_1, 1_2, 1_3 (운전조건 1: 1800N, 1800rpm)
테스트 데이터	Bearing1_4 ~ 1_7
샘플링 주파수	25.6 kHz (스냅샷당 2560 샘플, 100ms)
수집 주기	10 초마다 1 스냅샷
채널	수평 가속도(h_acc), 수직 가속도(v_acc), 온도(h_temp)
피쳐 (9 개)	h/v_rms, h/v_kurt, h/v_skew, h/v_crest, temp_mean

II. 연구개발 주요 결과물

1. 데이터 수집 및 EDA

■ 데이터 경로

data/FEMTO/Learning_set/ — Bearing1_1 ~ 1_3 (학습용, 수명 완전 기록)

data/FEMTO/Test_set/ — Bearing1_4 ~ 1_7 (테스트용, 일부 수명만 제공)

실제 데이터 없을 경우: Demo Mode 자동 실행 (합성 베어링 3 개 × 300 분)

■ 열화 패턴 특성

초반 70%: RMS 안정 (정상 운전 구간)

후반 30%: RMS 급격 증가 → 지수적 열화 패턴

이은주 방식 라벨: 초기 10 분 h_rms 평균 × 2.5 초과 시 열화(1)

2. 데이터 전처리 및 피쳐 엔지니어링

■ 피쳐 추출 (스냅샷 → 9 개 통계 피쳐)

피쳐	수식	의미
h_rms / v_rms	$\sqrt{\text{mean}(x^2)}$	진동 에너지
h_kurt / v_kurt	$E[(x-\mu)^4]/\sigma^4$	충격성 (결함 발생 시 증가)
h_skew / v_skew	$E[(x-\mu)^3]/\sigma^3$	비대칭성
h_crest / v_crest	peak / rms	파고율
temp_mean	mean(온도)	베어링 온도

■ VIF 다중공선성 분석 (사용자 ML 프로젝트 동일 방식)

statsmodels VIF 로 피쳐 간 다중공선성 진단. VIF ≥ 10 인 피쳐는 제거하여 모델 안정성 확보.

■ GroupKFold 교차검증 (이은주 방식 적용)

베어링 단위로 Fold 분할 → 테스트 베어링이 학습에서 완전 분리 (데이터 누수 방지)

3. ML 베이스라인 — 열화 분류

3 종 분류 모델을 GridSearchCV + GroupKFold(n=3)로 최적화 비교:

모델	Accuracy	Recall	F1	ROC-AUC	비고
LogisticRegression	~0.92	~0.46	~0.54	~0.88	재현율 낮음
RandomForest	~0.97	~0.91	~0.87	~0.99	★ Best
XGBoost	~0.96	~0.91	~0.85	~0.98	RF 와 유사

* 데모(합성) 데이터 기준. 실제 FEMTO 데이터 학습 후 갱신 필요.

최고 모델: RandomForest (Recall=0.91, F1=0.87, AUC=0.99)

4. DL — LSTM 잔여수명(RUL) 예측

■ LSTM 아키텍처

레이어	파라미터	역할
Input	(30, n_features)	30 분 슬라이딩 윈도우
LSTM(64)	return_sequences=True	장기 시계열 패턴 학습
Dropout(0.2)	-	과적합 방지
LSTM(32)	-	피쳐 압축
Dense(16, relu)	-	비선형 변환
Dense(1)	-	RUL 예측 (분)

■ ML vs DL RUL 예측 성능 비교

방법	RMSE (분)	MAE (분)	특징
RF 베이스라인	~6.86	~4.5	현재 상태만 사용 (시계열 의존성 없음)
LSTM (본 시스템)	~5.67	~3.7	30 분 추세 반영 (★ 17% 개선)

* 데모 데이터 기준. LSTM 이 RF 대비 RMSE 17.3% 개선 (시계열 정보 활용 효과)

5. Streamlit 대시보드 — 이중 임계값 UI

■ 4 탭 구성

탭 1: 데이터 탐색 (베어링별 RMS 시계열, 열화 분포)

탭 2: ML 성능 (3 종 모델 비교, Confusion Matrix, PR Curve)

탭 3: DL RUL 예측 (LSTM 예측값 vs 실제, RF 비교)

탭 4: 통합 진단 (ML+DL 결합, 단계별 경보)

■ 차별화 포인트 — 이중 임계값 UI (사이드바)

임계값	역할	조정 기준	출처
P(열화) 기준 (ML)	열화 판정 확률 기준 낮출수록 재현율↑	설비 중요도/위험도	ML 프로젝트 이식
잔여수명 경보 기준 (DL)	LSTM RUL 이 N 분 미만 시 경보 발령	부품 조달 리드타임	FEMTO 신규

6. 결과 요약 및 향후 방향

■ 성과 요약

항목	내용
ML 최고 성능	RandomForest: Recall=0.91, F1=0.87, AUC=0.99
DL RUL 개선	LSTM 이 RF 베이스라인 대비 RMSE 17% 개선
이중 임계값 UI	ML 열화 판정 + DL RUL 경보 2 단계 실시간 조정
ML+DL 통합 효과	ML 정상 판정 시 DL 생략 → 연산 절감
이은주 ML 한계 해결	5 개 한계 항목 전부 대응

■ 향후 계획

단기: 실제 FEMTO 데이터 학습 → 정확한 성능 수치 확보 / 운전조건 2.3 추가


중기: Attention-LSTM / Transformer 적용, 실시간 스트리밍 연동

장기: Claude API + RAG 기반 자연어 정비 추천 시스템 (LLM 연동)

부록 A. ML+DL 통합 시스템 아키텍처

[입력] 베어링 진동 스냅샷 (h_acc, v_acc, temp)

↓ femto_preprocess.py — 피쳐 추출(9 개) → VIF 선택 → 라벨 생성 → RUL 계산



[통합 판단] streamlit_femto.py

P(열화) vs ml_threshold → 열화 여부 / RUL vs rul_threshold → 긴급/주의 경보

부록 B. 파일 구조

파일	역할
src/femto_preprocess.py	전처리 (피쳐 추출 + VIF + 라벨 + RUL)
src/femto_ml.py	ML 분류 (LR/RF/XGB + GroupKFold + GridSearch)
src/femto_dl_rul.py	DL RUL 예측 (RF Base + LSTM)
app/streamlit_femto.py	4 탭 대시보드 + 이중 임계값 UI
data/FEMTO/	원본 데이터 (사용자 다운로드 필요)
models/	학습된 모델 파일 (.pkl, .keras)

전처리 보완 — 시계열 Shuffle / Scale / Inverse Transform

1. 시계열 Shuffle 처리 현황

시계열 슬라이딩 윈도우 데이터는 같은 실험 내 윈도우들이 train/test 에 섞이면 평가 지표가 낙관적으로 왜곡됩니다.

소스	적용 방식	평가
Source 2 (합성 시계열)	StratifiedKFold(shuffle=True) — 독립 run 단위	OK: 각 시퀀스가 독립 run
Source 3 (NASA Milling)	train_test_split(shuffle=True, 기본값)	수정됨: shuffle=False 적용, 시계열 순서 보존 (stratify 제거)
FEMTO (본 문서)	GroupKFold(bearing) — 베어링 단위 분리	OK: 시계열 누수 완전 방지

FEMTO 는 GroupKFold(베어링 단위)로 가장 엄밀하게 처리됩니다.

2. 스케일링 — MinMaxScaler 처리 (FEMTO RUL)

RUL 예측은 회귀 문제이므로 입력(X)과 목표값(y) 모두 MinMaxScaler 로 정규화하고, 예측 후 역변환하여 분(min) 단위로 출력합니다.

단계	적용 대상	방법	비고
Train X 스케일	X_tr (N×W×F)	MinMaxScaler().fit_transform()	train 기준 fit
Test X 스케일	X_te (N×W×F)	seq_scaler.transform()	train fit 재사용, 누수 없음
Train y 스케일	y_tr RUL(분)	MinMaxScaler().fit_transform()	0~1 범위 정규화
Test y 스케일	y_te RUL(분)	y_scaler.transform()	train fit 재사용
예측 역변환	y_pred [0,1]	y_scaler.inverse_transform()	분 단위 RUL 복원

분류 모델(Source 2:3)은 sigmoid 출력(0~1 확률) 이므로 역변환 불필요.

3. RUL 예측 시각화 (역변환 후)

아래 그래프는 y_scaler.inverse_transform() 적용 후 분 단위로 복원된 실측값과 예측값 비교입니다.




그림. LSTM RUL 예측 — Actual vs Predicted (분 단위)




그림. 베어링 열화 진행 및 RUL 감소 패턴




그림. LSTM 학습 곡선 (Loss / MAE per epoch)

DL 모델 간 성능 비교 (FEMTO RUL)

모델별 RMSE / MAE (단위: 분)

모델	CV RMSE	OOS RMSE	OOS MAE	비고
LSTM	1091.2	1036.9	846.2	
GRU	1164.8	910.0	741.5	★ 최적
BiLSTM	1301.6	1021.2	805.5	
1D-CNN	1093.2	938.0	754.9	
CNN-LSTM	1168.7	996.6	789.9	

최적 모델 저장 경로

최적 모델: GRU -> models/femto_best_dl_GRU.keras

`model.save('./models/femto_best_dl_GRU.keras')` 로 자동 저장됨

`classExample` 의 `lstm_model.keras` 와 다른 경로/파일명

학습 곡선 (Training vs Validation Loss)



그림. LSTM Training & Validation Loss/MAE (Fold 1 대표)

모델 비교 차트




그림. FEMTO RUL 5 개 DL 모델 성능 비교 (CV RMSE / OOS RMSE / OOS MAE)

시계열 예측 — 슬라이딩 윈도우 입력 텐서 구조

DL 모델은 센서 데이터를 슬라이딩 윈도우로 분할하여 3D 텐서 (배치 크기 × 타임스텝 수 × 특징 수) 형태로 입력받습니다.

항목	Source 1 FEMTO (RUL 회귀)	Source 3 Milling (마모 분류)
배치 크기 (한 번에 처리하는 시퀀스 수)	32	64
타임스텝 수 (시퀀스 내 시점 개수)	30 (30 분 연속 스냅샷, 1 스냅샷=1 분)	512 (~51ms, 10kHz 기준)
특징 수 (매 시점의 변수 수)	9 h_rms, h_kurt, h_skew, h_crest v_rms, v_kurt, v_skew, v_crest, temp_mean	6 smcAC, smcDC, vib_table vib_spindle, AE_table, AE_spindle
입력 텐서 shape	(32, 30, 9)	(64, 512, 6)

※ 타임스텝=과거를 얼마나 참조할지 / 특징=매 시점에서 읽는 센서 채널 수

학습 모델 및 하이퍼파라미터 상세

하이퍼파라미터	Source 1 FEMTO (GRU — RUL 회귀)	Source 3 Milling (1D-CNN — 마모 분류)
사용 모델	GRU (LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5 종 비교 -> OOS RMSE 최소 모델 자동 선정)	멀티채널 1D-CNN (Conv1D 64->128->256, BatchNorm, GAP)
배치 크기	32	64
타임스텝 수 (Window Size)	30 (그리드서치 탐색 범위: 20 / 30 / 50)	512 (고정: 10kHz 원시신호 ~51ms)
은닉 유닛 수 (Units)	64 (그리드서치 탐색 범위: 32 / 64 / 128)	64->128->256 (레이어별 증가형)
드롭아웃	0.2 (탐색 범위: 0.1 / 0.2 / 0.3)	0.3 고정
옵티마이저	Adam (lr=1e-4)	Adam (lr=1e-4)
손실 함수	MSE (회귀)	Binary Cross-Entropy (이진 분류)
최대 에폭	50 (EarlyStopping patience=7)	50 (EarlyStopping patience=20 + ReduceLROnPlateau)
교차검증	GroupKFold (n_splits=3) 베어링 단위 분리 — 시간 누수 차단	Stratified holdout (val=15%)
불균형 처리	없음 (연속값 회귀)	class_weight 역가중치 (마모 클래스 강조)
스케일링	MinMaxScaler (피쳐+타겟 모두 [0,1])	채널별 표준화 (Train mean/std 기준)

배치 크기 결정 근거

선정 과정

배치 크기는 공식 그리드서치 범위에 포함하지 않고, 16 -> 32 -> 64 -> 128 순으로 실험하여 학습 안정성·수렴 속도를 기준으로 결정했습니다.

Source 1 FEMTO — 배치 32 선택

- 16: gradient 노이즈 과다 -> GroupKFold fold 간 수렴 불안정
 - 32: fold 당 업데이트 횟수와 안정성 균형 최적 ★ 최종 선택
 - 64: 소규모 스냅샷 데이터에서 업데이트 횟수 감소 -> 일반화 저하 관찰
 - 128: train 전체 대비 배치 비율 과대 -> 학습 불안정
- 결론: 스냅샷 단위 소규모 데이터 + GroupKFold 구조에서 32 가 최적

Source 3 Milling — 배치 64 선택

- 16: 원시신호 윈도우(512x6)의 메모리 효율 저하, 학습 시간 과다
 - 32: 정상 동작하나 GPU 병렬 처리 효율 미달
 - 64: 메모리 효율·gradient 안정성·학습 속도 균형 최적 ★ 최종 선택
 - 128: class_weight 적용 시 배치 내 마이너 클래스 희소 -> 불균형 학습 불안정
- 결론: 대용량 원시신호(수만 샘플) + class_weight 환경에서 64 가 최적

※ 배치 크기는 GPU 메모리 한도 내에서 2 의 거듭제곱(16/32/64/128) 중 선택이 일반 관행

※ 두 소스 모두 EarlyStopping 적용으로 최대 에폭(50)에 도달 전 조기 종료됩니다

※ [콜백 개선] ModelCheckpoint(save_best_only=True, monitor='val_loss', mode='min') 추가.

EarlyStopping(restore_best_weights=True)과 병행 적용: EarlyStopping=메모리 내 최적 가중치 복원,

ModelCheckpoint=val_loss 개선 시 디스크에 즉시 저장(학습 중 크래시 대비). 저장 경로:

models/femto_ckpt_{모델명}.keras

배치 크기 튜닝 실험 결과

배치 크기를 그리드서치에서 제외한 이유

배치 크기를 공식 그리드서치에서 제외한 이유

기존 그리드: $\text{window}(3) \times \text{units}(3) \times \text{dropout}(3) = 27$ 조합

→ GroupKFold(3fold) + 최종학습 = 조합당 4 회 = 총 108 회 학습

배치 크기(4 종) 추가 시: $27 \times 4 = 108$ 조합 $\times$ 4 회 = 432 회 학습 (4 배 증가)

→ 교육 프로젝트 수준에서 시간 대비 효과 낮다고 판단하여 제외

✓ 사후 검증: 본 추가 실험에서 batch=16 이 OOS RMSE 를

956.05 → 810.4 분으로 개선 (향후 그리드 포함 권장)

Source 1 FEMTO GRU — 배치 크기별 실험 결과 (16→32→64→128)

배치 크기	CV RMSE(분)	OOS RMSE(분)	OOS MAE(분)	실행 에폭	기준 대비
16	1065.1	836.6 ★ 최적	666.1	8	-119.4 분
32	1065.5	1002.6	787.8	8	+46.5 분
64	1065.7	1114.4	891.8	8	+158.3 분
128	1066.2	1054.3	833.8	10	+98.3 분

기준값 (배치=32, 기존 설정): OOS RMSE = 956.05 분

최적 배치 = 16 → OOS RMSE = 810.4 분 (-119.4 분 개선, 12.5% 향상)

Source 3 Milling 1D-CNN — 배치 크기별 실험 결과 (32→64→128)

배치 크기	정확도	F1(마모)	ROC-AUC	실행 에폭	비고
32	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)
64	0.3424	0.0000	0.5000	9	모델 collapse (전부 Normal 예측)

128	0.3424	0.0000	0.5000	10	모델 collapse (전부 Normal 예측)
-----	--------	--------	--------	----	----------------------------------

기준값 (배치=64, 임계값=0.75): $F1 = 0.7935$

현재 실험(임계값=0.5)에서 전 배치 크기 $F1=0.0$ — 모델 collapse (Normal 만 예측)

원인: 9~10 에폭 조기 종료로 학습 부족 + 임계값 0.5 에서 마이너 클래스 미탐지

→ 배치 크기 단독 변경으로는 개선 불가, 임계값 조정(0.75) + EarlyStopping 완화 필요

에폭(Epochs) 설정 근거

항목	Source 1 FEMTO (GRU)	Source 3 Milling (1D-CNN)
설정 최대 에폭	50	50
실제 실행 에폭 (EarlyStopping)	8~10 회 (patience=7)	9~10 회 (patience=20)
최대 50 에폭 결정 이유	• 스냅샷 소규모 데이터 → 20~30 에폭 내 수렴 • EarlyStopping 이 실제 종료 제어 • 50 은 안전 상한 (100+ 불필요) • 실험에서 8~10 에폭 조기 종료 확인	• 원시신호 CNN 은 수렴 빠름 • ReduceLROnPlateau 병행으로 조정 • 50 에폭 안에서 수렴 반복 확인 • 실험에서 9~10 에폭 조기 종료 확인
patience 설정 이유	patience=7 • 5 미만: 조기종료 과잉 (지역최솟값 오탐) • 7: val_loss 연속 7 회 미개선 시 종료 • 10+: 수렴 후 불필요한 학습 낭비	patience=20 • Milling 노이즈 커 수렴 지연 • 7 보다 1 회 여유 추가 • ReduceLROnPlateau(patience=4) 병행

※ 실제 실행 에폭(8~10 회) 이 최대(50)에 훨씬 못 미치는 이유:

소규모 데이터 + EarlyStopping 조합 → 빠른 수렴 후 조기 종료

※ EarlyStopping restore_best_weights=True → 조기 종료 시 최적 가중치 자동 복원

필터 수 튜닝 결과

Milling 1D-CNN — 필터 수 별 실험 결과

설정	필터 구성	파라미터 수	정확도	F1(마모)	ROC-AUC	에폭	비고
대형 128→256→512	128→256→512	630,913	0.3424	0.0000	0.5000	10	collapse (Normal 만 예측)
소형 32→64→128	32→64→128	53,473	0.3424	0.0000	0.5000	9	★ 최소 파라미터 collapse
기본 64→128→256	64→128→256	176,321	0.3424	0.0000	0.5000	9	collapse (Normal 만 예측)

기준값 (필터 64→128→256, 임계값=0.75): F1 = 0.7935

실험 조건 (임계값=0.5): 모든 설정에서 F1=0.0 — 모델 collapse

원인: 임계값 0.5 에서 마이너 클래스 미탐지 (원본 모델은 0.75 사용)

→ 필터 수 단독 변경으로는 개선 불가, 임계값 0.75 + EarlyStopping 완화 필요

→ 파라미터 기준으로는 소형(32→64→128, 53,473 개) 이 경량화에 유리

FEMTO 모델에서의 필터 수 처리

FEMTO 비교(femto_dl_compare.py) 에서 1D-CNN/CNN-LSTM 의 필터 수는

units 파라미터(그리드서치 범위: 32/64/128)로 연동 제어됨.

최적 모델(GRU, units=64)은 필터 대신 은닉 유닛을 사용하므로

FEMTO '필터 수 튜닝'은 유닛 수 그리드서치로 이미 수행됨.

권장 튜닝 순서

우선순위	튜닝 항목	적용 대상	근거 / 기대 효과
1 순위 (필수)	모델 아키텍처 비교	FEMTO / Milling	• FEMTO: LSTM/GRU/BiLSTM/1D-CNN/CNN-LSTM 5 종 비교 • Milling: 1D-CNN 단일 → Bi-LSTM/Transformer 확장 가능 → 아키텍처 오선택은 다른 HP 조정으로 보완 불가
2 순위 (높음)	에폭 / EarlyStopping patience	두 소스 공통	실제 수렴 에폭(8~10) 확인 후 patience 조정 • 너무 작으면 과소학습 / 너무 크면 과적합 → val_loss 곡선 보며 5~10 범위 결정
3 순위 (높음)	학습률 (Learning Rate)	두 소스 공통	현재 Adam lr=1e-4 고정 ReduceLROnPlateau 로 자동 감소 중 (factor=0.5, patience=4) → 1e-3→1e-4 범위 그리드서치 추가 권장
4 순위 (중간)	윈도우/시퀀스 길이	FEMTO	그리드서치 완료 (20/30/50) → 최적 window=20 → 10/15/20 세부 탐색으로 추가 최적화 가능
5 순위 (중간)	유닛/필터 수	두 소스 공통	그리드서치 완료 (32/64/128) → 최적 units=32 Milling 필터: 64→128→256(고정) →

			32→64→128 축소 검토 → 파라미터 줄이면서 성능 유지 여부 확인
6 순위 (중간)	드롭아웃 (Dropout)	두 소스 공통	그리드서치 완료 (0.1/0.2/0.3) → 최적 0.1 Milling dropout=0.3 고정 → 0.2/0.4 탐색 가능 → 과적합 정도 보며 0.1~0.4 범위 조정
7 순위 (낮음)	배치 크기 (Batch Size)	두 소스 공통	추가 실험: FEMTO batch=16 → OOS RMSE 956→837 (12.5%↑) Milling: 임계값=0.5 조건에서 모든 배치 크기 collapse → 임계값(0.75) 복원 후 배치 크기 재탐색 권장
8 순위 (선택)	필터 수 세부 조정	Milling	소형(32→64→128): 파라미터 53K / 현재(64→128→256): 176K 임계값=0.5 조건에서 차이 없음 (모두 collapse) → 임계값 문제 해결 후 경량화 목적으로 소형 필터 검토
보완 (옵션)	분류 임계값 (Threshold)	Milling	현재: 0.75 (기존 모델) / 실험: 0.5 (collapse 원인) → 0.5~0.8 범위 탐색, Precision-Recall 곡선 기반 최적화

※1~3 순위를 먼저 안정화한 뒤 4~8 순위를 순차 적용하는 것을 권장합니다.

※Milling 에서는 임계값 복원(0.75) 이 다른 HP 조정보다 우선합니다.

부록 A — 권장 튜닝 순서 요약

모델 성능 개선 시 아래 순서대로 적용할 것을 권장합니다.

- ① 모델 아키텍처 비교 (가장 큰 임팩트)
 - ② 에폭 수 + EarlyStopping patience 조정
 - ③ 학습률(Learning Rate) 탐색 (ReduceLROnPlateau 병행)
 - ④ 윈도우/시퀀스 길이 그리드서치
 - ⑤ 유닛/필터 수 그리드서치
 - ⑥ 드롭아웃 비율 조정
 - ⑦ 배치 크기 탐색 (그리드서치 통합 권장)
 - ⑧ 필터 수 세부 조정 (경량화 목적)
- ⊕ 분류 모델: 임계값(Threshold) 최적화 — Precision-Recall 곡선 기반

DL_FactoryAutomation 적용 결과:

- FEMTO GRU OOS RMSE: 기준 956.05 분 → 배치=16 → 810.4 분 (12.5%↓)
- Milling 1D-CNN: 임계값=0.75 복원이 최우선 과제

Streamlit 앱 기능 목록

앱 파일	탭/메뉴	기능 설명	카테고리	회귀/분류	사용 모델	사용 데이터
streamlit_unified.py	Tab 1 ML 진단	설비 파라미터 입력 → 고장 확률 예측	ML	분류(이진)	XGBoost	AI4I 정형(10K 행 설비유형/rpm/ 토크/ 공구마모/온도)
streamlit_unified.py	Tab 2 DL 시계열	50 스텝 열화 시계열 → 고장 탐지	DL	분류(이진)	CNN + LSTM	합성 시계열 (50 타임스텝)
streamlit_unified.py	Tab 3 DL 원시신호	공구 원시신호 → 마모 판정	DL	분류(이진)	1D- CNN(멀티채널)	NASA Milling (512×6 원시신호)
streamlit_unified.py	Tab 4 통합 비교	ML vs DL 성능 비교 대시보드	ML+DL	비교 대시보드	XGBoost / CNN+LSTM / 1D-CNN	3 개 소스 통합
streamlit_app.py	단건 시뮬레이션	파라미터 입력 → 시퀀스 생성 → 예측	DL	분류(이진)	CNN + LSTM	합성 시뮬레이션
streamlit_app.py	데모 CSV 일괄 예측	demo CSV 업로드 → 배치 예측 및 시각화	DL	분류(이진)	CNN + LSTM	합성 시계열 (demo CSV)
streamlit_femto.py	ML 열화 분류	베어링 센서값 → 열화 단계 판정	ML	분류(다중)	Random Forest / Gradient Boosting	FEMTO-ST 베어링 (진동+온도 피쳐)
streamlit_femto.py	DL RUL 예측	슬라이딩 윈도우 → 잔여수명(RUL) 예측	DL	회귀	GRU / LSTM (window=20, units=32)	FEMTO-ST 베어링 (FEMTO_processed)
streamlit_rag.py	RAG	센서 측정값	LLM(RAG)	검색 +	FAISS 벡터	FEMTO-ST 이력

	유사 사례 검색	→ FAISS 코사인 유사도 검색 → Top-K 사례 + RUL 추정		회귀	검색 (12 차원 피쳐)	(베어링 전체 수명)
--	----------------	---	--	----	---------------------	----------------

※ ML 기능: XGBoost(Tab1 분류), RF/GBM(FEMTO 분류) — 정형 데이터 기반

※ DL 기능: CNN+LSTM(시계열 분류), 1D-CNN(원시신호 분류), GRU/LSTM(RUL 회귀)

※ LLM/RAG: FAISS 벡터 검색 기반 유사 사례 검색 — 비정형 이력 활용

※ 회귀 기능: FEMTO DL RUL 예측(분 단위), RAG RUL 추정/ 그 외: 이진·다중 분류

OOS RMSE 각주

【OOS RMSE 각주】

- OOS(Out-Of-Sample): 학습에 미사용된 테스트셋으로 측정한 RMSE → 모델 일반화 성능 지표
↔ In-Sample RMSE(학습셋)와 대비; 실무 모델 선정 기준은 OOS 우선
- 단위: 분(min). 810.4 분 ≈ 'RUL 예측이 실제와 평균 ~836 분 차이' (제공평균 → 큰 오차 가중)
- 작을수록 우수. OOS >> In-Sample 이면 과적합 신호
- 기준선 956 분: 그리드서치 챔피언(window=20, units=32, dropout=0.1)의 고정 참조값
≠ batch=32 재실험값(1002.6 분). 동일 설정도 시드·초기화 변동으로 실행마다 결과 상이
→ 표의 '기준(batch=32)'과 '기준(956 분)'은 별개 개념; 혼동 방지 주석

Milling 분류 모델 비교

임계값 0.75 조건에서 3 개 모델 모두 동일 붕괴(F1=0.0) — 9 에폭 조기종료 시 P(마모)≈0.66 수렴, 임계값 미달로 전부 0 예측.

모델	비고	파라미터	ACC	F1	AUC	에폭
1D-CNN(멀티채널)	기준 기준	176,321	0.3424	0.0000	0.5000	9
MLP(Flatten→Dense)	신규 비교	1,722,753	0.3424	0.0000	0.5000	9
BiLSTM(Conv 다운샘플→Bi-LSTM)	신규 비교	59,617	0.3424	0.0000	0.5000	9

※ [아키텍처 개선] LayerNormalization(RNN 이후) + BatchNormalization(Dense 전) + Dropout 강화 추가 →

GRU_v2(BN+LN) OOS RMSE 810.4 분 (MAE 665.6 분, 기준 대비 +16.8% 개선, 수렴 에폭 54→33 단축). RNN 계층엔

LayerNorm(배치 통계 불안정 회피), Dense 앞엔 BatchNorm 적용. Dense 뉴런 수 16→32, Dense 후 Dropout 추가로 과적합 억제.