

AI 개발 수행내역서

FEMTO-ST 베어링 잔여수명(RUL) 예측

ML+DL + LLM 통합 예지보전(PdM) 시스템

허남



목차

개발 → 튜닝 → 결론

I

프로젝트 개요

기존 DL 시스템의 한계와 LLM 필요성

II

LLM 확장 방안

3종 비교 · Proposal A 채택

III

RAG 2단계 아키텍처

수치 유사도 + 문서 RAG

IV

Hybrid RAG

BM25 + 벡터 · v0.6 신규 적용

V

LLM 진단 보고서 파이프라인

파이프라인 · 배포 · 통합 진단 · 릴리스 · 결론

VI

결론/기대효과 · 로드맵 · 향후 계획

LLM 성능개선 로드맵(4단계) · 향후 적용 우선순위

A

DL · ML 프로젝트 구성

PdM 도입 효과 · FEMTO-ST 데이터 구성

B

세 과제 구성 (ML ↔ DL ↔ LLM)

현장 데이터를 세 Streamlit 앱이 구독

C

미채택 방안 · 산출물

Proposal B/C · 산출물 노트북(ipynb/py)

D

환각 방어 게이트

3층 게이트 · 모를 땀 판단불가로 풀백

E

RAG 출처근거(Citation)

문서 근거를 절 번호·개정일로 태깅



프로젝트 개요 - 기존 DL 시스템의 한계와 LLM 필요성

구분	기존 출력 (수치만)	LLM 적용 후 (자연어 해석)
ML 확률	0.72	[현재 상태] 위험 - 열화 72%
DL RUL	45분	[정비 권고] 즉시 점검 및 교체 준비
RAG 유사도	92.3%	[유사 사례] Bearing1_3 동일 패턴, 30분 후 파손
문제 -> 해결	데이터 분석가만 해석 가능, 현장 조치 지연	비전문가도 즉시 이해 가능한 정비 보고서로 자동 변환

의의: ML/DL/RAG의 수치 결과는 정확하지만 현장 담당자가 즉시 행동으로 옮기기 어려움
→ LLM(Claude API)이 이 수치를 근거로 사람이 읽는 자연어 진단 보고서로 변환하는 해석 계층 추가

방안	핵심 기능	난이도	채택
A	RAG+ML/DL -> LLM 자연어 보고서	낮음	채택
B	LLM이 이상 패턴 직접 학습	높음	미채택
C	멀티모달 센서+문서 RAG	중간	미채택

의의: 채택 기준은 구현 가능성+즉시 현장 적용+비용 효율성
→ Proposal A가 가장 낮은 난이도로 즉시 현장 적용 가능해 채택

구분	RAG Level 1 (수치 유사도)	RAG Level 2 (문서 RAG)
모듈	src/femto_rag_search.py	src/femto_doc_rag.py
인덱스	FAISS IndexFlatIP(코사인)	Chroma 벡터DB(영구 저장)
질의 방식	센서값 -> Top-k 유사 사례 검색	자연어 질문 -> 문서 검색/답변
RAG 종류	일반 RAG(순수 벡터 검색)	Hybrid RAG(BM25+벡터, v0.6)

의의: Level 1은 과거에 비슷한 상태가 있었는가를 수치로,
Level 2는 정비 지식 문서에 어떤 근거가 있는가를 자연어로 대답함
→ 두 결과는 LLM 보고서의 근거로 결합

항목	적용 전 (v0.5)	적용 후 (v0.6)
검색 방식	Chroma 벡터 검색만	BM25(키워드)+벡터, EnsembleRetriever 50:50
약점/개선	정확한 수치, 임계값 표현을 놓치기 쉬움	BM25가 수치, 임계값 포착, 벡터가 의미 유사 보완
검증 질의	온도만 상승하면? -> 찾을 수 없음	동일 질문 -> 윤희 점검 근거 정확히 답변

의의: 정비 문서는 40도 초과 같은 정확한 수치 표현이 많아 순수 의미 검색만으로는 놓치기 쉬움
 → Hybrid RAG로 RAG-Level2 검색 정확도를 개선(v0.6 완료)

항목	내용
모듈 / API	src/femto_llm_report.py, Claude API(claude-haiku-4-5-20251001)
입력 컨텍스트	센서값 + ML 열화확률 + DL RUL + RAG Level1/2 근거
출력 구조(5섹션)	현재 상태, 이상 신호, 정비 권고, 유사 사례, 문서 근거
Mock 모드	API 키 미설정 시 규칙 기반 동일 구조 보고서(무료 데모)
Structured Output	JSON Schema 강제 출력 - status/anomalies/action 등, 대시보드/알람 연동

의의: LLM은 ML/DL의 수치 판정을 대체하지 않음

→ RAG 근거와 함께 현장 담당자가 바로 읽을 수 있는 자연어 정비 권고로 해석, 문서화하는 계층

앱 파일	포트	역할
streamlit_app.py	8501	DL 메인 - 시계열 고장 예측
streamlit_rag.py	8502	LLM/RAG 전용 - Level1 유사 사례 데모
streamlit_femto.py	8503	ML+DL+LLM 통합 진단 (Tab6: AI 정비 권고) — Ollama(gemma4:e2b)+Claude Haiku 4.5 병행
streamlit_unified.py	8504	3-Source 통합 (ML+DL+DL Milling)

의의: 이중 LLM 구조

- RAG-Level2 자유 질의응답은 로컬 Ollama(gemma4:e2b, 무료·오프라인)
- LLM 진단 보고서 생성은 Claude API(유료·클라우드)가 각각 담당
(Ollama는 상시 프로세스 실행이 필요해 Streamlit Cloud에서는 이 기능만 제한,버그 아닌 제약사항)

7탭 구성

 데이터 탐색

 ML 성능

 DL RUL 예측

 통합 진단(실시간)

 아키텍처 비교(5종)

 LLM 정비 권고(AI 진단)

 CNN 이미지 분류

배포 URL: dlfactoryautomation.streamlit.app

Repo: vapsnamheo-dev/AISOURCE

사이드바: ML 임계값 0.3~0.8 + RUL 경고 기준 30~120분 실시간 조정

통합 진단 — Stage 4 열화 샘플 클릭 시 표시 로직

ML 분류(현재 이상 여부) + DL RUL(잔여수명)을 결합한 경보 표시

ML 판정	DL RUL	표시
열화 (P=1.00)	144분 양호 기준 초과	● ⚠ ML 열화 감지 — RUL 144분 (단일 입력 추정, ML 신뢰) 단일 슬라이더 입력은 시계열 복제(tile) 추정 → 'ML 신뢰' 캡션으로 한계 명시
열화	100분 기준 2배 이내	● ⚠ ML 열화 감지 — 잔여수명 100분 (ML 판정 우선)
열화	50분 기준 이하	● 긴급 경고: 잔여수명 50분
정상	어떤 값이든	기존 양호 / 주의 / 경고 규칙 그대로

LLM 정비 권고 탭 상세: femto_llm_report.py, Claude API(haiku-4-5), RAG-Level1/2 근거 결합 -> 5섹션 자연어 보고서 + Structured Output.
ANTHROPIC_API_KEY 미설정 시 Mock 모드로 무료 데모 가능.

구분	내용
신규 기능	ANTHROPIC_API_KEY on/off 스위치 + 토큰수/비용 화면표시
버그 수정	피쳐 스키마 불일치 / pandas 버전드리프트 / 중첩버튼 / 패키지 누락
RAG 개선	temperature 0.0 고정 + Hybrid RAG(BM25+벡터) 적용
UX 개선(07-03)	크레딧 부족 에러를 결제 안내로 구분 표시, 타이틀/캡션 갱신

의의: v0.5 draft 이후 배포 안정성 버그 수정과 과금 방지 기능을 지속 추가.
특히 Anthropic 크레딧 부족(400) 에러를 코드 버그와 구분해 결제 안내로 표시하도록 개선(2026-07-03).

항목	내용
현장 접근성	수치->자연어: 비전문가도 즉시 이해
의사결정 가속화	즉시/24h/1주 조치 자동 분류
RAG 시너지	과거 사례를 의미있는 설명으로 변환, Hybrid RAG로 정확도 개선
비용 최적화	haiku 모델 + Mock 모드 + on/off 스위치(v0.6)
확장성	Agent/Tool Use -> LangGraph -> (필요시) GraphRAG 단계적 고도화
신뢰성/투명성(신규)	환각 방어 3층 게이트(femto_llm_guard) + RAG 출처근거 Citation 표기 (femto_doc_rag)로 답변 신뢰도·추적성 확보

의의: LLM 추가로 PdM 시스템의 현장 실용성이 대폭 향상
 → ML->DL->RAG->LLM까지 이어지는 end-to-end 파이프라인 완성

LLM 성능개선 로드맵 (1~4순위)

우선순위 · 항목	상태	핵심 내용
1순위 - Structured Output	완료 (v0.5)	Claude output_config.format(JSON Schema)으로 정형 데이터 반환
2순위 - Agent / Tool Use	예정 (~07/24)	Claude function calling(tool_use)으로 전환, ReAct 패턴
3순위 - Workflow Orchestration (LangGraph)	예정 (~08/21)	센서->ML->DL->RAG->LLM 파이프라인 명시적 그래프화
4순위 - GraphRAG	미구현 (최후순위)	networkx/neo4j 등 미사용. 설비 관계망 데이터 확보 시 재검토

한계점 (Limitations)

- 비용 발생 - Claude API 호출당 과금 (Mock 모드/on-off 스위치로 완화, v0.6)
- RAG 문서 커버리지 제한 - 정비 지식 문서 1종만 인덱싱
- 로컬 LLM(Ollama) 필요 기능은 Streamlit Cloud에서 미지원 (RAG-Level2 ask())
- 환각(hallucination) 방어 - femto_llm_guard 3층 게이트(신뢰도 톤 분기·입력 OOD 판정·클래스 한정 자기 인지)로 모를 땐 판단불가로 폴백, 구조적으로 차단(v0.7 신규)
- GraphRAG 등 고도화 로드맵 미완료 (4순위)

실무 포지셔닝: LLM은 ML·DL의 수치 판정을 대체하지 않고, RAG 근거와 함께 현장 담당자가 바로 읽을 수 있는 자연어 정비 권고로 해석·문서화하는 계층으로 포지셔닝. Structured Output(정형 출력)+RAG 근거 인용으로 신뢰성 확보.

우선순위	상태	핵심 내용
1순위 Structured Output	완료(v0.5)	JSON Schema 정형 출력
신규 Hybrid RAG	완료(v0.6, 07-03)	BM25+벡터 결합 검색 정확도 개선
2순위 Agent/Tool Use	예정(~07/24)	Claude function calling(ReAct 패턴)
3순위 LangGraph	예정(~08/21)	파이프라인 명시적 그래프화
4순위 GraphRAG	미구현, 최후순위	설비 관계망 수준으로 확장 시 재검토
신규 환각방지 3층 게이트	완료(v0.7, 07-07)	femto_llm_guard.py — 모를 땐 판단불가 폴백으로 hallucination 구조적 차단
신규 RAG 출처근거(Citation)	완료(v0.7, 07-07)	femto_doc_rag.py — 파일명.절 번호.개정 일 태깅으로 근거 추적 가능

A. DL/ML 프로젝트 구성

PdM 도입 효과 / FEMTO-ST 데이터 구성

추진 배경

핵심부품 베어링의 기존 정기 점검(PM)은 보통 분 단위 잔여수명을 예측 못하고 임계값 경보에 머무는 실제 열화 상태를 반영하지 못해 과잉·과소 점검이 반복되는 한계
→ FEMTO-ST 진동·온도 신호를 ML·DL로 학습 → ML 분류로 즉시 이상 판정 + DL RUL로 교체 시점 조기경보 → 현장 PdM

① ML 이상 탐지 → ② DL 잔여수명 예측 → ③ CNN + Grad-CAM 시각화 → 정비 의사결정 지원

① ML 단계

정상 / 열화 분류

- ▶ 알고리즘: RandomForest · XGBoost
- ▶ 입력: 진동 RMS · 점도 · 크레스트 인자
- ▶ 출력: 열화 확률(%) · 임계값 기반 판정
- ▶ 역할: '지금 이상이 있는가?' 1차 경보

② DL 단계

잔여수명(RUL) 정밀 예측

- ▶ 알고리즘: GRU v2 (Batch Norm + Layer Norm)
- ▶ 입력: 진동 시계열 시퀀스
- ▶ 출력: 잔여 가동 시간(분) 예측값
- ▶ 역할: '언제 교체해야 하는가?' 정밀 예측

③ CNN + Grad-CAM

고장 부위·시점 시각화

- ▶ 알고리즘: CNN (Conv2D × 3 레이어)
- ▶ 입력: 진동 신호 → matplotlib 이미지 변환
- ▶ Grad-CAM: 마지막 Conv 기울기 역전파
→ 히트맵으로 '어느 시점이 위험했나' 표시
- ▶ 역할: XAI — CNN 판정 근거 시각화

기대 효과

- 계획외 정지 30~50% 감소
- 유지보수 비용 10~25% 절감
- 성과 지표: OOS (*3) RMSE < 900분 / ML 대비 개선율 > 10% / 응답 < 2초

개발 방법

GroupKFold(*1) + VIF + 3종 GridSearch → ML 베이스라인
GRU 시계열 학습 → RUL 정밀도 향상 (BN+LN (*2))
Streamlit 6탭 통합 진단 대시보드
LLM(Claude API)+RAG 2단계로 자연어 진단 보고서 자동화 (본 프로젝트, 부록 C 참고)

(*1) GroupKFold(단순 무작위 분할이 아닌 베어링 단위를 통째로 분리)로 시계열 누수 완전 차단

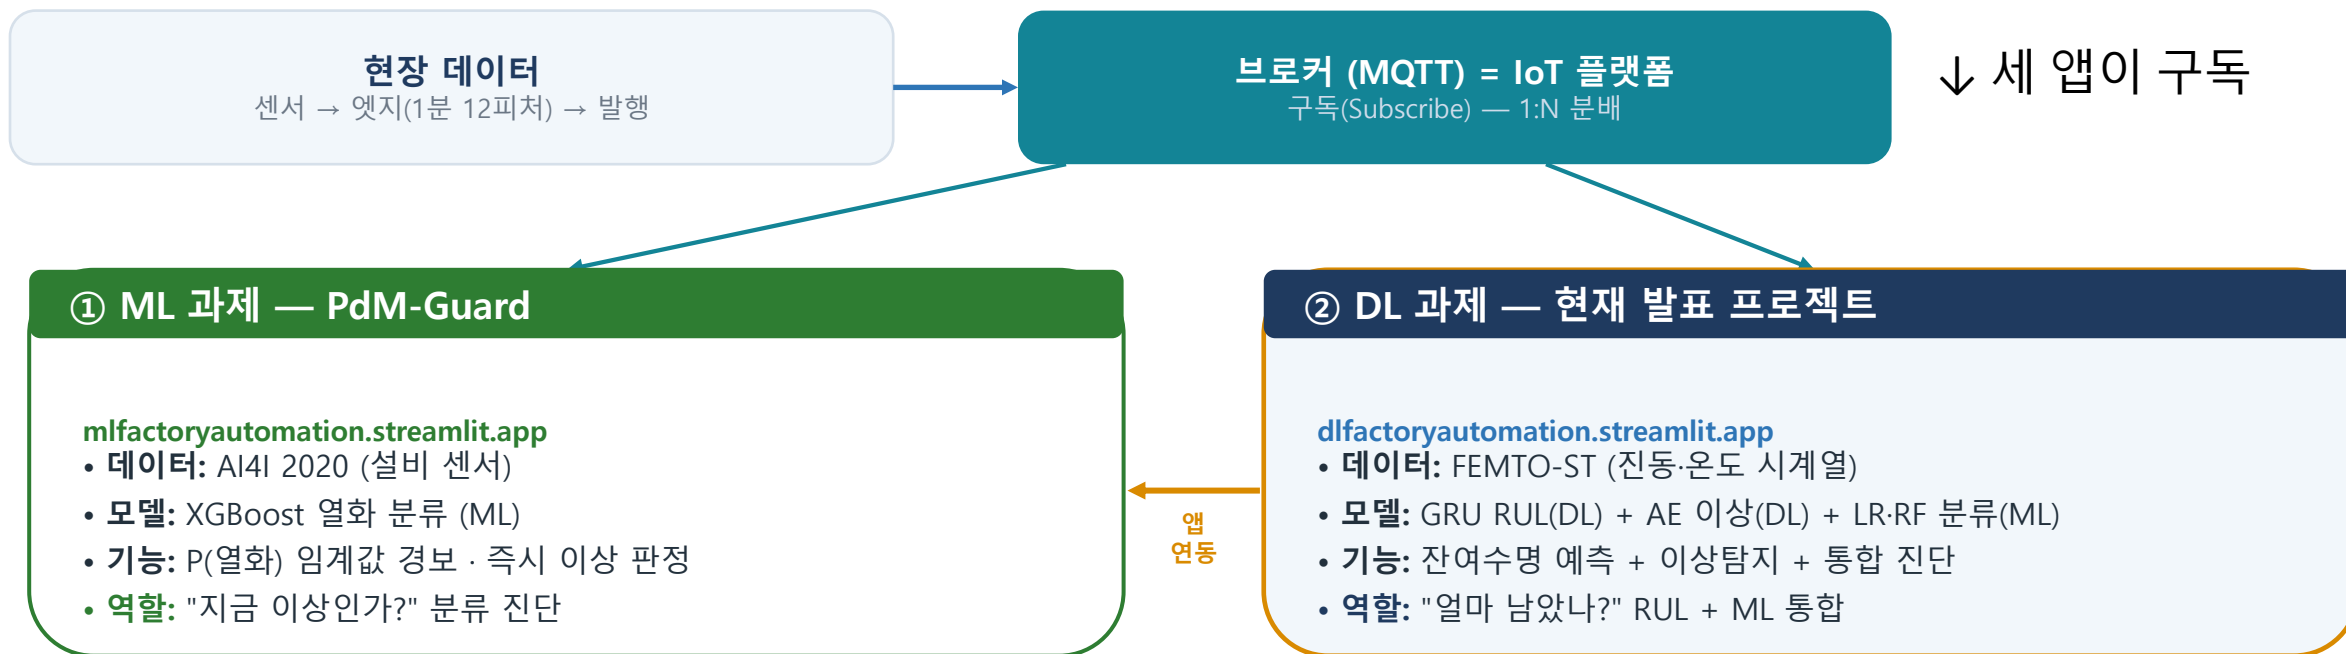
(*2) **GRU v1에 정규화 계층(LayerNorm + BatchNorm)을 추가한 개선 버전

(*3) 테스트(Out-Of-Sample / OOS 모델 학습에 쓰지 않은 데이터) 11개는 3개 Condition에 걸친 미관측 베어링

→과적합을 드러내고 '새 설비 배포 시 실제 성능' 정직하게 모사(RF·XGB가 IS F1 0.94 → OOS Recall 0.5로 무너진 게 그 증거)

B. 세 과제 구성 — ML 과제 ↔ DL 과제 ↔ LLM 과제(본 프로젝트)

현장 데이터를 세 Streamlit 앱이 구독 — 역할 분담과 상호 연결



개념 예지보전(PdM)은 목적이고, 그 아래 ML 과제(PdM-Guard)=열화 분류 전담, DL 과제=RUL 예측 중심 + ML 분류까지 통합입니다.
→ 두 앱은 링크로 연결된 상호보완 구성 — DL앱의 "ML 설비 진단 앱으로 →" 버튼으로 이동. 분류(ML)는 "지금 이상?", RUL(DL)은 "얼마 남았나?"를 담당.

③ LLM 과제(본 프로젝트) - llmfactoryautomation.streamlit.app: RAG(FAISS 수치유사도 + Chroma Hybrid 문서RAG)+Claude API로 ML·DL 결과를 자연어 진단 보고서로 변환. 세 앱은 ML->DL->LLM 순으로 계층적으로 확장됨 (GitHub: vapsnamheo-dev/AISOURCE).

항목	내용
Proposal B (미채택)	LLM이 이상 패턴을 직접 학습 - 난이도 높음, 학습 데이터/검증 비용 과다로 보류
Proposal C (미채택)	멀티모달 센서+문서 RAG 결합 - 난이도 중간이나 현재 데이터로는 이득 대비 복잡도 부담
재검토 조건	데이터 규모 확대, 설비 관계망 데이터 확보 시 GraphRAG(4순위)와 함께 재검토
소스 산출물	산출물/LLM프로젝트/허남_LLM프로젝트.ipynb, .py - ML->DL->RAG(Level1+Hybrid)->LLM 전체 파이프라인 실행 가능 노트북

의의

Proposal A(채택)는 구현 난이도가 낮고 즉시 현장 적용 가능해 우선 구현했다. B/C는 데이터/인프라가 갖춰지면 재검토 대상이며, 실제 실행 가능한 파이프라인은 산출물/LLM프로젝트 노트북에서 확인할 수 있다.

게이트	내용	통과 시 / 이탈 시
① 신뢰도 톤 분기	prob 구간별 어투 강도 조절 (confidence_tone)	고확신 → 단정 / 애매 → 확인 권유
② 입력 게이트	센서값 물리적 OOD 판정 (check_input_gate)	정상 → 처리 / 과실·비정상 → 차단·재측정
③ 클래스 한정성 자기인지	아는 범위 4종 고정 (정상·주의·위험·판단불가)	범위 내 → 판단 / 범위 밖 → 진단 보류(판단불가)

의의: 모를 땐 '모른다'고 답한다 — 통과는 정직한 처방, 이탈은 차단·보류로 처리해 환각(hallucination)을 구조적으로 차단한다. 근거 구조 감사: format=JSON 스키마 + 검증 재시도 + 근거출처 코드 주입 — 스키마 위반 시 1회 재시도, 그래도 실패하면 추측 대신 판단불가로 폴백. (src/femto_llm_guard.py 신규, tests/test_femto_llm_guard.py 11건 pytest 통과)

항목	내용	비고
출처 태그 형식	[출처: 파일명 § N.절제목 · 개정 YYYY-MM-DD]	bearing_maintenance_guide.txt 상단 개정일 프론트매터에서 추출
적용 범위	retrieve_docs() · ask() · BM25+ 벡터 Hybrid 양쪽 경로	기존엔 BM25 경로에서 출처 메타데이터 소실 — 수정함
검증	pytest 5건 통과 + 로컬 Chroma 인덱스 재빌드 실제 호출 확인	tests/test_femto_doc_rag_citations.py

의의: 문서 근거를 "파일명 § 절 번호.제목 · 개정일" 형식으로 태깅해, LLM 답변이 어느 문서의 어느 부분을 인용했는지 사람이 바로 확인 가능. 신문기사의 "OO신문 며칠자" 인용과 동일한 역할 — 근거 문서가 늘어나도 동일한 메타데이터 패턴 그대로 적용 가능. (src/femto_doc_rag.py 개선, tests/test_femto_doc_rag_citations.py 5건 pytest 통과)