

AI 개발 수행내역서

FEMTO-ST 베어링 잔여수명(RUL) 예측

ML+DL + LLM 통합 예지보전(PdM) 시스템

담당자: 허남



목차

개발 → 튜닝 → 결론

I

프로젝트 개요

기존 DL 시스템의 한계와 LLM 필요성

II

LLM 확장 방안

3종 비교 · Proposal A 채택

III

RAG 2단계 아키텍처

수치 유사도 + 문서 RAG

IV

Hybrid RAG

BM25 + 벡터 · v0.6 신규 적용

V

LLM 진단 보고서 파이프라인

파이프라인 · 배포 · 통합 진단 · 릴리스 · 결론

VI

결론/기대효과 · 로드맵 · 향후 계획

LLM 성능개선 로드맵(4단계) · 향후 적용 우선순위

A

DL · ML 프로젝트 구성

PdM 도입 효과 · FEMTO-ST 데이터 구성

B

세 과제 구성 (ML ↔ DL ↔ LLM)

현장 데이터를 세 Streamlit 앱이 구독

C

미채택 방안 · 산출물

Proposal B/C · 산출물 노트북(ipynb/py)



프로젝트 개요 - 기존 DL 시스템의 한계와 LLM 필요성

구분	기존 출력 (수치만)	LLM 적용 후 (자연어 해석)
ML 확률	0.72	[현재 상태] 위험 - 열화 72%
DL RUL	45분	[정비 권고] 즉시 점검 및 교체 준비
RAG 유사도	92.3%	[유사 사례] Bearing1_3 동일 패턴, 30분 후 파손
문제 -> 해결	데이터 분석가만 해석 가능, 현장 조치 지연	비전문가도 즉시 이해 가능한 정비 보고서로 자동 변환

의의: ML/DL/RAG의 수치 결과는 정확하지만 현장 담당자가 즉시 행동으로 옮기기 어렵다. LLM(Claude API)이 이 수치를 근거로 사람이 읽는 자연어 진단 보고서로 변환하는 해석 계층을 추가한다.

방안	핵심 기능	난이도	채택
A	RAG+ML/DL -> LLM 자연어 보고서	낮음	채택
B	LLM이 이상 패턴 직접 학습	높음	미채택
C	멀티모달 센서+문서 RAG	중간	미채택

의의: 채택 기준은 구현 가능성+즉시 현장 적용+비용 효율성. Proposal A가 가장 낮은 난이도로 즉시 현장 적용 가능해 채택했다.

구분	RAG Level 1 (수치 유사도)	RAG Level 2 (문서 RAG)
모듈	src/femto_rag_search.py	src/femto_doc_rag.py
인덱스	FAISS IndexFlatIP(코사인)	Chroma 벡터DB(영구 저장)
질의 방식	센서값 -> Top-k 유사 사례 검색	자연어 질문 -> 문서 검색/답변
RAG 종류	일반 RAG(순수 벡터 검색)	Hybrid RAG(BM25+벡터, v0.6)

의의: Level 1은 과거에 비슷한 상태가 있었는가를 수치로, Level 2는 정비 지식 문서에 어떤 근거가 있는가를 자연어로 답한다. 두 결과는 LLM 보고서의 근거로 결합된다.

항목	적용 전 (v0.5)	적용 후 (v0.6)
검색 방식	Chroma 벡터 검색만	BM25(키워드)+벡터, EnsembleRetriever 50:50
약점/개선	정확한 수치, 임계값 표현을 놓치기 쉬움	BM25가 수치, 임계값 포착, 벡터가 의미 유사 보완
검증 질의	온도만 상승하면? -> 찾을 수 없음	동일 질문 -> 윤희 점검 근거 정확히 답변

의의: 정비 문서는 40도 초과 같은 정확한 수치 표현이 많아 순수 의미 검색만으로는 놓치기 쉽다. Hybrid RAG로 RAG-Level2 검색 정확도를 개선했다(2026-07-03, v0.6 완료).

항목	내용
모듈 / API	src/femto_llm_report.py, Claude API(claude-haiku-4-5-20251001)
입력 컨텍스트	센서값 + ML 열화확률 + DL RUL + RAG Level1/2 근거
출력 구조(5섹션)	현재 상태, 이상 신호, 정비 권고, 유사 사례, 문서 근거
Mock 모드	API 키 미설정 시 규칙 기반 동일 구조 보고서(무료 데모)
Structured Output	JSON Schema 강제 출력 - status/anomalies/action 등, 대시보드/알람 연동

의의: LLM은 ML/DL의 수치 판정을 대체하지 않고, RAG 근거와 함께 현장 담당자가 바로 읽을 수 있는 자연어 정비 권고로 해석, 문서화하는 계층이다.

앱 파일	포트	역할
streamlit_app.py	8501	DL 메인 - 시계열 고장 예측
streamlit_rag.py	8502	LLM/RAG 전용 - Level1 유사 사례 데모
streamlit_femto.py	8503	ML+DL+LLM 통합 진단 (Tab6: AI 정비 권고)
streamlit_unified.py	8504	3-Source 통합 (ML+DL+DL Milling)

의의: 배포 URL은 `llmfactoryautomation.streamlit.app`. RAG-Level2의 자유 질의응답(`ask()`)은 로컬 Ollama(gemma)가 필요해 Streamlit Cloud(상시 프로세스 실행 불가)에서는 이 기능만 제한된다(버그 아님, 의도된 제약). 문서 검색과 Claude API 진단 보고서는 Cloud에서 정상 동작한다.

7탭 구성

 데이터 탐색

 ML 성능

 DL RUL 예측

 통합 진단(실시간)

 아키텍처 비교(5종)

 LLM 정비 권고(AI 진단)

 CNN 이미지 분류

배포

URL: dfactoryautomation.streamlit.app

Repo: vapsnamheo-dev/AISOURCE

사이드바: ML 임계값 0.3~0.8 + RUL 경보 기준 30~120분 실시간 조정

통합 진단 — Stage 4 열화 샘플 클릭 시 표시 로직

ML 분류(현재 이상 여부) + DL RUL(잔여수명)을 결합한 경보 표시

ML 판정	DL RUL	표시
열화 (P=1.00)	144분 양호 기준 초과	● ⚠ ML 열화 감지 — RUL 144분 (단일 입력 추정, ML 신뢰) 단일 슬라이더 입력은 시계열 복제(tile) 추정 → 'ML 신뢰' 캡션으로 한계 명시
열화	100분 기준 2배 이내	● ⚠ ML 열화 감지 — 잔여수명 100분 (ML 판정 우선)
열화	50분 기준 이하	● 긴급 경보: 잔여수명 50분
정상	어떤 값이든	기존 양호 / 주의 / 경보 규칙 그대로

LLM 정비 권고 탭 상세: femto_llm_report.py, Claude API(haiku-4-5), RAG-Level1/2 근거 결합 -> 5섹션 자연어 보고서 + Structured Output.
ANTHROPIC_API_KEY 미설정 시 Mock 모드로 무료 데모 가능.

구분	내용
신규 기능	ANTHROPIC_API_KEY on/off 스위치 + 토큰수/비용 화면표시
버그 수정	피쳐 스키마 불일치 / pandas 버전드리프트 / 중첩버튼 / 패키지 누락
RAG 개선	temperature 0.0 고정 + Hybrid RAG(BM25+벡터) 적용
UX 개선(07-03)	크레딧 부족 에러를 결제 안내로 구분 표시, 타이틀/캡션 갱신

의의: v0.5 draft 이후 배포 안정성 버그 수정과 과금 방지 기능을 지속 추가했다. 특히 Anthropic 크레딧 부족 (400) 에러를 코드 버그와 구분해 결제 안내로 표시하도록 개선(2026-07-03)했다.

VI.

1. 결론 및 기대효과

항목	내용
현장 접근성	수치->자연어: 비전문가도 즉시 이해
의사결정 가속화	즉시/24h/1주 조치 자동 분류
RAG 시너지	과거 사례를 의미있는 설명으로 변환, Hybrid RAG로 정확도 개선
비용 최적화	haiku 모델 + Mock 모드 + on/off 스위치(v0.6)
확장성	Agent/Tool Use -> LangGraph -> (필요시) GraphRAG 단계적 고도화

의의: LLM 추가로 PdM 시스템의 현장 실용성이 대폭 향상되었으며, ML->DL->RAG->LLM까지 이어지는 end-to-end 파이프라인을 v0.6 기준으로 완성했다.

LLM 성능개선 로드맵 (1~4순위)

우선순위 · 항목	상태	핵심 내용
1순위 - Structured Output	완료 (v0.5)	Claude output_config.format(JSON Schema)으로 정형 데이터 반환
2순위 - Agent / Tool Use	예정 (~07/24)	Claude function calling(tool_use)으로 전환, ReAct 패턴
3순위 - Workflow Orchestration (LangGraph)	예정 (~08/21)	센서->ML->DL->RAG->LLM 파이프라인 명시적 그래프화
4순위 - GraphRAG	미구현 (최후순위)	networkx/neo4j 등 미사용. 설비 관계망 데이터 확보 시 재검토

한계점 (Limitations)

- 비용 발생 - Claude API 호출당 과금 (Mock 모드/on-off 스위치로 완화, v0.6)
- RAG 문서 커버리지 제한 - 정비 지식 문서 1종만 인덱싱
- 로컬 LLM(Ollama) 필요 기능은 Streamlit Cloud에서 미지원 (RAG-Level2 ask())
- 환각(hallucination) 가능성 - Structured Output + 문서 근거 인용으로 완화하나 완전 제거는 아님
- GraphRAG 등 고도화 로드맵 미완료 (4순위)

실무 포지셔닝: LLM은 ML·DL의 수치 판정을 대체하지 않고, RAG 근거와 함께 현장 담당자가 바로 읽을 수 있는 자연어 정비 권고로 해석·문서화하는 계층으로 포지셔닝. Structured Output(정형 출력)+RAG 근거 인용으로 신뢰성 확보.

우선순위	상태	핵심 내용
1순위 Structured Output	완료(v0.5)	JSON Schema 정형 출력
신규 Hybrid RAG	완료(v0.6, 07-03)	BM25+벡터 결합 검색 정확도 개선
2순위 Agent/Tool Use	예정(~07/24)	Claude function calling(ReAct 패턴)
3순위 LangGraph	예정(~08/21)	파이프라인 명시적 그래프화
4순위 GraphRAG	미구현, 최후순위	설비 관계망 수준으로 확장 시 재검토

의의: Hybrid RAG(BM25+벡터)는 이미 v0.6로 구현을 완료했고, GraphRAG(그래프 기반 지식 검색)는 아직 미구현이며 로드맵상 가장 낮은 4순위다 - 이름은 비슷하지만 현재 상태는 정반대다.

A. DL/ML 프로젝트 구성

PdM 도입 효과 / FEMTO-ST 데이터 구성

추진 배경

핵심부품 베어링의 기존 정기 점검(PM)은 보통 분 단위 잔여수명을 예측 못하고 임계값 경보에 머무는 실제 열화 상태를 반영하지 못해 과잉·과소 점검이 반복되는 한계
 → FEMTO-ST 진동·온도 신호를 ML·DL 로 학습 → ML 분류로 즉시 이상 판정 + DL RUL로 교체 시점 조기경보 → 현장 PdM

① ML 이상 탐지 → ② DL 잔여수명 예측 → ③ CNN + Grad-CAM 시각화 → 정비 의사결정 지원

① ML 단계

정상 / 열화 분류

- ▶ 알고리즘: RandomForest · XGBoost
- ▶ 입력: 진동 RMS · 점도 · 크레스트 인자
- ▶ 출력: 열화 확률(%) · 임계값 기반 판정
- ▶ 역할: '지금 이상이 있는가?' 1차 경보

② DL 단계

잔여수명(RUL) 정밀 예측

- ▶ 알고리즘: GRU v2 (Batch Norm + Layer Norm)
- ▶ 입력: 진동 시계열 시퀀스
- ▶ 출력: 잔여 가동 시간(분) 예측값
- ▶ 역할: '언제 교체해야 하는가?' 정밀 예측

③ CNN + Grad-CAM

고장 부위·시점 시각화

- ▶ 알고리즘: CNN (Conv2D × 3 레이어)
- ▶ 입력: 진동 신호 → matplotlib 이미지 변환
- ▶ Grad-CAM: 마지막 Conv 기울기 역전파
→ 히트맵으로 '어느 시점이 위험했나' 표시
- ▶ 역할: XAI — CNN 판정 근거 시각화

기대 효과

- 계획외 정지 30~50% 감소
- 유지보수 비용 10~25% 절감
- 성과 지표: OOS (*3) RMSE < 900분 / ML 대비 개선율 > 10% / 응답 < 2초

개발 방법

GroupKFold(*1) + VIF + 3종 GridSearch → ML 베이스라인
 GRU 시계열 학습 → RUL 정밀도 향상 (BN+LN (*2))
 Streamlit 6탭 통합 진단 대시보드
 LLM(Claude API)+RAG 2단계로 자연어 진단 보고서 자동화 (본 프로젝트, 부록 C 참고)

(*1) GroupKFold(단순 무작위 분할이 아닌 베어링 단위를 통째로 분리)로 시계열 누수 완전 차단


(*2) **GRU v1에 정규화 계층(LayerNorm + BatchNorm)을 추가한 개선 버전

(*3) 테스트(Out-Of-Sample / OOS 모델 학습에 쓰지 않은 데이터) 11개는 3개 Condition에 걸친 미관측 베어링

→과적합을 드러내고 '새 설비 배포 시 실제 성능' 정직하게 모사(RF·XGB가 IS F1 0.94 → OOS Recall 0.5로 무너진 게 그 증거)

B. 세 과제 구성 — ML 과제 ↔ DL 과제 ↔ LLM 과제(본 프로젝트)

현장 데이터를 세 Streamlit 앱이 구독 — 역할 분담과 상호 연결



개념 예지보전(PdM)은 목적이고, 그 아래 ML 과제(PdM-Guard)=열화 분류 전담, DL 과제=RUL 예측 중심 + ML 분류까지 통합입니다.
→ 두 앱은 링크로 연결된 상호보완 구성 — DL앱의 "ML 설비 진단 앱으로 →" 버튼으로 이동. 분류(ML)는 "지금 이상?", RUL(DL)은 "얼마 남았나?"를 담당.

③ LLM 과제(본 프로젝트) - llmfactoryautomation.streamlit.app: RAG(FAISS 수치유사도 + Chroma Hybrid 문서RAG)+Claude API로 ML·DL 결과를 자연어 진단 보고서로 변환. 세 앱은 ML->DL->LLM 순으로 계층적으로 확장됨 (GitHub: vapsnamheo-dev/AISOURCE).

항목	내용
Proposal B (미채택)	LLM이 이상 패턴을 직접 학습 - 난이도 높음, 학습 데이터/검증 비용 과다로 보류
Proposal C (미채택)	멀티모달 센서+문서 RAG 결합 - 난이도 중간이나 현재 데이터로는 이득 대비 복잡도 부담
재검토 조건	데이터 규모 확대, 설비 관계망 데이터 확보 시 GraphRAG(4순위)와 함께 재검토
소스 산출물	산출물/LLM프로젝트/허남_LLM프로젝트.ipynb, .py - ML->DL->RAG(Level1+Hybrid)->LLM 전체 파이프라인 실행 가능 노트북

의의

Proposal A(채택)는 구현 난이도가 낮고 즉시 현장 적용 가능해 우선 구현했다. B/C는 데이터/인프라가 갖춰지면 재검토 대상이며, 실제 실행 가능한 파이프라인은 산출물/LLM프로젝트 노트북에서 확인할 수 있다.