인공지능(AI) 개발자 양성 과정

7 차시

프로젝트 기획 및 설계

휴먼교육센터 안홍근 강사

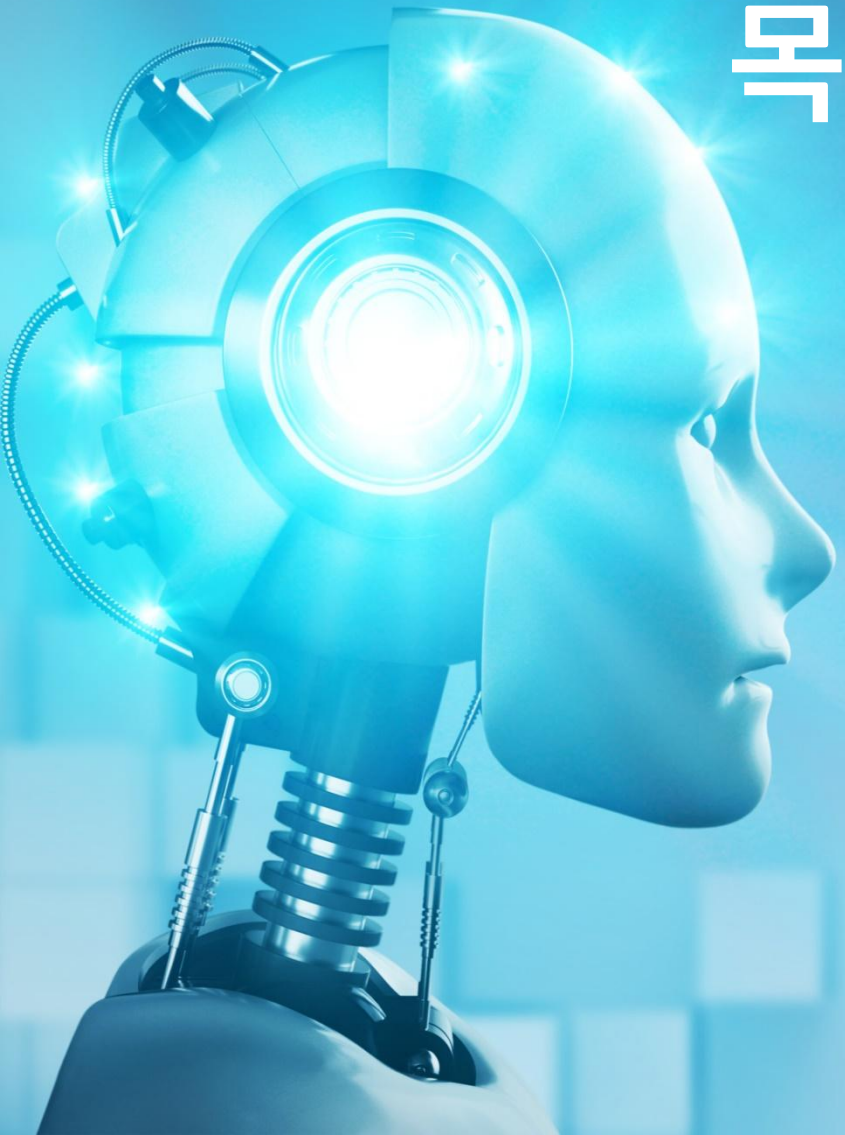

목차 Contents

1. 프로젝트 기획

2. 프로젝트 설계

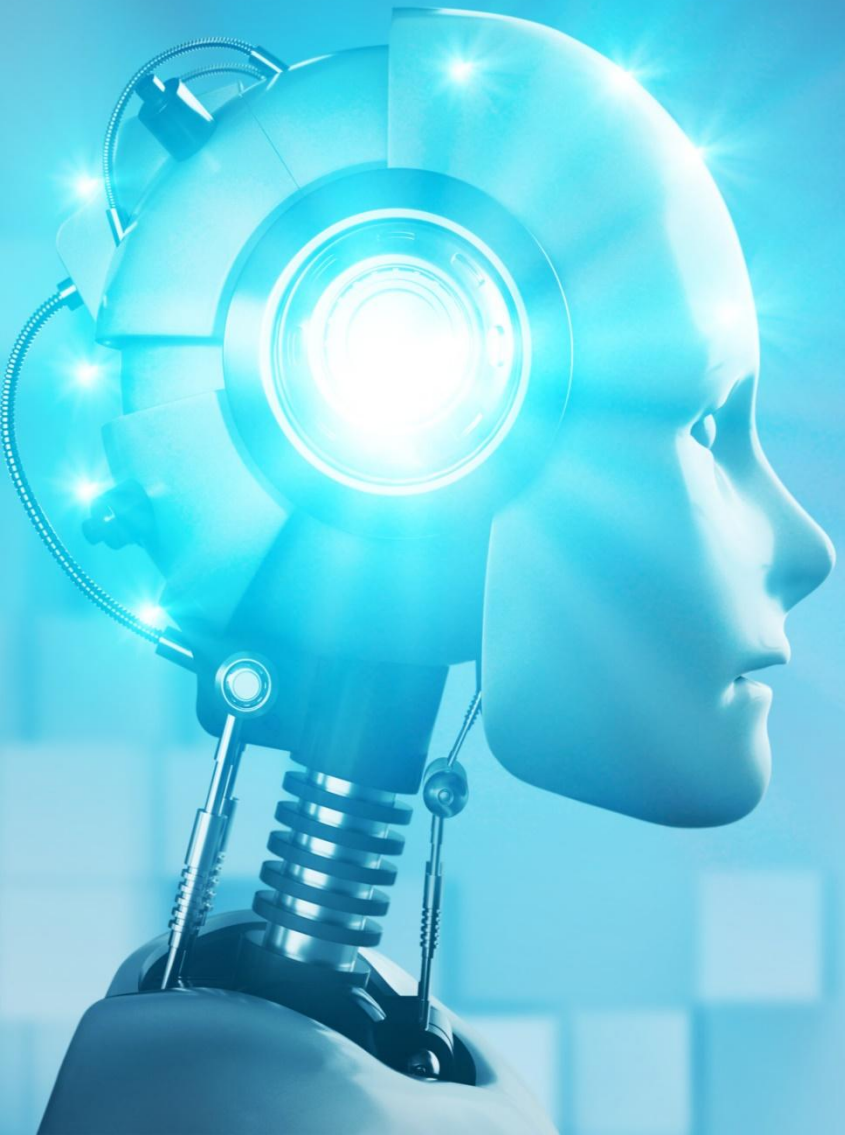

1 프로젝트 기획

1. 디자인 씽킹 (Design Thinking)
2. 기획서 작성 예시
3. 데이터 수집 및 전처리

1. 디자인씽킹 (Design Thinking)

1.1 정의와 특징

- 기획 단계에서 **사용자의 니즈(Neess)를 명확하게 이해**하고, **문제를 도출**하고, **실용적인 해결 방법을 찾기 위한** 일련의 과정
- 디자인씽킹은 사용자 중심의 문제해결 접근법으로, 창의적 문제 해결과 혁신을 위한 인간 중심적 문제 해결 방법론

특징	설명
사용자 중심	문제 해결 과정이 중심에 사용자를 두고, 사용자 경험과 요구를 깊이 탐구
창의적 문제 해결	기존의 틀에 얽메이지 않고 다양한 관점을 통해 새로운 해결책을 모색
협업	다양한 배경과 전문성을 가진 팀원이 협력하여 다각적인 접근을 가능하게 함
프로토타입 중심	빠르게 프로토타입을 제작하고 테스트를 통해 문제 해결 과정을 반복적으로 개선
반복적인 과정	결과가 만족스럽지 않더라도 반복과 피드백을 통해 지속적으로 개선

1.2 디자인씽킹 프로세스

☑ 디자인씽킹은 일반적으로 **5단계로 구성**되며, 각 단계는 유기적으로 연결되어 있음

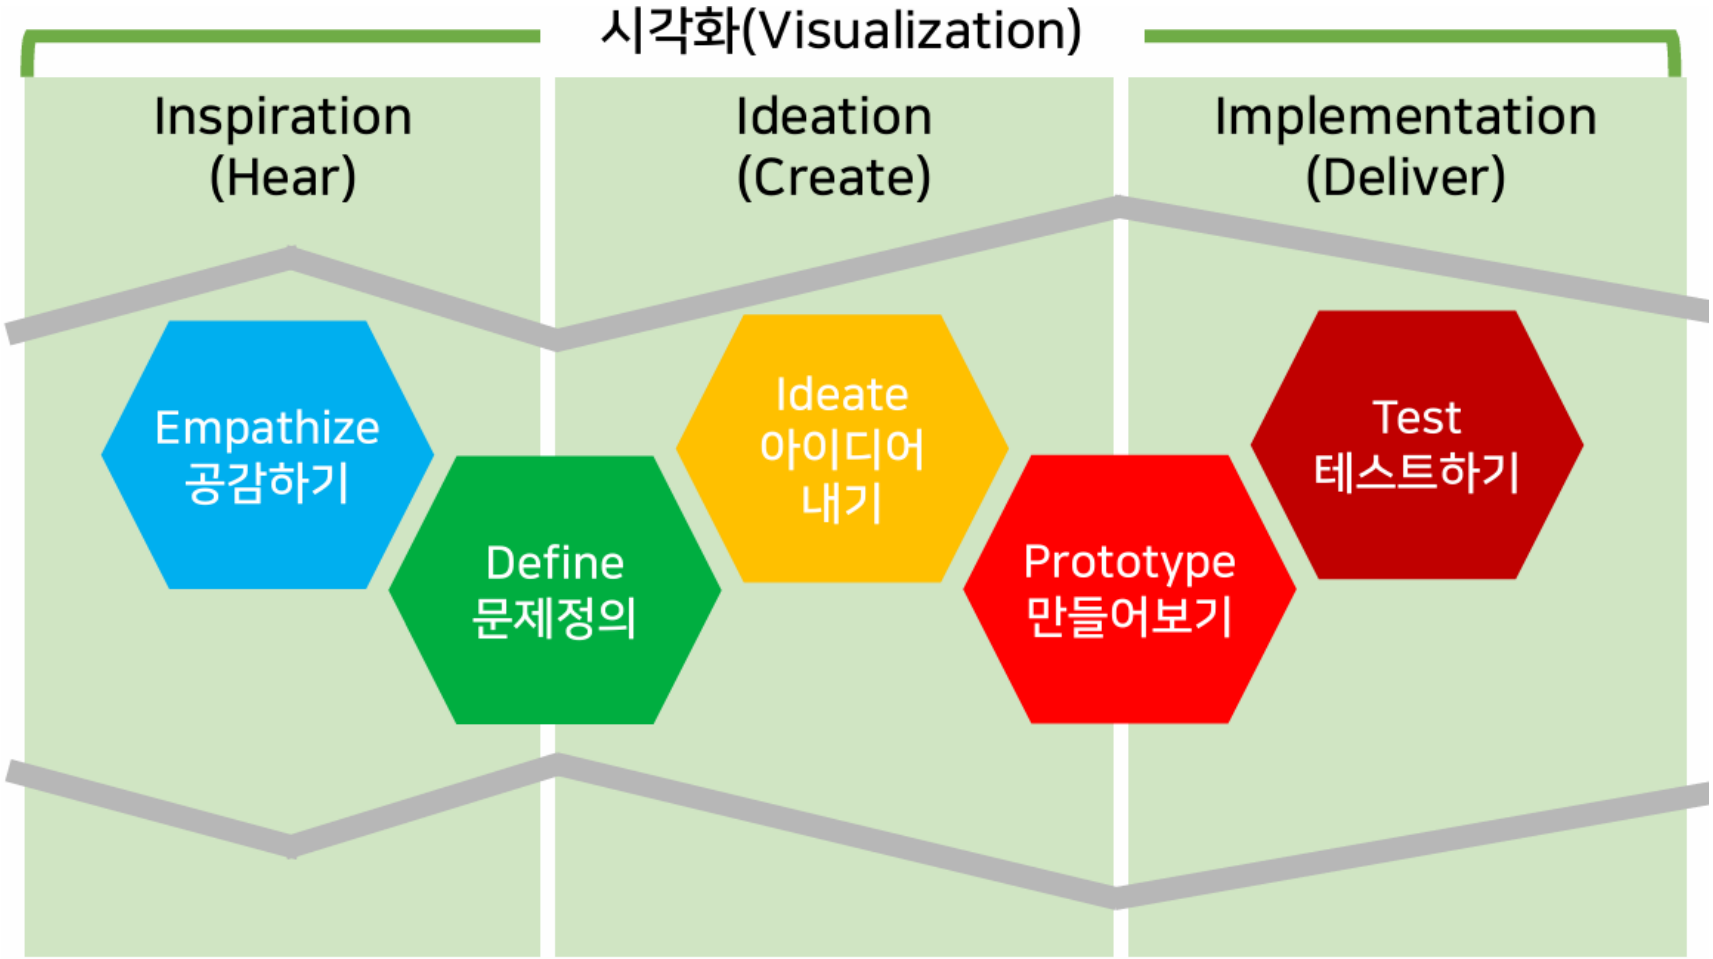

1.3 단계별 설명 (1/2)

☑ 디자인씽킹은 일반적으로 **5단계로 구성**되며, 각 단계는 유기적으로 연결되어 있음

단계	구분	설명
1. 공감 (Empathize)	목적	• 사용자의 관점에서 문제를 이해하고 공감하는 단계
	활동	• 사용자 인터뷰, 관찰, 설문조사 등을 통해 사용자의 니즈와 문제를 파악 • 사용자가 어떤 경험을 하고 있는가? 를 깊이 이해
2. 문제 정의 (Define)	목적	• 사용자의 요구와 문제를 명확하게 정의하는 단계
	활동	• 수집한 데이터를 분석해 핵심 문제를 도출 • 문제를 사용자 중심으로 다시 정의 (예: "사용자는 OO를 원하지만 △△ 때문에 어려움을 겪고 있다.")
3. 아이디어 도출(Ideate)	목적	• 문제 해결을 위한 다양한 아이디어를 생성하는 단계
	활동	• 브레인스토밍, 마인드맵을 통해 창의적이고 혁신적인 해결책을 탐구 • 비판 없이 가능한 많은 아이디어을 도출

1.3 단계별 설명 (2/2)

☑ 디자인씽킹은 일반적으로 **5단계로 구성**되며, 각 단계는 유기적으로 연결되어 있음

단계	구분	설명
4. 프로토타입(Prototype)	목적	• 도출된 아이디어를 빠르게 시각화하거나 모델링하여 실험 가능한 솔루션을 만듬
	활동	• 프로토타입을 제작 • 사용자가 솔루션을 직접 체험할 수 있는 형태로 구현
5. 테스트(Test)	목적	• 프로토타입을 사용자가 테스트하고 피드백을 받아 솔루션을 개선
	활동	• 사용자에게 프로토입을 제공하고 실제 사용 상황에서 평가 • 사용자 피드백을 통해 디자인과 기능을 수정 및 보완

1.4 챗봇 개발을 위한 디자인씽킹 예시 (1/3)

챗봇 개발을 위한 디지인씽킹에 대한 예시 프로세스

Step 1

공감단계 ▸▸▸

고객 인터뷰

- 현재 고객 서비스 경험 관점
- 불편사항, 기대사항 파악
- 예상질문 예시
  - “ 고객상담에서 가장 불편했던 경험은 무엇인가요?

고객 여정 매핑

- 고객의 상담 경험 전체 과정 시각화
- 접점별 감정, 니즈, 기대사항 분석

Step 2

문제 정의단계 ▸▸▸

주요 분석 내용

- 현재 고객 상담의 주요 문제점 도출
- 반복적으로 발생하는 고객문의유형
- 챗봇을 통해 해결가능한 영역 식별

문제 정의 접근 방법

- 고객불만 데이터 분석
- 상담원 인터뷰
- 기존 고객 서비스 프로세스 진단

Step 3

아이디어도출 단계

아이디어 생성 방법

- 브레인스토밍 방법
- 마인드맵 활용

주요 아이디어 도출 방향

- 다국어 지원 기능
- 감정 인식 및 공감 능력
- 개인화된 응대
- 복합 문의 처리 능력
- 학습 및 개선 매커니즘

1.4 챗봇 개발을 위한 디자인씽킹 예시 (2/3)

☑ 챗봇 개발을 위한 디지인씽킹에 대한 예시 프로세스

Step 4

프로토타이핑 단계

1. 기술 아키텍처 설계

- 자연어 처리(NLP) 모델 선택
- 대화관리 시스템 아키텍처
- 머신러닝 모델 학습 인프라
- 데이터 파이프라인 구축

2. 데이터 준비 및 전처리

- 데이터 수집
  - 내부 고객 상담 이력 데이터
  - 공개 대화 데이터셋
- 데이터 전처리
  - 개인정보 익명화
  - 중복, 누락 데이터, 이상값 제거

3. AI모델 선택 및 학습

- 대규모 언어 모델(LLM) 선택
  - GPT 또는 SLLM(llama, gemma 등 선택)
- 모델 학습 접근법
  - 전이학습, 파인튜닝 등

4. 기술 스택 선정

- 개발환경
  - 프로그래밍 언어 : Python
- 프레임워크
  - Tensorflow, Hugging Face Transformers
- 클라우드 인프라 : AWS, Azure 등

5. 대화 시스템 아키텍처 설계

- 의도 분류기
- 개체명 인식
- 대화 상태 관리
- 응답 생성기
- 감정 분석 모듈

1.4 챗봇 개발을 위한 디자인씽킹 예시 (3/3)

☑ 챗봇 개발을 위한 디지인씽킹에 대한 예시 프로세스

Step 5

테스트 단계 ▸▸▸

1. 성능 평가 지표

- 정확도 (Accuracy)
- 오차 (Loss)
- 응답 대기 시간
- 사용자 만족도
- 대화 자연스러움

2. 테스트 방법론

- 기능성 테스트
  - 의도인식 정확도
  - 예외 상황 대응
- 사용성 테스트 : UX 플로우 검증
- 성능 부하 테스트
  - 동시 접속자 처리, 응답속도 등

3. 윤리적 AI 검증

- 답변의 편향성 탐지
- 차별 방지
- 유해 콘텐츠 필터링
- 개인정보 보호

4. 지속적 개선 프레임워크

- 실시간 로그 분석
- 사용자 피드백 수집
- 오류 케이스 학습
- 모델 재훈련 주기 설정

5. 보안 및 개인정보 보호

- 데이터 암호화
- 접근 제어
- 감사 추적
- 규정 준수

2. 기획서 작성 예시

2.1 기획 배경 및 목적

기획 배경

- 현대 비즈니스 환경에서는 고객의 즉각적인 요청에 응답하는 것이 중요합니다. 그러나 상담원 중심의 고객 서비스는 높은 운영 비용과 제한된 응답 시간으로 인해 한계가 존재합니다.
- 최근 인공지능 기술의 발전으로 고객 문의 중 반복적인 작업을 자동화하고, 24시간 운영이 가능한 AI 챗봇 서비스의 필요성이 커지고 있습니다.
- **배경 요약**

- 고객 문의의 40% 이상이 반복적인 질문(Frequently Asked Questions, FAQ)으로 구성
- 고객 대기 시간 감소와 상담원 업무 효율성 향상이 필요
- AI 기술을 활용한 비즈니스 자동화 트렌드

기획 목적

- AI 기반 상담 챗봇을 통해 고객의 반복적인 문의를 자동 처리하고, 상담원의 효율성을 향상시킴으로써 고객 만족도를 높이고 운영 비용을 절감
- **세부 목적**

- **고객 만족도 향상**: 실시간 응답과 신속한 문제 해결 제공
- **업무 효율성 개선**: 상담원이 고부가가치 업무에 집중할 수 있도록 지원
- **운영 비용 절감**: 상담 인력 의존도를 줄이고 24시간 서비스 제공

2. 기획서 작성 예시

2.2 기대 효과

비즈니스 성과 향상

- 반복 문의 자동 처리로 상담 업무량 30% 이상 감소
- 24시간 무중단 운영으로 고객 이탈률 감소

고객 경험 개선

- 고객 대기 시간 50% 단축
- 정확한 응답과 개인화된 추천 서비스 제공

비용 절감

- 신규 상담 인력 채용 및 교육 비용 절감
- AI기술로 업무 프로세스 최적화

2.3 주요 기능

주요 기능	설명
반복 질문 응답 (FAQ 자동화)	• 배송 조회, 환불 절차 안내 등 자주 묻는 질문 자동 응답
주문 정보 조회	• 고객 주문 번호 입력 시 실시간 배송 상태 제공
사용자 맞춤형 추천	• 고객 문의 기록 분석을 통한 맞춤형 상품/서비스 추천
24시간 운영	• 상담원이 없는 시간에도 실시간 응답 가능
상담원 연결 지원	• 복잡한 문의는 AI가 상담원에게 자동 전달
기타	• 음성 지원 챗봇(옵션), 다국어 지원(한국어, 영어, 일본어, 중국어 등)

2.4 기획 일정

날짜	단계	주요 활동	결과물
Day 1	**공감(Empathize)**	• 고객 및 상담원 인터뷰 • 기존 상담 데이터 분석 • 주요 문제 정의	고객 니즈와 문제 리스트 작성
Day 2	**문제 정의(Define)**	• 사용자 페르소나 작성 • 문제 진술문 작성	사용자 페르소나, 문제 진술물 작성
Day 3	**아이디어 도출 (Ideate)**	• 브레인스토밍 진행 • 주요 아이디어 선정	주요 기능 리스트, 선정된 아이디어
Day 4	**프로토타입 (Prototype)**	• 챗봇 대화 흐름 설계 • 간단한 프로토타입 제작(Figma 등)	대화 흐름 설계안, 프로토타입
Day 5	**테스트(Test)**	• 프로토타입 사용자 테스트 • 피드백 수집 및 개선	테스트 결과, 개선안
Day 6	**기획서 작성**	• 최종 결과물 정리 • 서비스 기획서 작성	최종 서비스 기획서 초안
Day 7	**발표 및 확정**	• 최종 기획 발표 • 이해 관계자의 피드백 반영 • 기획서 확정	확정된 서비스 기획서

2. 기획서 작성 예시

2.5 기타 : 대화 흐름 설계

챗봇의 기본 구조

- 초기 메시지 : 사용자 접속 시 챗봇이 먼저 인사
- 옵션 제공 : 사용자가 선택할 수 있는 주요 기능 제공
- 사용자 요청 처리 : 사용자의 입력에 따라 해당 작업 수행

대화 흐름 다이어그램

- 사용자 접속
- 챗봇 인사 및 메뉴 제공
  - "안녕하세요! 고객 상담 챗봇입니다. 무엇을 도와드릴까요?"
  - 메뉴 : 1. 배송 조회, 2. 환불 요청, 3. 상담원 연결
- 1번 선택 시 (배송 조회)
  - "주문 번호를 입력해 주세요."
  - 사용자 입력 → 주문번호 확인
  - "주문번호 "123456"의 상태는 '배송중' 입니다. 예상 도착일은 12월 1일 입니다. →" 더 도움이 필요하시면 '처음으로 돌아가기'를 선택해주세요"
- 2번 선택 시 (환불요청) : 환불 요청 상품명 입력 → 환불처리 가능 여부 확인 → 처음으로 돌아가기
- 3번 선택 시 (상담원 연결)

3. 데이터 수집 및 전처리

3.1 데이터 소스 개요

- 데이터를 수집하려면 신뢰할 수 있는 데이터 소스를 선정하는 것이 중요
- 데이터 소스를 수집할 수 있는 주요 플랫폼은 Kaggle, AI Hub, 공공데이터 포털이 있음

특징	사이트 주소	설명
Kaggle	https://www.kaggle.com	• 세계적인 데이터 과학 플랫폼으로, 다양한 데이터셋 제공 • 데이터 분석, 머신러닝, 시각화 등 다양한 문제해결을 위한 데이터셋 이용 가능 • 주요 특징 : 커뮤니티 기반, 코드 공유 가능, 대회참여 가능
AI Hub	https://www.aihub.or.kr	• 한국정보화진흥원(NIA)에서 운영하는 인공지능 데이터 허브 • AI 학습을 위해 무료로 사용할 수 있는 고품질 데이터셋 제공 • 주요 데이터 유형 : 자연어 처리, 컴퓨터 비전, 음성 인식, 의료 데이터 등
공공데이터 포털	https://www.data.go.kr	• 대한민국 정부가 운영하는 공공 데이터 플랫폼 • 행정, 교육, 의료, 교통 등 다양한 공공 데이터 제공 • API 또는 파일 형태로 데이터 다운로드 가능
기타	기타 데이터 소스	• Google Dataset Search : 다양한 공개 데이터셋 검색 • Amazon AWS Open Data Registry : 대규모 데이터 분석 및 클라우드 기반 데이터셋

3.2 데이터 수집 계획 및 방법론

- 데이터 수집에는 수집되는 데이터의 품질과 신뢰성을 보장하여 분석의 정확성을 높이는 것이 중요
- 데이터 수집에 소요되는 비용과 자원을 효율적으로 관리하고 최적화

데이터 수집 절차

- **목적 정의** : 분석 또는 모델링 목표에 따라 필요한 데이터 유형 정의
- **데이터 소스 탐색** : Kaggl, AI Hub 등에서 데이터 검색 및 비교
- **데이터 다운로드 및 API 사용** : 파일다운로드 또는 API 호출로 데이터 수집
- **데이터 검증** : 데이터 품질과 적합성 확인(누락값, 불균형, 이상치)

수집 방법론

- **스크래핑(Web Scraping)** : BeautifulSoup, Selenium을 활용해 웹에서 데이터 추출
- **API 호출** : REST API 등을 통해 실시간 또는 배치 데이터 수집
- **데이터 파이프라인** : 자동화된 데이터 수집과 처리를 위해 Airflow, Prefect 같은 도구 사용

주의사항

- 데이터 라이선스 확인(저작권 및 사용 제한 준수)
- 개인 정보 보호 규정 준수
- 데이터의 최신성과 신뢰성 확인

3.3 학습용 데이터 구축 과정 (1/2)

- 인공지능 학습용 데이터 구축과정에서 확보된 데이터 품질이 학습데이터 전체의 품질을 결정
- 데이터 구축 시 수행되는 구축공정에 따라서 구축계획 수립, 데이터 획득/수집, 데이터 정제, 데이터 가공, 데이터 학습순으로 진행

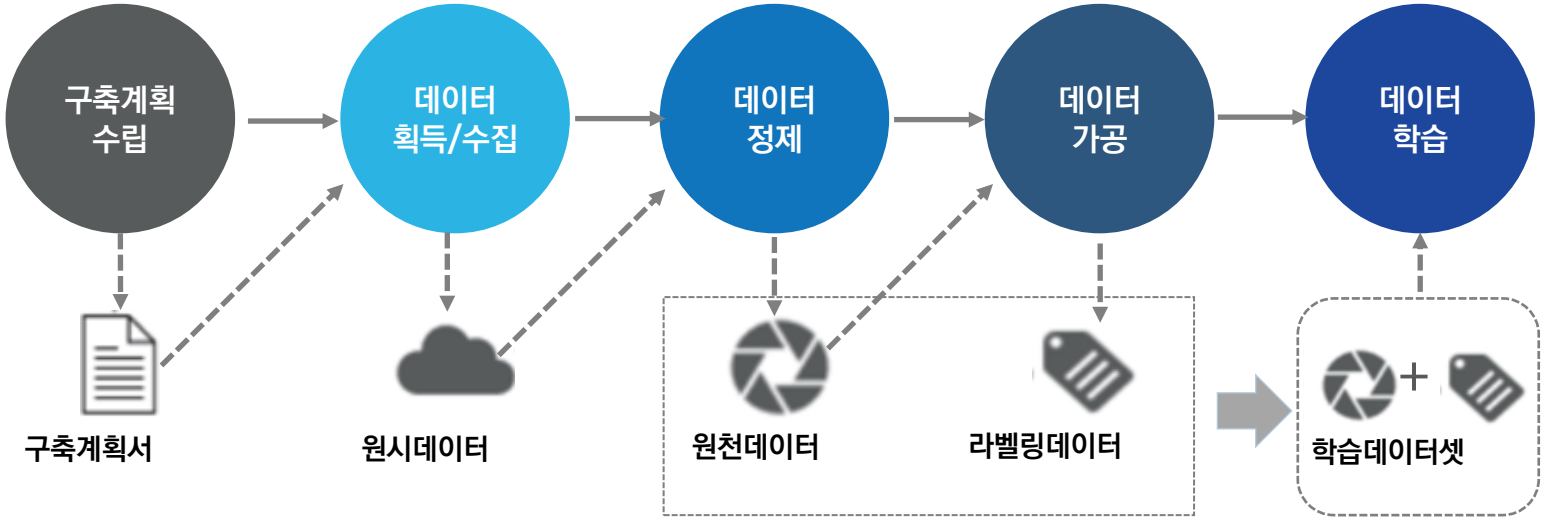

3.3 학습용 데이터 구축 과정 (2/2)

단계	내 용	산출물/데이터
구축계획 수립	• 인공지능이 기계학습을 통해 해결하고자 하는 문제를 명확하게 정의하고 문제 해결에 필요한 인공지능 학습용 데이터를 구체적으로 정의하고 설계하는 활동	구축계획서
데이터 획득/수집	• 보유하고 있는 조직이나 시스템 등으로부터 인공지능 학습에 필요한 데이터를 확보하는 등 원시데이터를 확보하는 활동	기상, 유량, 수질데이터
데이터 정제	• 획득한 원시데이터를 기계학습에 필요한 형식이나 크기로 맞추고 데이터 중복 제거 • 이 단계에서 확보된 원천데이터는 라벨링이 부여되지 않은 상태의 데이터를 의미	원천데이터 (ph, DO, BOD, TOC, SS, TN, TP 등 센서에서 측정된 데이터)
데이터 가공	• 인공지능이 기계학습에 활용될 수 있도록 기능이나 목적에 부합하는 라벨을 원천데이터에 부착하는 라벨링 작업 수행 • 여기서 생성된 라벨링 데이터는 원천데이터에 부여한 파일형식, 해상도 등의 데이터 속성과 설명, 주석 등이 포함된 집합을 의미	라벨링데이터 (수질등급, 오염발생여부, 법적기준적합도 등 출력목표값 포함)
데이터 학습	• 학습데이터셋을 이용하여 사전에 정의된 인공지능 알고리즘을 학습시키고, 학습된 인공지능 모델의 성능을 향상시키거나 보정하는 활동 수행 • 학습데이터셋은 원천데이터와 라벨링데이터의 묶음을 의미	학습용데이터

3.4 탐색적 데이터 분석 ▶ 3.4.1 데이터 전처리

- 데이터 전처리를 위해 탐삭적 데이터 분석(Explorative Data Analysis, EDA) 도구를 활용
- EDA 도구는 데이터의 구조패턴, 이상치, 결측치, 중복값을 파악하고 전처리를 수행하는데 보조적인 역할을 함

전처리 기술		내용	사용 예시
데이터 변환	평활화	• 다양한 형식으로 수집된 데이터를 분석에 용이하도록 일관성 있는 형식으로 변환	
	정규화	• 데이터에 대한 최소-최대 정규화, Z-Score 정규화, 소수스케일링 등 통계적 기법 적용	StandardScaler (평균0, 표준편차1)
	일반화	• 특정구간에 분포하는 값으로 스케일을 변화	
데이터 정제	결측값 처리	• 통계값 적용 : 평균값, 중앙값, 같은 클래스 값의 평균값 등 • 추정치 적용 : 베이지안 확률, 결정트리 • 모든 값을 '0'으로 적용 • 삭제 : 결측값이 발생한 모든 관측치를 삭제	통계값 적용
	이상값 처리	• 단순삭제 : 이상값이 Human error에 의해서 발생한 경우에는 해당 관측치를 삭제 (ex. 단순오타, 데이터 처리과정 오류 등) • 통계값 적용 : 다른값(평균, 중앙값 등)으로 대체	통계값 적용
데이터 통합 및 축소	데이터 통합	• 출처가 다른 상호 연관성이 있는 데이터들을 하나로 결합 • 데이터 통합 시 동일한 데이터가 입력될 수 있으므로 연관관계 분석 등을 통해 중복 데이터를 검출	
	데이터 축소	• 분석에 불필요한 데이터를 축소하여 고유한 특성은 손상되지 않도록 하고 분석에 대한 효율성을 증대	

3.4 탐색적 데이터 분석 ▶ 3.4.2 탐색적 데이터 분석(EDA) 정의

탐색적 데이터 분석 정의

수치 요약과 시각화를 사용하여 **데이터를 탐색**하고 **변수 간 패턴, 상관 관계**를 찾아내며 **변수 주요 특성과 결측치/이상치를 식별**하는데 사용

1 데이터 탐색

- EDA는 데이터를 시각적이고 통계적으로 탐색하여 패턴, 추이, 이상치를 식별하는 과정

2 시각화

- EDA에서는 다양한 시각화 기법을 활용하여 데이터의 패턴을 쉽게 파악 가능
- 히스토그램, 산점도 등을 이용하여 데이터의 분포, 중심 경향성, 이상치를 시각적으로 확인하고, 이를 통해 데이터 특성 파악 용이

3 가설 설정 및 검증

- 데이터를 분석하면서 도출된 패턴이나 관찰을 토대로 가설 수립 및 검증
- 데이터의 실제 특성을 깊이 이해하고, 후속 분석 및 모델링 방향 설정

3.4 탐색적 데이터 분석 ▶ 3.4.3 탐색적 데이터 상관분석

수질데이터

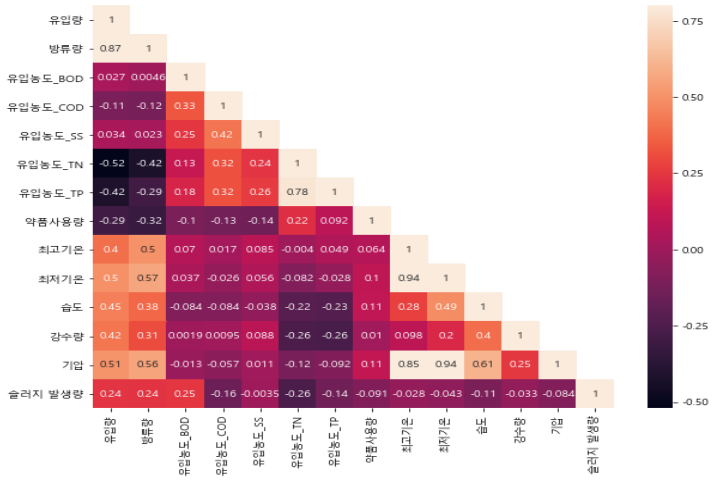

상관관계 분석 예시

- EDA 히스토그램, 히트맵 변수별 분포를 통해 정규분포 여부, 데이터 변환(ex. 로그변환) 필요성 및 변수 간 관계를 유추
- 수질 예측 모델링을 위한 대상 설정 : 전력량, 약품사용량
- 전력량, 약품사용량에 영향을 미치는 요인 분석
  - 수질변수 : BOD, TOC, TN, TP, SS 등
  - 운영변수 : 처리공정, 슬러지처리방법 등
  - 환경변수 : 강수량, 기온, 계절 등

결측치 및 중복값 통계

Overview | Alerts 23 | Reproduction

Dataset statistics

Number of variables	25
Number of observations	365
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	1
Duplicate rows (%)	0.3%
Total size in memory	71.4 KiB
Average record size in memory	200.4 B

변수별 데이터분포(Histogram)

유입수BOD

Real number (ℝ)

HIGH CORRELATION

Distinct	271	Minimum	4.4
Distinct (%)	74.2%	Maximum	511
Missing	0	Zeros	0
Missing (%)	0.0%	Zeros (%)	0.0%
Infinite	0	Negative	0
Infinite (%)	0.0%	Negative (%)	0.0%
Mean	235.92548	Memory size	3.0 KiB

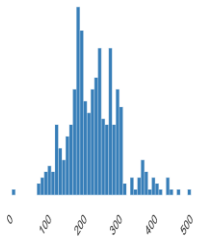

3.4 탐색적 데이터 분석 ▶ 3.4.4 EDA 라이브러리 설치 및 예시 (1/2)

설치방법

- pip를 사용한 설치 : pip install ydata-profiling, pip install pandas
- 데이터 소스 불러오기 : 실행 파일과 같은 위치에 있는 dataset 폴더 생성하여 불러오고자 하는 파일 저장

사용법

- 데이터 소스 불러오기 : 실행 파일과 같은 위치에 있는 **dataset 폴더 생성**하여 불러오고자 하는 파일 저장
- 실행 파일과 같은 위치에 EDA 생성된 리포트 저장을 위한 **report 폴더 생성** → EDA 보고서가 자동 저장

```
import pandas as pd
from ydata_profiling import ProfileReport

# 데이터 불러오기
df = pd.read_csv('./dataset/data.csv')

# 프로파일링 리포트 생성
profile = ProfileReport(df, title="EDA Report", explorative=True)

# 리포트 저장 및 출력
profile.to_file("./report/eda_report.html")
profile.to_notebook_iframe()
```

3.4 탐색적 데이터 분석 ▶ 3.4.4 EDA 라이브러리 설치 및 예시 (2/2)

EDA의 기본 구조

1. 파일 로드

- 데이터 파일을 불러올 때 padas.read_csv()를 사용
- 인코딩 옵션 :'utf-8', 여기서는 'cp949' 사용

2. 데이터 탐색

- 기본 확인 : df.head()로 데이터의 일부를 출력 확인
- 결측값 탐색 : df.isnull().sum()로 결측값 확인
- 데이터양 많을 때 : 무작위 샘플링 ex. df.sample(n=2000)

3. 프로파일링 리포트 생성

- ProfileReport()를 통해 데이터 탐색 리포트 생성
- 옵션 : title(리포트 제목), explorative=True(확장된 분석 기능 활성화)

4. 리포트 저장 및 시각화

- HTML 파일로 저장 : profile.to_file()로 리포트를 저장

EDA 예제

```
import pandas as pd
from ydata_profiling import ProfileReport

# 파일 로드
df = pd.read_csv('data.csv', encoding='cp949')

# 데이터 확인
print(df.head())

# 프로파일링 리포트 생성
profile = ProfileReport(df, title="EDA Report",
explorative=True)

# 리포트 저장 및 출력
profile.to_file("eda_report.html")
```

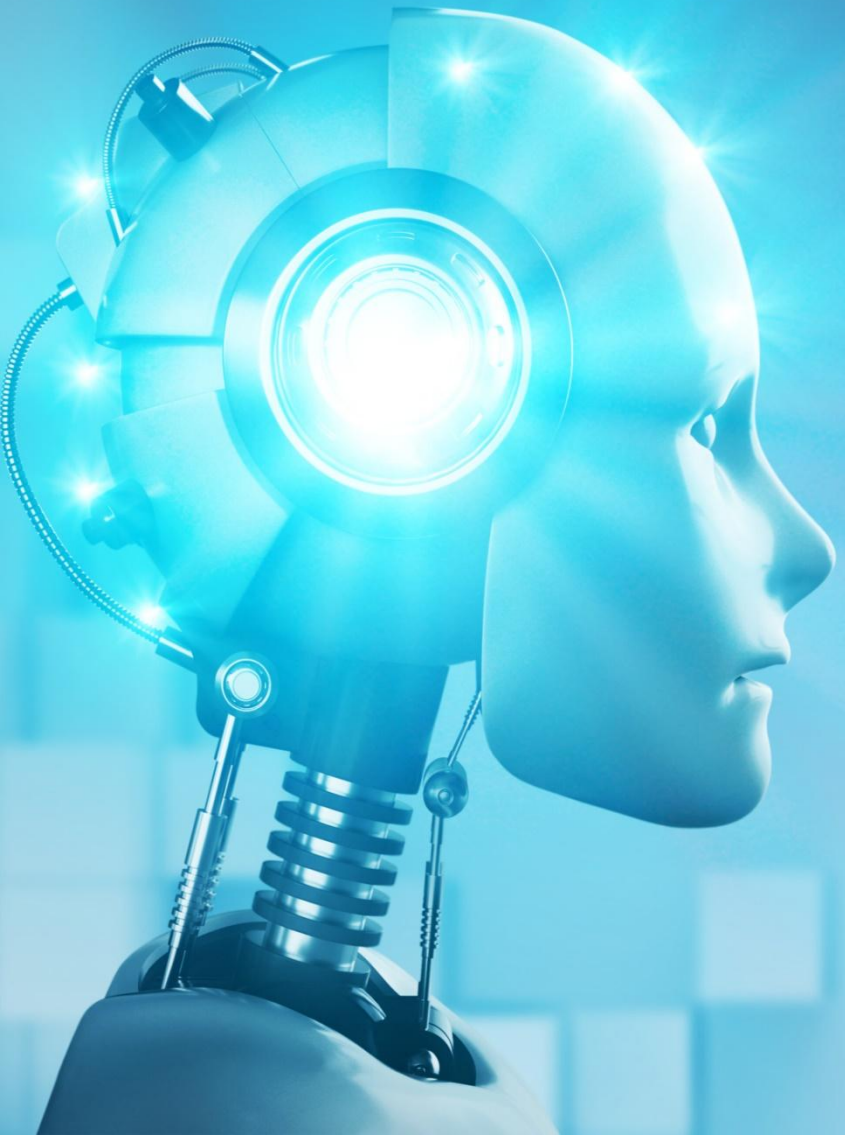

1 프로젝트 설계

1. 프로젝트 세부 설계
2. 준비사항 및 도구
3. 예상 리스크 및 대응방안

1. 프로젝트 세부 설계

1.1 프로젝트 목표 및 문제 정의

- 비즈니스적 가치와 기술적 실현 가능성을 고려하여, 실제 문제를 해결할 수 있는 명확하고 측정가능한 목표를 설정하는 과정
- 문제의 성격, 데이터 특성, 예상되는 성과, 전략적 목표를 종합적을 분석하여 최적의 머신러닝/딥러닝 접근 방법을 선택

구분	내용	예시
문제 정의	**해결하려는 문제를 명확하게 기술**	• 주어진 시계열 데이터를 바탕으로 전력 수요를 예측 • 고객 리뷰 텍스트 데이터를 활용하여 긍정/부정 감정을 분류 • 이미지 데이터를 활용하여 결함을 자동으로 검출
목표 설정	**프로젝트의 최종 성과를 수치화**	• 모델의 RMSE를 10 이하로 달성한다. • 분류 정확도를 95% 이상으로 도달한다. • 데이터 처리 및 예측 시간을 30% 단축한다.
제약 사항	**프로젝트에서 고려할 제약 조건 사전 확인**	• 하드웨어 및 소프트웨어 제약(예 : CPU, GPU 환경) • 데이터 양 및 품질 제한 • 프로젝트 기한 및 예산 제한

1.2 프로젝트 범위 (1/2)

- 프로젝트 범위를 통해 한정된 자원과 시간 내에서 머신러싱/딥러닝 프로젝트의 명확한 경계를 정립하고 불필요한 내용 제거
- 핵심목표 달성을 위한 체계적이고 집중적인 접근을 하기위함

단계	목적	세부활동
데이터 준비	고품질의 신뢰할 수 있는 데이터셋 확보	• 데이터 소스 식별 및 수집 • 데이터 전처리 • 결측값 처리 • 이상치 제거 • 피처 엔지니어링(ex. 스케일링, 정규화)
모델 구축	문제에 최적화된 머신러닝/딥러닝 모델 설계	• 문제 유형에 적합한 알고리즘 선택 • 모델 아키텍처 설계 • 하이퍼파라미터 초기 설정 • 베이스라인 모델 개발 • 모델 복잡도 조정 • 전이학습/앙상블 기법 고려
모델 평가	모델의 성능과 일반화 능력 검증	• 다양한 성능 메트릭 측정 • 교차 검증 • 과적합/과소적합 진단 • 학습 곡선 분석

1.2 프로젝트 범위 (2/2)

단계	목적	세부활동
결과 분석	**모델 성능의 심층적 이해와 인사이트 도출**	• 모델 예측 오류 분석 • 피처 중요도 평가 • 모델 해석도구 활용(SHAP, LIME) • 비즈니스 관점 성과 분석 • 모델 결정의 편향성 검토 • 실무적 활용 가능성 평가
향후 개선 사항 도출	**모델의 지속적인 성능 개선 전략 수립**	• 모델 성능 bottleneck 식별 • 추가 데이터 수집 전략 • 하이퍼파라미터 최적화 계획 • 모델 아키텍처 개선방향성 설정 • 새로운 피처 발굴 • 모델 재훈련 주기 설정 • 최신 알고리즘/기법 적용 가능성 탐색

1.3 프로젝트 팀 및 역할 분담 (현업 종사자 기준)

- 프로젝트의 복잡성을 효과적으로 관리하고, 각 팀원의 전문성을 최대한 활용하여 프로젝트의 성공가능성을 높이기 위함
- **다양한 관점에서 문제를 접근**하고 **협업을 통해 더나은 솔루션을 창출**하기 위함

구분	주요 역할
프로젝트 리더	• 전체 프로젝트 기획 및 방향성 설정 • 프로젝트 일정 및 리소스 관리 • 팀 협업 조율, 최종 결과물 통합 및 발표
AI/ML 엔지니어	• 학습된 모델을 실서비스에 배포, 성능 모니터링 및 지속 개선(MLOps 포함)
데이터 사이언티스트	• 머신러닝, 딥러닝을 활용한 예측 모델 개발, 비즈니스 의사결정 지원
데이터 애널리스트	• 데이터 시각화 및 리포트, 데이터 분석을 통한 인사이트 전달 • Tableau, Power BI, Superset 등 BI(Business Intelligence) 도구 활용
AI 프로덕트 매너저	• AI 서비스 기획, AI모델을 실제 서비스로 전환하는 전략 및 기능 기획
ML/DL 연구원	• 고급 알고리즘 연구 및 실험 • 모델 성능 최적화
프롬프트 엔지니어	• LLM의 성능을 극대화하기 위해 효과적인 입력전략을 개발하고 검증, 모델 활용의 정확도와 효율성 향상

1.4 프로젝트 일정계획

☑ 프로젝트의 성공적인 구축을 위하여 세부적인 일정계획을 수립하여 단계별로 달성해 나가는 것이 필요

단계	세부 활동
문제 정의 및 목표 설정	• 문제 정의, 목표 수립, 데이터 확보 계획
데이터 준비	• 데이터 수집, 전처리, 탐색적 데이터 분석(EDA)
모델 개발 및 학습	• 모델 선정, 학습, 하이퍼파라미터 튜닝
모델 평가 및 검증	• 모델 성능 평가, 비교 및 분석
결과 분석 및 결론 도출	• 결과 시각화, 보고서 작성, 개선 사항 도출

2. 준비사항 및 도구

하드웨어 요구사항

- CPU/GPU 사양 (예:NVIDIA RTX 3090, Intel i9 등)
- 메모리 (RAM) : 최소 16GB 이상

소프트웨어 및 라이브러리

- 개발 환경 : Python (Jupyter Notebook), 비주얼스튜디오코드(VSCODE)
- 주요 라이브러리 : 데이터분석(pandas, numpy), 데이터 시각화(matplotlib, seaborn), 머신러닝(scikit-learn, XGBoost), 딥러닝(Tensorflow), 시계열분석(statsmodel, Prophet)

데이터 관리 도구

- 데이터베이스 : :MySQL, MariaDB, Oracle
- 버전 관리 : GitHub, GitLab
- 협업 도구 : Notion, Slack

3. 예상 리스크 및 대응방안

리스크	발생 원인	대응 방안
데이터 부족 및 품질저하	**데이터 수집이 제한적이거나 불완전함**	• 외부 데이터셋 확보, 데이터 증강기법 활용
모델 학습 시간 지연	**데이터 양이 많거나 모델이 복잡함**	• 하드웨어 업그레이드, 데이터 샘플링
모델 성능이 기대 이하임	**데이터 불균형, 하이퍼파라미터 최적화 실패**	• 데이터 리샘플링
일정 지연	**예상보다 많은 시간 소요**	• 주간/월간 일정 점검 및 우선순위 조정

카디널리티(Cardinality)

- 카디널리티 : 데이터베이스의 ERD에서 엔티티 간의 관계를 정의하는 개념으로 두 엔티티가 어떻게 연결되었는지 나타냄

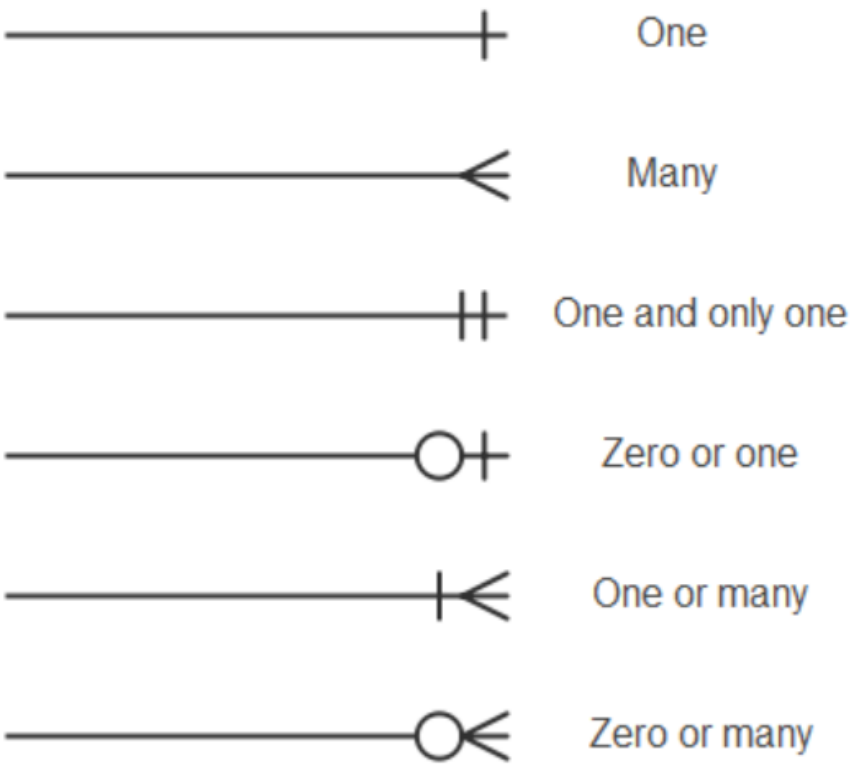

식별자 및 비식별자

식별자(Identifying Relationship), 기호 ———————

- 식별자 관계는 자식 테이블이 부모 테이블의 기본 키를 반드시 포함해야 함

- `ORDER` 테이블 (부모)
  - `주문번호 (order_id)` **PK**
  - `고객명 (customer_name)`
  - `주문일자 (order_date)`
- `ORDER_DETAIL` 테이블 (자식)
  - `주문번호 (order_id)` **PK + FK**
  - `상품번호 (product_id)` **PK**
  - `수량 (quantity)`

비식별자(Non-Identifying Relationship) -

- 비식별자는 부모 테이블의 기본 키가 자식 테이블의 외래키(Foreign Key)로 연결되는 관계임
- 자식 엔티티티는 부모 엔티티 없이도 존재할 수 있음, 자식 테이블의 독립성이 보장됨

- `DEPARTMENT` 테이블 (부모)
  - `학과코드 (dept_id)` **PK**
  - `학과명 (dept_name)`
- `STUDENT` 테이블 (자식)
  - `학번 (student_id)` **PK**
  - `학생이름 (student_name)`
  - `학과코드 (dept_id)` **FK**

정규화 ▶ 1차 정규화

1차 정규화 (1NF)

- 1차 정규화는 하나의 속성에 여러 개의 값이 들어갈 수 없도록 분해하는 과정
- 릴레이션의 모든 속성 값이 원자값을 갖도록 하는 것

1차 정규화 위반 예시

- 상품명, 수량, 배송지 속성에 여러 개의 값이 저장되어 있음
- 문제점 : 특정 상품을 주문한 고객을 찾거나 특정 배송지로 배송된 주문을 검색하기 어려움

주문 ID	고객 ID	상품명	수량	배송지
1	101	노트북, 마우스	1, 2	서울, 경기
2	102	키보드	1	부산

정규화 ▶ 2차 정규화

2차 정규화 (2NF)

- 2차 정규화는 기본 키의 부분이 아닌 모든 속성이 기본 키에 완전 종속되도록 하는 것
- 예를들어 복합키에서, 복합키의 일부 키에 종속되어 결정되는 속성이 있다면 별도로 분리해야 함

2차 정규화 위반 예시

- 여기서 복합키는 주문ID, 상품ID 기본키로 이루어지는데, 상품명과 가격은 상품ID에만 종속되어 있음
- 즉, 주문 ID는 상품명과 가격을 결정하는데 필요하지 않음

주문 ID	상품 ID	상품명	주문 수량	가격
1	101	노트북	1	150만원
1	102	마우스	2	3만원
2	101	노트북	1	150만원
3	103	키보드	1	5만원

주문 ID	상품 ID	주문 수량
1	101	1
1	102	2
2	101	1
3	103	1

상품 ID	상품명	가격
101	노트북	150만원
102	마우스	3만원
103	키보드	5만원

정규화 ▶ 3차 정규화

3차 정규화 (3NF)

- 3차 정규화는 2차 정규화를 만족하면서 기본 키가 아닌 속성이 기본 키에만 직접적으로 의존해야 함

3차 정규화 위반 예시

- 여기서 학과이름은 학과 코드를 통해 결정되어 3차 정규화 위반됨

학번	학생 이름	학과 코드	학과 이름
1001	김철수	CS01	컴퓨터공학과
1002	이영희	EE01	전자공학과
1003	박민준	CS01	컴퓨터공학과

학번	학생 이름	학과 코드
1001	김철수	CS01
1002	이영희	EE01
1003	박민준	CS01

학과 코드	학과 이름
CS01	컴퓨터공학과
EE01	전자공학과

정규화 ▶ 4차 정규화

4차 정규화 (4NF)

- 4차 정규화는 한 개의 키에 대해 여러 개의 값이 독립적으로 존재하는 경우 발생

4차 정규화 위반 예시

- 한 한생이 여러 개의 전화번호를 가질 수 있고, 동시에 여러 동아리에 가입할 수 있는 문제 발생
- 학번 하나로 인해 불필요한 중복 데이터가 발생

학번	학생 이름	전화번호	동아리
1001	김철수	010-1234-5678	축구부
1001	김철수	010-1234-5678	독서회
1001	김철수	010-8765-4321	축구부
1001	김철수	010-8765-4321	독서회
1002	이영희	010-2222-3333	농구부

학번	학생 이름	전화번호
1001	김철수	010-1234-5678
1001	김철수	010-8765-4321
1002	이영희	010-2222-3333

학번	학생 이름	동아리
1001	김철수	축구부
1001	김철수	독서회
1002	이영희	농구부

ERD ▶ 논리적 ERD 예시

논리적 ERD

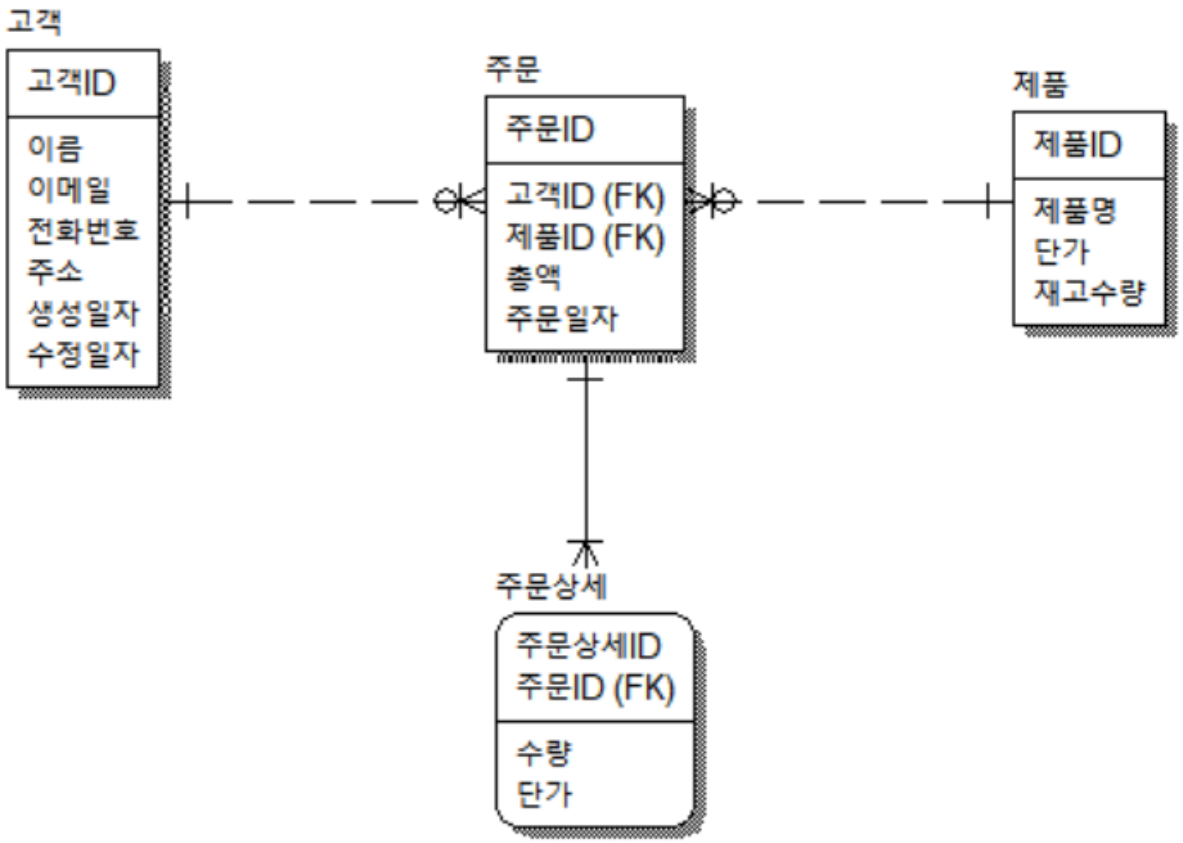

ERD ▶ 물리적 ERD 예시
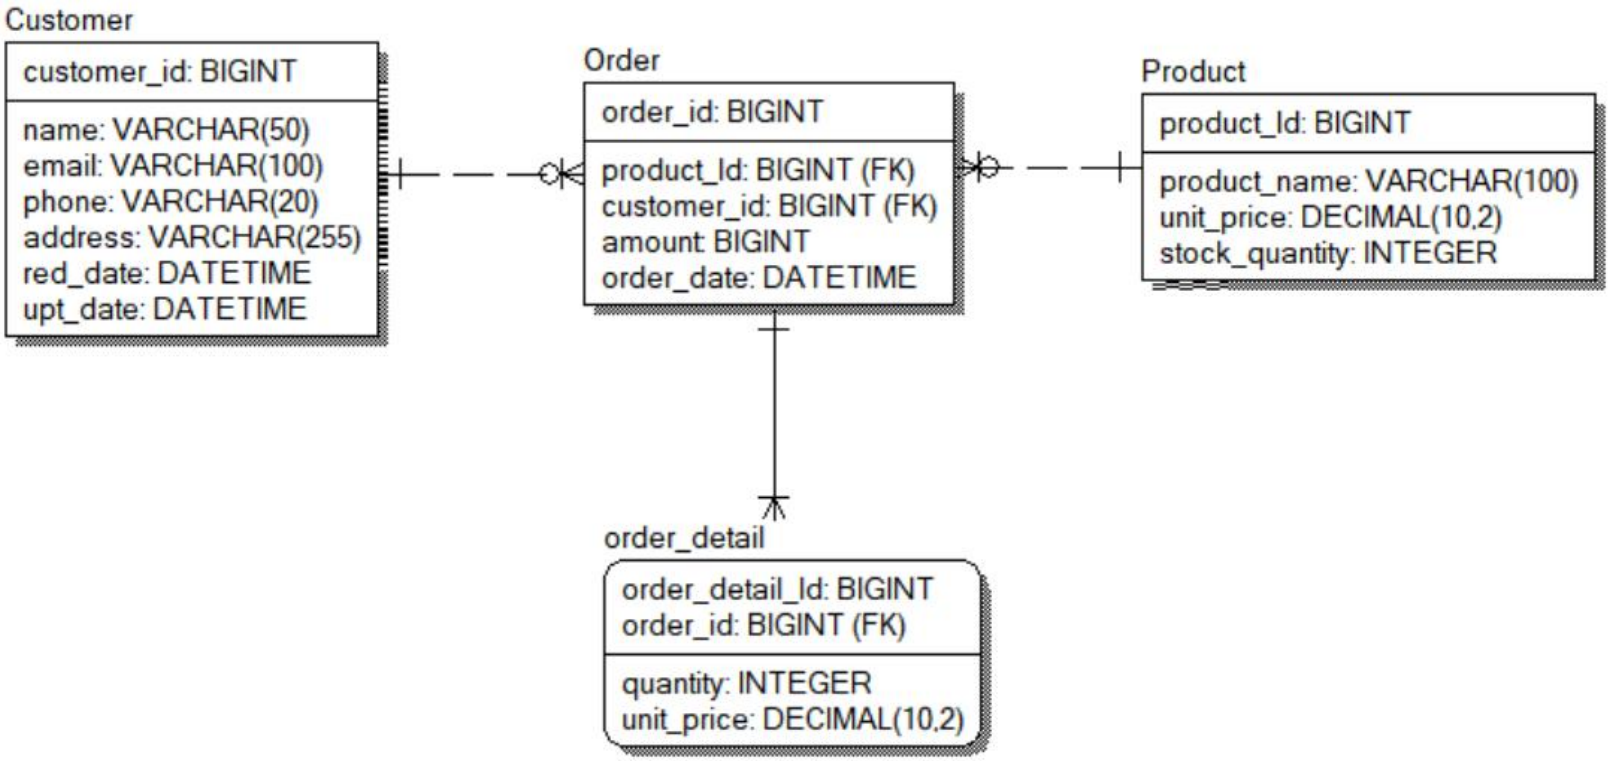
물리적 ERD