

2026년도 머신러닝 프로젝트
AI개발 수행내역서

과제명	AI기반 중고차 가격 예측 모델 개발
담당자	손OO

2025년 04 월 03 일

AI개발 수행내용

<사업과제 : AI기반 중고차 가격 예측 모델 개발>

1. 개요 및 현황

1.1 추진배경 및 목적

- 중고차 가격은 연식, 주행거리, 브랜드, 연료 타입, 변속기, 소유주 이력, 차량 성능 등 다양한 요소의 영향을 받아 결정되며, 적정 가격 산정은 거래 과정에서 중요한 의사결정 요소로 작용
- 실제 중고차 시장에서는 동일 브랜드 내에서도 모델, 연식, 주행거리 등에 따라 가격 차이가 발생하여 객관적인 판단이 어려운 경우가 많음
- 이에 따라 차량 거래 데이터를 기반으로 중고차 가격을 예측할 수 있는 인공지능 기반 모델의 활용 가능성과 수요가 점차 높아짐
- 본 과제에서는 중고차 상세 정보를 활용한 가격 예측 모델을 구현 및 데이터 기반 가격 예측을 검토

1.2 과제 범위

과제구분		내용
AI	AI 기반 중고차 가격 예측 모델 구현	원시 데이터 수집 및 데이터셋 구축
		데이터 전처리, 표준화, 상관관계 분석 (EDA도구 활용)
		예측모델 선정 및 학습
		RMSE, MAE 등 평가지표를 활용한 모델 성능 평가
		웹 API 및 프로토타입 구축
		예측모델 웹기반 시스템 구축
		테스트
시각화	중고 차량 특징 입력 및 가격 예측 시각화	사용자 입력 구현
		MSE, RMSE, R^2 기반 성능 평가
		예측 결과 기반 원화 환산값 제공
		테스트

1.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 접근성 및 활용성

- 공개 데이터 셋을 활용할 수 있어 데이터 수집 및 관리가 용이한 구조인지 여부
- 중고차 가격 예측에 영향을 미치는 다양한 독립변수에 대한 정보가 포함되어 있어 모델 학습에 적합한 지 여부
- 차량 가격, 주행거리, 연식, 연료, 변속기, 소유주 이력, 차량 성능 등 가격 예측에 필요한 핵심 변수가 포함되어 있는 지 여부

○ 예측모델 개발 효율성

- 회귀 기반 예측 문제로 정의가 가능 및 모델 학습 및 평가 과정이 비교적 명확한 구조인지 여부
- 수치형 변수와 범주형 변수가 함께 포함되어 있어 전처리, 인코딩, 회귀 모델링 전반을 실습하기에 적합한 지 여부
- 개발된 모델을 프로토타입 화면과 연계하여 실제 예측 흐름까지 확인할 수 있는 지 여부


○ 기여도 및 경제성

- 예측모델을 통해 중고차 적정 가격 산정에 대한 참고자료로 활용 가능한 지 여부
- 향후 브랜드/모델 정보 고도화, 추가 모델 비교, 하이퍼파라미터 튜닝 등을 통해 성능 개선이 가능한 지 여부
- 자산평가, 중고거래, 이커머스 가격 예측 등 유사 도메인으로 확장 적용 가능한 지 여부

2) AI 예측 분석모델 적용 대상

기능	수집 데이터	예측모델인자 (독립변수)	AI예측 분석 대상
중고차 가격 예측	- 중고차 거래/매물 정보 데이터 - 차량명, 연식, 판매가격, 주행거리, 연료 타입, 판매자 유형, 변속기, 소유주 이력 등이 포함된 데이터셋 - 연비, 배기량, 최대출력, 토크, 좌석 수 등 차량 성능 및 제원 정보 포함	- 기본정보 : 연식, 주행거리, 좌석 수 - 성능정보 : 연비, 배기량, 최대출력 - 이력정보 : 판매자 유형, 변속기, 소유주 이력 - 분류 및 파생정보 : 브랜드명_차량명, car_age	- 중고차 판매가격 예측 - 차량 특성별 가격 결정 요인 분석 - 사용자 입력 기반 예측 결과 제공 및 프로토타입 화면 구현

3) AI 분석모델 구축 프로세스



연구개발 주요 결과물

1. 데이터 수집 (출처 및 구성)

1.1 데이터 출처

- Kaggle 공개 데이터셋 Car Details v3
- <https://www.kaggle.com/datasets/nehalbirla/vehicle-dataset-from-cardekho/>

1.2 데이터 구성 및 변수 구성

- 데이터 셋은 8128개의 Row와 13개의 Column으로 구성

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	name	year	selling_price	km_driven	fuel	seller_type	transmission	owner	mileage	engine	max_power	torque	seats
2	Maruti Swift Dzire VDI	2014	450000	145500	Diesel	Individual	Manual	First Owner	23.4 kmpl	1248 CC	74 bhp	190Nm@ 2000rpm	5
3	Skoda Rapid 1.5 TDI Ambition	2014	370000	120000	Diesel	Individual	Manual	Second Owner	21.14 kmpl	1498 CC	103.52 bhp	250Nm@ 1500-2500rpm	5
4	Honda City 2017-2020 EXi	2006	158000	140000	Petrol	Individual	Manual	Third Owner	17.7 kmpl	1497 CC	78 bhp	12.7@ 2,700(kgm@ rpm)	5
5	Hyundai i20 Sportz Diesel	2010	225000	127000	Diesel	Individual	Manual	First Owner	23.0 kmpl	1396 CC	90 bhp	22.4 kgm at 1750-2750rpm	5
6	Maruti Swift VXI BSIII	2007	130000	120000	Petrol	Individual	Manual	First Owner	16.1 kmpl	1298 CC	88.2 bhp	11.5@ 4,500(kgm@ rpm)	5
7	Hyundai Xcent 1.2 VTVT E Plus	2017	440000	45000	Petrol	Individual	Manual	First Owner	20.14 kmpl	1197 CC	81.86 bhp	113.75nm@ 4000rpm	5
8	Maruti Wagon R LXI DUO BSIII	2007	96000	175000	LPG	Individual	Manual	First Owner	17.3 km/kg	1061 CC	57.5 bhp	7.8@ 4,500(kgm@ rpm)	5
9	Maruti 800 DX BSII	2001	45000	5000	Petrol	Individual	Manual	Second Owner	16.1 kmpl	796 CC	37 bhp	59Nm@ 2500rpm	4
10	Toyota Etios VXD	2011	350000	90000	Diesel	Individual	Manual	First Owner	23.59 kmpl	1364 CC	67.1 bhp	170Nm@ 1800-2400rpm	5
11	Ford Figo Diesel Celebration Edition	2013	200000	169000	Diesel	Individual	Manual	First Owner	20.0 kmpl	1399 CC	68.1 bhp	160Nm@ 2000rpm	5
12	Renault Duster 110PS Diesel RxL	2014	500000	68000	Diesel	Individual	Manual	Second Owner	19.01 kmpl	1461 CC	108.45 bhp	248Nm@ 2250rpm	5
13	Maruti Zen LX	2005	92000	100000	Petrol	Individual	Manual	Second Owner	17.3 kmpl	993 CC	60 bhp	78Nm@ 4500rpm	5
14	Maruti Swift Dzire VDI	2009	280000	140000	Diesel	Individual	Manual	Second Owner	19.3 kmpl	1248 CC	73.9 bhp	190Nm@ 2000rpm	5
15	Maruti Swift 1.3 VXI	2007	200000	80000	Petrol	Individual	Manual	Second Owner					

그림1. 데이터 구성

이름	Null 존재 여부	Dtype	설명
name	X	object	차량 모델명
year	X	int64	차량 연식
selling_price	X	int64	판매 가격 (화폐 단위: 루피) (Target 변수)
km_driven	X	int64	총 주행 거리
fuel	X	object	연료 타입
seller_type	X	object	판매자 유형
transmission	X	object	변속기 종류
owner	X	object	소유주 변경 이력
mileage	O (221)	object	연비
engine	O (221)	object	배기량
max_power	O (215)	object	최대 출력
torque	O (222)	object	토크
seats	O (221)	float64	승차 정원

표1. Column 정보

2. 데이터 전처리

2.1 중복 데이터 확인 및 처리

- ydata_profiling에서 중복 데이터의 존재 확인
- duplicated()를 활용하여 제거되어야 할 중복 데이터 1202건 확인 (전체 14.79%)
- 중복 데이터는 학습 데이터의 분포 왜곡 및 모델 성능 과대평가 가능성이 있어 제거 대상
- 중복 데이터 처리 후 전체 Row 수 (8128 -> 6926)

2.2 "범주형" -> "수치형" 변환

- mileage (연비) engine (배기량) max_power (최대 출력)와 같은 칼럼들이 고유한 단위로 인해서 object형으로 표현됨 (23.4 kmpl, 1248cc, 74 bhp 등)
- split(' ')을 활용하여 수치 정보만 수집 (23.4, 1248, 74)
- ' bph'와 같은 정보들은 수치가 포함되지 않은 사실상 Null 값

mileage	23.4 kmpl	21.14 kmpl	17.7 kmpl	23.0 kmpl	16.1 kmpl
engine	1248 CC	1498 CC	1497 CC	1396 CC	1298 CC
max_power	74 bhp	103.52 bhp	78 bhp	90 bhp	88.2 bhp
torque	190Nm@ 2000rpm	250Nm@ 1500- 2500rpm	12.7@ 2,700(kgm@ rpm)	22.4 kgm at 1750-2750rpm	11.5@ 4,500(kgm@ rpm)
seats	5.0	5.0	5.0	5.0	5.0
float_mileage	23.4	21.14	17.7	23.0	16.1
float_engine	1248.0	1498.0	1497.0	1396.0	1298.0
float_max_power	74.0	103.52	78.0	90.0	88.2
float_torque	190.0	250.0	12.7	22.4	11.5

그림2. 범주형 -> 수치형 변환 예시 자료

2.3 결측치 확인 및 처리

- seat, float_mileage, float_engine, float_max_power 칼럼들에 결측치 존재 확인
- 수치형 변수의 분포를 보았을 때, 치우친 느낌이 있어서 평균보다 중앙값으로 처리

2.4 Target 데이터 Log Scale

- Target 데이터인 Selling Price(판매 금액)의 데이터 분포 확인
- Target 데이터의 왜도 완화 및 값의 범위를 안정화 하기 위해 로그 스케일링 적용




그림3. Selling Price (Target), Log Scale 전/후 비교

2.5 변수 생성

○ 변수 생성

- “브랜드 + 모델명” 형식에서 브랜드명 추출

- Hyundai i20 Magna -> Hyundai

○ 파생 변수 생성

- 데이터 상 최대 연도인 2020년을 기준 연도로 설정

- 기준 연도 대비 차량이 오래된 정도인 “car_age = 2020 - year” 변수를 생성

2.6 범주형 인코딩

○ 범주형 변수 (owner, fuel, seller_type, transmission, brand_name) 인코딩

- owner의 경우, First Owner, Second Owner와 같이 순서에 의미가 있어서 Label Encoding

- 그 외 범주형 변수들은 One-Hot-Encoding

- brand_name의 경우, 브랜드명 32개 중 상위 9개가 전체 데이터의 91%에 해당하므로, 나머지는 others로 통합 후 Encoding

3. 탐색적 데이터 분석

3.1 HeatMap

○ 칼럼 간 상관관계 시각화




그림4. 히트맵 시각화 이미지

3.2 범주형 변수와 Target(price)과의 관계

○ 범주형 변수에 따른 로그 판매가격 분포




그림5. Box Plot

3.3 수치형 변수와 Target(price)과의 관계

○ car_age가 높을수록 (차량이 오래 되었을수록) 가격이 하락하는 모습




그림6. car_age와 log_selling_price의 관계

- Max Power(최대 출력)이 높을 수록 가격이 상승하는 모습




그림7. Max Power와 log_selling_price의 관계

4. 학습 및 모델 평가

4.1 Feature Selection

- 최종 입력 변수 구성
 - 수치형: car_age, km_driven, seats, float_mileage, float_engine, float_max_power, float_torque
 - 순서형: owner_encoding
 - 범주형: fuel, seller_type, transmission, brand_name
- 제외 변수
 - year는 car_age와 동일한 연식관련 정보를 포함하므로 제외
 - 원본 Object 형 칼럼 (mileage, engine, max_power, torque)는 수치형 변환 후 제외

4.2 모델 성능 비교

- 모델 성능 비교 표 (원래 가격 기준)

모델	MAE	RMSE	Test R ²
Linear Regression	95359	178429	0.85
RandomForest	74364	134371	0.91
XGBoost	73692	145666	0.9
LightGBM	71160	128428	0.92

표2. 성능 비교 표 (1)

○ 과적합/일반화 비교 표 (로그 스케일 기준)

모델	Train R ²	Test R ²	Gap
Linear Regression	0.87	0.86	0.1
RandomForest	0.98	0.9	0.08
XGBoost	0.97	0.9	0.07
LightGBM	0.94	0.91	0.03

표3. 성능 비교 표 (2)

4.3 Permutation Importance & SHAP

○ LightGBM 모델의 Permutation Importance

- 타 변수 대비 car_age의 중요도가 매우 높음




그림5. Permutation Importance 시각화 그래프

○ LightGBM 모델의 SHAP




그림6. SHAP

4.4 하이퍼 파라미터 튜닝 (LightGBM)

○ 주요 파라미터

- 트리 개수 (n_estimators), 학습률 (learning_rate), 최대 깊이 (max_depth), 리프 수 (num_leaves) 최소 샘플 수 (min_child_samples)

○ LightGBM의 하이퍼 파라미터 튜닝 전 후 성능 지표 비교

성능 지표	튜닝 전	튜닝 후	abs(Gap)
MAE	71160	70307	853
RMSE	128428	128015	413
Test R ²	0.9247	0.925	0.0003

표4. 하이퍼 파라미터 튜닝 전 후 성능 비교

4.5 성능 시각화

○ Actual vs Predicted




그림7. 실제 값과 예측 값 비교

5. Streamlit 프로토타입

○ 차량 정보 (변수) 입력 페이지

★ 가격 예측 📄 모델 정보

차량 정보 입력

※ 기준 연도는 2020년으로 설정되어 있으며, 연식 입력은 2020년 이하로 제한됩니다.

연식 (Year)	소유주 이력
2018 - +	Test Drive Car ▾
주행거리 (km)	브랜드
40000 - +	Maruti ▾
좌석 수	연비 (kmpl)
5.00 - +	18.00 - +
연료 타입	배기량 (CC)
Diesel ▾	1200.00 - +
판매자 유형	최대출력 (bhp)
Individual ▾	80.00 - +
변속기	토크 (Nm)
Manual ▾	120.00 - +

그림8. Streamlit 변수 입력 화면

○ 중고차량 가격 예측 결과



그림9. 입력 기반 가격 예측 결과

○ 사용한 모델의 성능 정보




그림 10. 최종 모델 LightGBM 평가 지표

6. 한계점 및 개선 방향

6.1 한계점 및 개선 방향

- torque 칼럼은 표기 형식과 단위가 매우 다양
 - 따라서 현재 프로젝트에서는 단순 일부 수치 추출 수준으로만 활용
 - 향후 보다 정교한 전처리를 통해 성능 변수로 반영하도록 개선 예정
- 차량명(name) 칼럼에서는 현재 브랜드 정보만 추출하여 활용
 - 동일 브랜드 내에서도 모델별 가격 차이가 발생 할 여지 존재
 - 향후 모델명까지 분리·추출하여 가격 예측 변수로 활용 가능하게 개선 예정
- 가격 및 일부 수치형 변수에서 극단적인 값이 관찰
 - 중고차 시장 특성상 실제 거래 가능한 값일 가능성 존재
 - 본 단계에서는 별도 제거하지 않음
 - 향후 이상치 기준을 명확히 설정 및 모델 성능에 미치는 영향을 비교 검토할 필요성 확인
- 파생 변수인 car_age 변수의 설명력이 매우 높음
 - 변수 중요도가 0.6 이상 나오면서, 다른 변수의 영향이 상대적으로 축소됨
 - 다른 변수의 표현력을 보강하거나 보다 의미있는 변수를 생성하여 개선 필요
- 인도 중고차 시장을 기반으로 수집된 데이터 셋
 - 판매 가격의 화폐 단위가 인도 루피(INR) 기준
 - 국내 중고차 시장과 직접적인 비교 및 일반화하기 어려움